

호출 너머의 LLM 운영

LARGE LANGUAGE MODEL (LLM)

01 TRACE

02 COMPARE

03 EVALUATE

04 IMPROVE

TRACE · 비교 실험 · 16주 서비스 개선 페루프

ARTIFICIAL INTELLIGENCE (AI) · PRODUCT MANAGER (PM)

차성재 · 무신사 Core AI PM × 아주대 AI대학원 겸임교수

1주차의 위치

CURRENT / WEEK 01 · 실시간 온라인

09.04

오리엔테이션과 서비스 개선 페루프

한 번의 모델 호출을 어떻게 재현·
비교·개선 가능한 서비스 실행으로
바꾸는가

16-WEEK PORTFOLIO RAIL

W01-03

문제·계약

W04-05

데이터·근거

W06-08

기술·기획

W09-10

서비스·관찰

W11-14

평가·운영

W15-16

통합·발표

WEEK 01 / COMPLETION EVIDENCE

01 프로젝트 문제 후보 1개

02 기준선·변형 실행 추적 2건

03 단일 변수 비교와 다음 개선 가설

04 교수 설계 리뷰 질문 1-3개

매주 같은 위치의 로드맵에서 해당 주차만 파랑으로 갱신

| 16주 수업 일정

전 주차 온라인 운영 · 기본 실시간 강의 · W04·W06 녹화 영상 · W08 온라인 제출

W01-08 / DESIGN

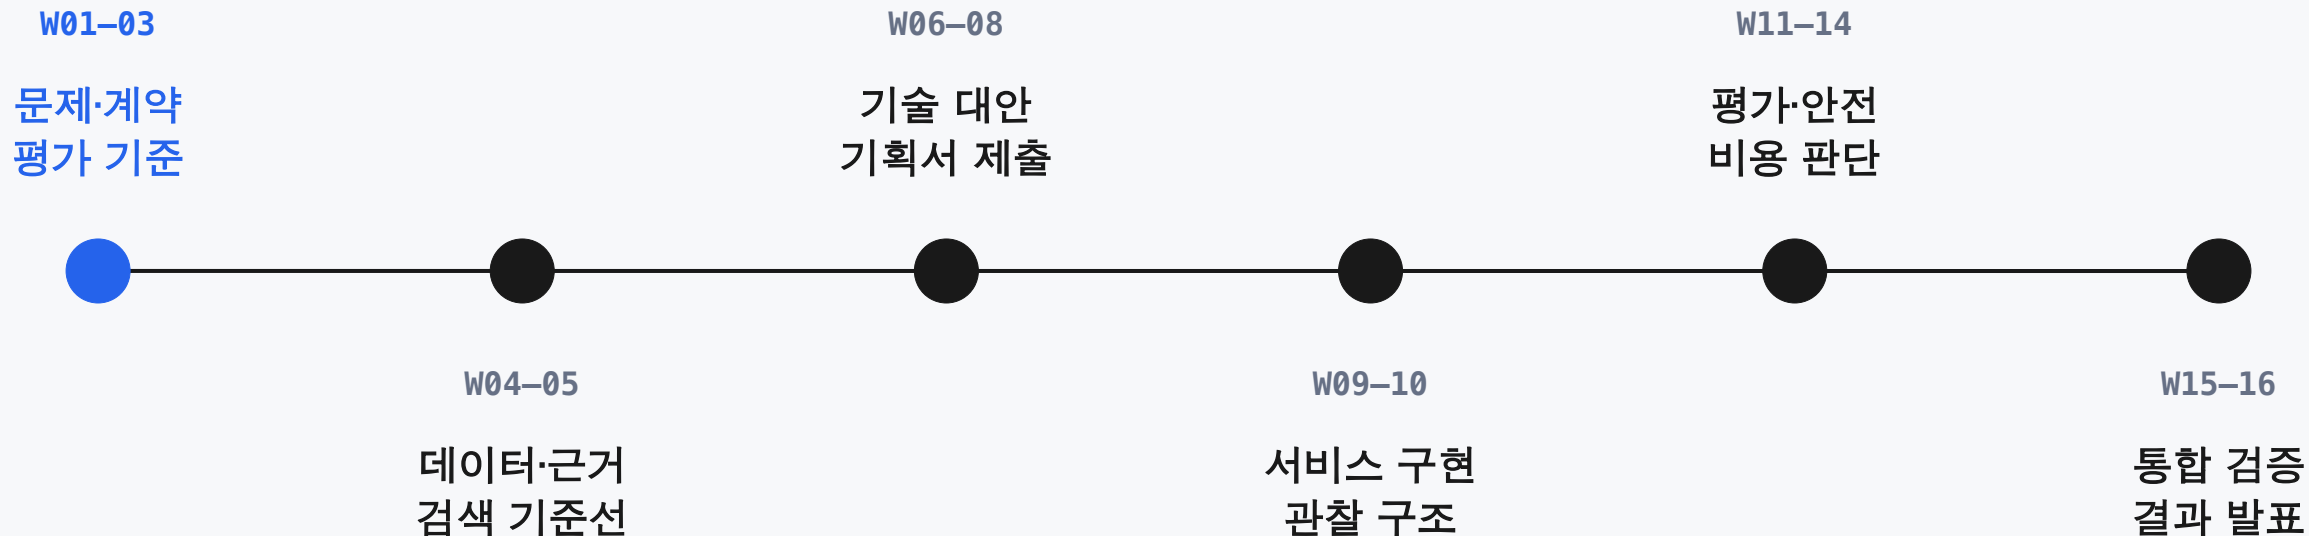
W01	09.04	오리엔테이션·페루프	현재 · 실시간
W02	09.11	프롬프트 계약·버전	실시간 온라인
W03	09.18	프롬프트 평가·오류	실시간 온라인
W04	09.25	검색 근거 계약	녹화 · 추석
W05	10.02	검색 품질·파이프라인	실시간 온라인
W06	10.09	미세조정·데이터	녹화 · 한글날
W07	10.16	선호 최적화·대안	실시간 온라인
W08	10.23	기말 프로젝트 기획서	온라인 제출

W09-16 / OPERATE

W09	10.30	요청·응답 서비스 계약	실시간 온라인
W10	11.06	관찰 가능한 배포	실시간 온라인
W11	11.13	오프라인 평가	실시간 온라인
W12	11.20	온라인 관찰·실험	실시간 온라인
W13	11.27	안전성·거버넌스	실시간 온라인
W14	12.04	비용·지연·용량	실시간 온라인
W15	12.11	통합 검증·리허설	실시간 온라인
W16	12.18	기말 프로젝트 발표	실시간 발표

W08 · 실시간 수업 없이 온라인 기획서 제출 평가 / W16 · 실시간 온라인 프로젝트 발표

| 16주 포트폴리오 로드맵



문제 정의 · 실행 증거 · 평가 기준 · 운영 판단 · 버전 개선의 누적

| 기획서 제출 패키지

화면 검토와 인쇄 제출을 함께 지원하는 세 가지 HTML 기준 문서

01

16주 과정 로드맵

현재 주차·학습 질문
주차별 일정·누적 산출물
온라인 영상 대체 일정

`curriculum/2026-2/web/
course-roadmap.html`

02

2페이지 제안서

문제와 사용자·기준선
입력·출력 계약
해법·평가·교수 질문

`curriculum/2026-2/web/
project-proposal-2pager.html`

03

제품 요구사항 문서(PRD)

기능·비기능 요구사항
데이터·권한·위험
수락·승격·중단 기준

`curriculum/2026-2/web/
project-prd.html`

W08 / ONLINE SUBMISSION

중간고사 없음 · 실시간 수업 없음 · 세 문서와 PPT 요약본의 온라인 제출로 평가

| 교수 설계 리뷰와 수정 기록

초안 0.1 · 근거 확인 · 학생 결정 · 수정안 0.2

DRAFT 0.1

DESIGN REVIEW

DECISION

REVISION 0.2

현재 기획

교수 질문

학생 판단

문서 수정

가정과 선택지
확인할 질문 1-3개

빈 근거와 경계
반례·추가 확인

채택 · 보류 · 반박
결정 이유

변경 전후와 근거
남은 위험

질의응답은 시험이 아닌 상시 설계 리뷰 · 최종 선택과 책임은 학생에게 귀속

| 공휴일 주차의 녹화 강의

W04 / 2026.09.25 · 추석

검색 근거 계약

실시간 온라인 강의 없음

녹화 강의영상 업로드로 대체

학습관리시스템 공지에 따른 시청·산출물 제출

완료 증거 · 데이터 출처·권한·검색 기준선

W06 / 2026.10.09 · 한글날

미세조정과 데이터

실시간 온라인 강의 없음

녹화 강의영상 업로드로 대체

학습관리시스템 공지에 따른 시청·산출물 제출

완료 증거 · 모델 적응 판단·데이터 제외 기준

| AI 제품과 교육의 운영 경험

차성재

무신사 Core AI PM × 아주대 AI대학원 겸임교수

Artificial Intelligence (AI) · Product Manager (PM)

금융 · 자동화 머신러닝과 운영

의료 · 컴퓨터 비전과 데이터 운영

교육 · 거대 언어 모델 운영과 AI 컨택센터

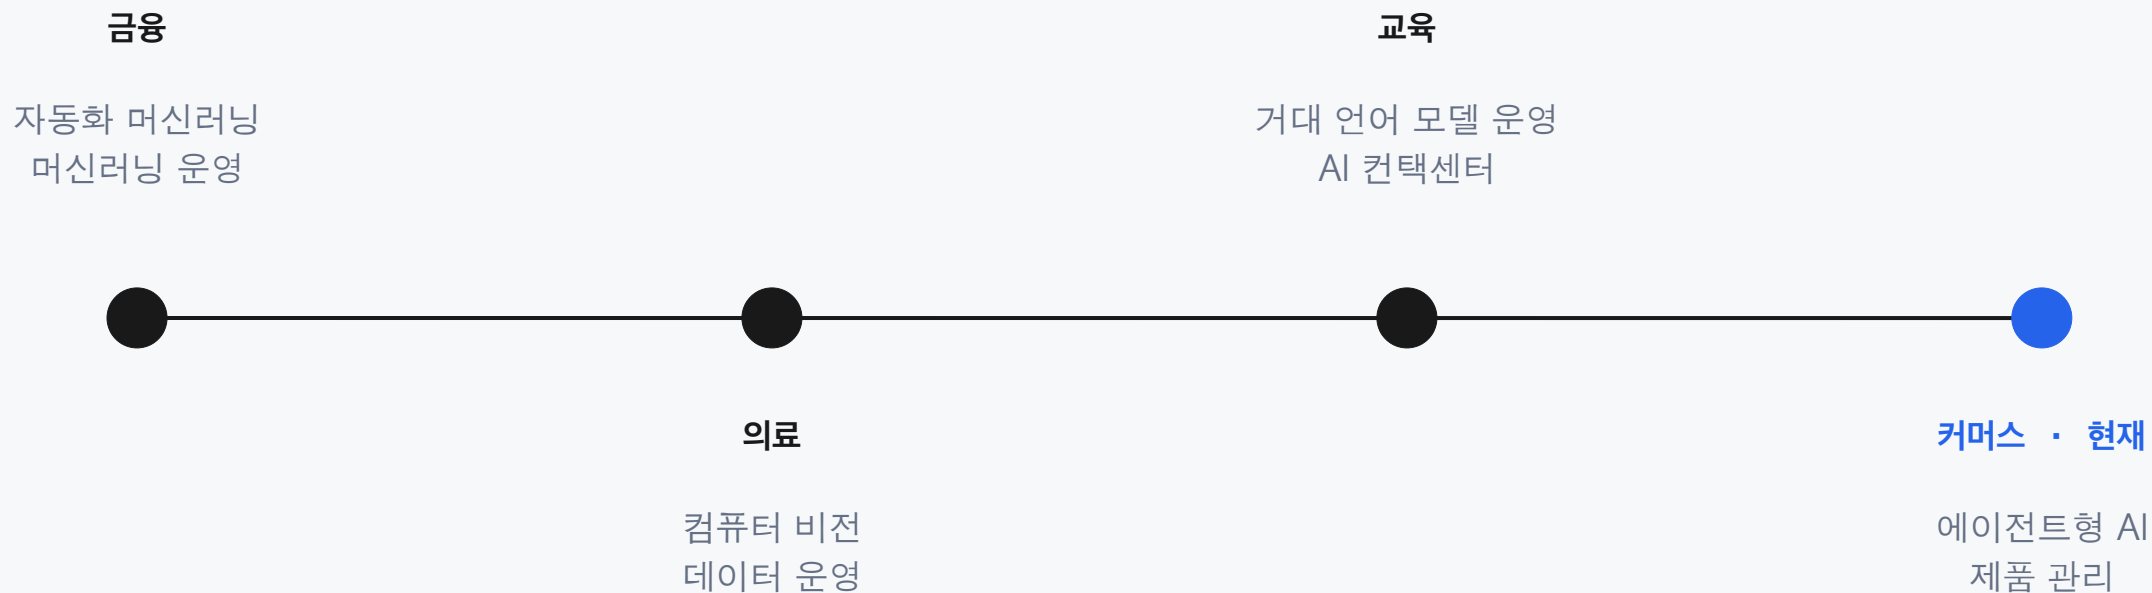
커머스 · 에이전트형 AI 제품



문제 정의 · 제품 계약 · 평가 · 운영 지표의 연결

PRODUCT · EDUCATION · OPERATION

| 정형 데이터에서 생성형 AI까지



도메인은 달라도 서비스 운영의 질문은 반복

| 도메인을 관통한 운영 질문

정확도 다음의 제품 운영 질문

현업에서는 한 번의 좋은 응답보다 같은 조건의 재실행, 실패의 관찰, 정책 통제와 변경 설명이 필요하다.


- | | | |
|----|--------|-------------|
| 01 | 재현성 | 같은 조건의 재실행 |
| 02 | 관찰 가능성 | 실패 위치와 분포 |
| 03 | 통제 가능성 | 권한·정책·대체 경로 |
| 04 | 설명 가능성 | 변경 이유와 판정 |

모델 점수 · 서비스 행동 · 운영 증거의 분리

| 두 라이프사이클의 관리 범위

비교 축	모델·시스템 수명주기	수업의 서비스 개선 페루프
단계 구조	1. 학습 (Training) 2. 평가 (Evaluation) 3. 배포 (Deployment) 4. 유지 (Maintenance) 5. 종료 (Retirement)	1. 기획·데이터 2. 프롬프트·맥락 3. 실행·배포 4. 평가·관찰 5. 개선·버전
관리 단위	모델 또는 전체 인공지능 시스템 생성부터 유지·종료까지의 상태	프롬프트·맥락·코드·설정·정책 서비스 행동과 실행 증거
수업의 사용	모델과 시스템의 전체 생애를 설명할 때 활용 가능한 분류	매주 실행을 재현·비교·판정하고 다음 버전을 설계하는 공통 좌표

| 수업 운영 프레임: 서비스 개선 페루프



COURSE STANDARD

16주 산출물을 연결하는 교육용 운영 작표계

업계의 단일 표준을 주장하지 않는다. 이미 학습된 기반 모델을 포함한 서비스를 반복적으로 관찰하고 개선하기 위한 공통 프레임이다.

판정 경계

계속 · 교체 · 종료

| 판정 가능한 개선의 조건

01

기준

성공·금지 조건

02

맥락

사용자·업무·데이터

03

버전

변경 대상과 이유

04

평가

같은 축의 비교

정답 암기가 아니라 다른 사람이 다시 판정할 수 있는 운영 계약

| 1주차 완료 상태



실행 서비스

상태 확인과 사용자 화면 (User Interface, UI)



실행 추적 두 건

같은 입력의 기준선과 변형



단일 변수

프롬프트 버전 또는 생성 온도



비교 표


출력·상태·응답 지연·토큰



개선 가설

변경·기대·판정의 두 문장

| 첫 호출의 전환



한 번의 생성 결과 → 팀이 다시 확인할 수 있는 실험 단위

| 기준 사례: 고객 피드백 도우미

INPUT

“결제는 빨랐지만 교환 절차를 찾기 어려웠어요. 다음 주문 전에는 개선되면 좋겠어요.”

OUTPUT CONTRACT

- 01 핵심 요약
- 02 핵심 신호
마찰 지점
다음 행동
- 03 실무 문장 재작성

OPERATING EVIDENCE

trace_id
prompt_version
provider / model
status / latency
token_estimate
content_fingerprint

| 눈에 보이는 호출과 운영 체계

VISIBLE

프롬프트 → 모델 → 응답

OPERATING SYSTEM

평가 데이터

버전

평가

시간 초과

대체 경로

안전성

비용

책임자

데모의 화면보다 배포 판단에 필요한 운영 증거의 구조


01

FROM CAPABILITY TO RELIABILITY

능력의 형성과 신뢰성의 간극

규칙 · 데이터 · 연산 · Attention · Pretraining

| AI 역사의 네 번의 병목 이동



새 능력은 이전 운영 문제를 지우지 않고 새로운 관리 대상을 추가

| 규칙 기반 시스템의 경계

EXPLICIT RULES

IF / THEN의 명시성

동작을 직접 설명하고 통제하기 쉬움

작은 범위와 안정된 규칙에 강점

EXCEPTION GROWTH

예외의 조합 폭증

규칙 수와 상호작용이 빠르게 증가

모호한 언어·영상·패턴에 취약

| 데이터 기반 학습의 전환

BEFORE

사람이 규칙을 작성

도메인 규칙 → 코드 → 결과

오류 수정은 규칙의 직접 변경

AFTER

데이터에서 패턴 추정

데이터 + 목표 → 학습 → 모델

오류 수정은 데이터·목표·모델의 변경

| 딥러닝의 세 조건

01

데이터

다양한 학습 신호와 충분한 규모

02

그래픽 처리 장치

Graphics Processing Unit (GPU) 기반
병렬 연산

03

학습 구조

역전파·아키텍처·최적화

데이터 · 병렬 연산 · 학습 구조의 결합

| 표현 학습의 변화

HAND-CRAFTED FEATURE

사람의 특징 설계

원시 데이터 → 특징 추출 → 모델

도메인 전문지식이 병목


REPRESENTATION LEARNING

학습된 표현

원시 데이터 → 계층 표현 → 출력

데이터와 목표의 품질이 병목

| 시퀀스 모델의 순차 병목



이전 위치의 계산을 기다리는 순차성 · 멀리 떨어진 정보의 긴 전달 경로

| 자기 주의의 핵심 질문

입력 토큰

고객

은

교환

절차

불편

현재 해석 위치

불편

01

질의(Query)

현재 위치가
찾는 관계

02

키(Key)

각 토큰의
비교 단서

03

값(Value)

선택된 정보의
전달 내용

현재 위치를 이해하기 위해 다른 위치를 얼마나 참고할지 계산


| 토큰 관계의 가중치 지도

	고객	교환	절차	불편	개선
고객	0.9	0.2	0.1	0.2	0.1
교환	0.2	0.9	0.6	0.2	0.2
절차	0.1	0.7	0.9	0.8	0.4
불편	0.2	0.2	0.8	0.9	0.6
개선	0.1	0.3	0.5	0.7	0.9

색의 강도 =
해석에 기여한 관계 가중치


가중치는 설명용 예시이며 실제 모델의 자기
주의(attention) 값이 아님

| 트랜스포머의 관계 계산 구조



Q=Query · K=Key · V=Value · FFN=Feed-Forward Network

| 사전학습의 다음 토큰 목표



생성형 디코더 전용 대규모 언어 모델의 대표적인 사전학습 목표

| 범용 언어 능력의 목록

01

생성

초안·아이디어

02

요약

압축·핵심

03

변환

문체·형식

04

분류

레이블·경로

05

코드

생성·해석

하나의 모델이 여러 자연어 작업을 수행하는 범용성

| 서비스 보장의 공백

모델 능력 · MODEL CAPABILITY

생성 가능한 것

요약 · 번역 · 질의응답 · 코드 · 멀티모달

확률적 일반화 능력

서비스 신뢰성 · SERVICE RELIABILITY

별도 계약이 필요한 것

사실성 · 최신성 · 권한 · 지연 · 비용 · 안전

운영 환경의 판정 기준

| 생성형 시스템의 변동성

같은 애플리케이션 코드도 실행 조건의 버전 조합에 따라 다른 결과

모델

외부 맥락

생성 설정

프롬프트

provider · tag · revision

retrieval · tool result

temperature · seed

template · example

제공자·모델 태그·개정

검색 결과·도구 반환값

온도·난수 시드

템플릿·예시·정책

모델만 기록하지 않고 네 버전을 하나의 실행 추적으로 결합

| 제품 정의의 잔여 과제

모델 능력 $\neq$ 서비스 신뢰성

사용자

누구의 결정을 지원

맥락

어떤 상황과 데이터

성공

무엇을 얼마나 잘

경계

금지 행동과 책임

남은 과제의 소유자는 모델이 아니라 제품과 운영 팀

02

INTERVENTION LEVERS

서비스 행동의 개입 레버

프롬프트 · 검색 · 도구 · 모델 선택 · 사후학습

| 개입 레버의 비용·가역성 지도

비용·시간

파랑 = 이번 가설을 가장 싸고 빠르게 검증할 첫 변경점



| 프롬프트의 통제 범위

역할

응답 관점과 책임

지시

해야 할 일과 금지 행동

예시

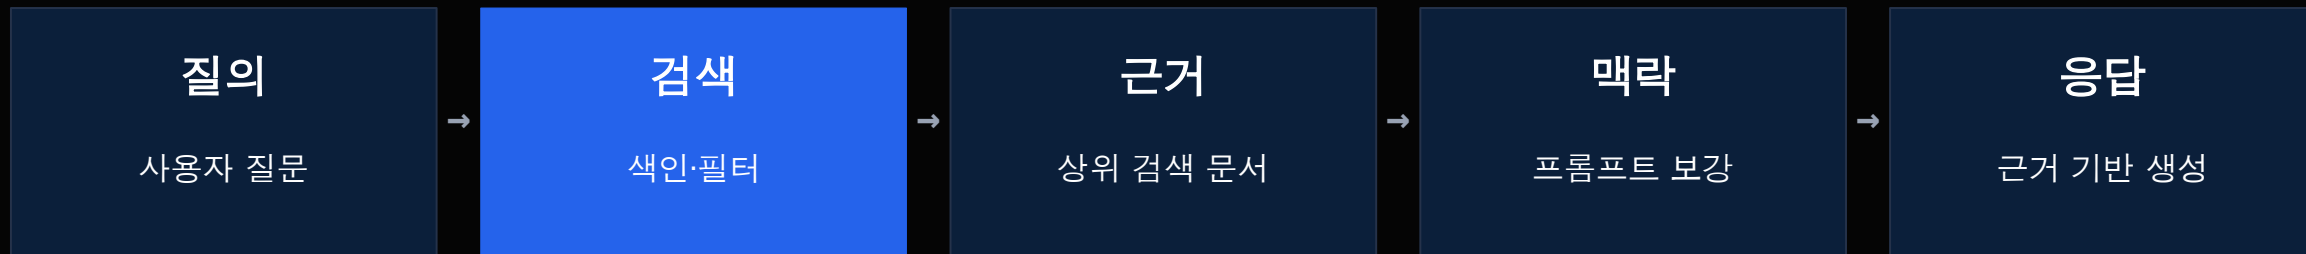
입력·출력 패턴

출력 스키마

형식·필드·길이

모델 weight 바깥에서 빠르게 변경·버전·rollback 가능한 제어면

| 검색 증강 생성의 외부 근거



검색 증강 생성 (Retrieval-Augmented Generation, RAG) 의 근거·최신성·권한 계약

| 도구 호출의 행동 경계

모델 · MODEL

행동의 제안

도구 이름과 인수를 생성

확률적 판단 · 외부 변경 없음

실행 환경 · RUNTIME

권한이 있는 실행

스키마 검증 · 승인 · 실제 응용 프로그래밍 인터페이스
호출

시간 초과 · 감사 · 먹등성

| 모델 라우팅의 선택 축

요청 유형	우선 축	모델 선택 기준
짧은 분류	지연 · 비용	작은 모델 · 짧은 제한시간 · 일괄 처리
근거형 답변	품질 · 안전	검색 증강 생성 · 인용 · 보호 정책
복잡한 추론	품질 · 토큰	긴 맥락 · 상위 모델 · 예산
민감 데이터	권한 · 위치	로컬·사설망 · 로그 정책 · 마스킹

| 지도 미세조정의 행동 학습



지도 미세조정 (Supervised Fine-Tuning, SFT) · 반복 행동을 좋은 예시로 적응

| 지도 미세조정 데이터의 최소 계약

01

지시

고객 피드백에서
핵심 신호·마찰·다음 행동 추출

02

입력

실제 분포를 닮은 합성·검수 입력
민감 원문 제외

03

기대 출력

고정 스키마
근거 있는 값

잘못된 예시는 잘못된 행동을 더 일관되게 재현

| 선호 데이터의 구조

선호 응답 · CHOSEN

짧고 근거 있는 응답

요청한 스키마 준수

입력에 없는 사실 없음

실행 가능한 다음 행동

비선호 응답 · REJECTED


그렇듯하지만 불리한 응답

형식 누락

새 사실 추가

과도한 상황함


| 인간 피드백 기반 강화학습의 대표 경로



Reinforcement Learning from Human Feedback (RLHF) · Proximal Policy Optimization (PPO)

| 직접 선호 최적화의 두 경로

PPO 기반 RLHF



Reinforcement Learning from Human Feedback · Proximal Policy Optimization

직접 선호 최적화(DPO)




Direct Preference Optimization (DPO) · 참조 정책과 선호 쌍의 직접 최적화

| 저랭크 적응의 변경 단위



+



작은 변경 단위 · 독립 저장 · 교체 가능한 실험

Low-Rank Adaptation (LoRA) · Parameter-Efficient Fine-Tuning (PEFT)

| 개입 순서의 기본 휴리스틱

가장 낮은 비용의 검증에서 시작해 근거가 쌓일 때 다음 변경으로 이동

01	기준선	현재 품질·비용·응답 지연·실패 분포의 기록
02	프롬프트	모델 가중치 밖의 지시·예시·출력 형식 변경
03	검색·도구	외부 사실 근거와 실제 행동의 연결
04	모델 선택	능력·비용·지연·배포 제약의 교체 검증
05	미세조정	반복 행동 패턴을 가중치에 반영할 근거 확인

데이터·평가셋·배포 이득이 없으면 미세조정보다 앞 단계의 개선

03

OPERATING ASSETS & LOOP

운영 관심사와 관리 자산의 확장

코드 · 데이터 · 모델 · 프롬프트 · 맥락 · 실행 추적 · 평가

| 세 운영 영역의 관심사 확장

DevOps

CODE · BUILD · RELEASE · RUNTIME

Development and Operations · 코드의 빌드·테스트·배포·관찰

MLOps

DATA · FEATURE · MODEL · EXPERIMENT

Machine Learning Operations · 데이터·학습·모델의 버전과 품질 관문

LLMOps

PROMPT · CONTEXT · TRACE · EVALUATION

Large Language Model Operations · 맥락·응답·피드백·보호 정책

대체 관계가 아니라 운영 대상과 증거 구조의 누적

| LLM 서비스의 추가 운영 자산

EXECUTION KEY

TRACE ID

한 번의 실행을
다시 찾는 식별자

ff2c901e8a16

01	프롬프트 버전	템플릿 · 예시 · 정책
02	외부 맥락 참조	검색 문서 · 도구 반환값
03	응답과 운영 값	출력 · 상태 · 응답 지연
04	평가와 피드백	점수 · 오류 유형 · 판정

| 동일 코드의 서로 다른 동작

같은 코드 · SAME CODE

커밋 a1b2c3

동일 접근 경로

동일 요청 스키마

동일 애플리케이션 코드

다른 실행 · DIFFERENT RUN

프롬프트 · 맥락 · 모델 · 설정

서로 다른 출력

서로 다른 응답 지연·토큰·상태

서로 다른 품질 판정

| 버전 조합의 실행 단위

추적 식별자 · TRACE ID

ff2c901e8a16

과업 · 설정

extract / t=0.2

출력

execution evidence

프롬프트 버전

w01.signal.v1

상태 · 응답 지연

ok / 0.12 ms

추정 토큰

estimate: 63

제공자 · 모델

demo / trace-demo-1

콘텐츠 참조

sha256:ffdf...fe72

생성 시각

UTC timestamp

Trace ID = 버전 자산과 실행 증거를 연결하는 결합 키 · UTC = Coordinated Universal Time

| 이 과목의 다섯 공통 판단 축

01	품질	업무 정답 · 근거 · 형식 · 유용성
02	응답 지연	평균 · 50번째 백분위 · 95번째 백분위 · 시간 초과
03	비용	토큰 · 모델 · 도구 · 캐시
04	안전성	개인 식별 정보(Personally Identifiable Information, PII) 프롬프트 주입 · 권한 · 감사
05	재현성	환경 · 버전 · 실행 추적 · 커밋

| 운영 지표의 상충 관계

한 지표의 개선은 다른 지표의 비용을 함께 확인할 때만 운영 판단으로 완성

판단 축	변경 레버	함께 확인할 손실
품질 ↔ 비용	상위 모델 · 긴 맥락	요청당 비용 · 처리량
품질 ↔ 응답 시간	검색 · 도구 · 판정 단계	대기시간 · 시간 초과
안전 ↔ 처리 범위	차단 강도 · 사람 검토	정상 요청 누락
재사용 ↔ 최신성	캐시 적중 · 응답 재사용	정보 노후화


네 관계는 고정 법칙이 아니라 실험 전에 함께 관찰할 위험 가설

| 품질 지표의 업무 의존성

업무	우선 품질 축	대표 실패
요약	충실성 · 압축률 · 핵심 보존	새 사실 추가 · 중요 정보 누락
정보 추출	스키마 준수 · 필드 정확성	필드 누락 · 근거 없는 값
검색 증강 답변	근거성 · 인용 정확도	근거 미검색 · 잘못된 인용
에이전트 행동	과업 성공 · 정책 준수	권한 없는 실행 · 중복 행동

| 지연시간의 분포 관점

설명용 분포 · 실제 측정값 아님



| 요청 단위 비용의 구조

$$\text{요청 비용} = \text{생성} + \text{워크플로} + \text{실패} - \text{재사용}$$

생성	워크플로	실패	재사용
입력·맥락·출력 토큰	검색·재순위·판정·도구	재시도·대체 경로·시간 초과	캐시·일괄 처리·모델 선택

모델 단가만이 아니라 한 요청이 실제로 거치는 전체 경로

| 안전성의 권한·데이터 경계

입력

개인 식별 정보

정책 분류

프롬프트 주입

실행

도구 허용목록

시간 초과

사람 검토

출력

근거 연결

금지 표현

감사 로그

저장

원문 최소화

보존 기간

접근 통제

| 재현성의 다섯 고정값



환경

Python · 패키지 · 운영체제 · 가속기



입력

평가 데이터 개정 · 콘텐츠 지문



지시

프롬프트 식별자 · 버전 · 스키마



실행


제공자 · 모델 · 설정



코드

커밋 · 접근 경로 · 정책

| 서비스 개선 페루프의 전체 구조



COURSE STANDARD

관찰 결과가 다음 기획과 변경
가설의 입력

품질·지연·비용·안전·재현성은 한 단계가
아니라 전 단계를 가로지르는 판단 축이다.
특정 마지막 노드는 없다.

판정 경계

계속 · 교체 · 종료

| 1단계 / 기획·데이터의 성공 계약

PROJECT BRIEF

누구의 어떤 결정을 돕는가?

모델 선택보다 먼저 문제·데이터·평가의 범위를
프로젝트 브리프로 고정

01

대상 사용자와
지원할 의사결정

02

대표 입력과
기대 행동

03

성공·금지 조건과
평가 데이터

04

데이터 권한·개인정보·
보존 경계

| 2단계 / 프롬프트·맥락의 버전 계약

02

OPERATING QUESTION

무엇이 바뀌었고 왜 바뀌었는가?

01

프롬프트 식별자·버전·책임자

02

입출력 스키마·예시

03

검색·도구 맥락 참조

읽기 좋은 프롬프트보다 고정 평가 데이터에서 비교 가능한 프롬프트

1 기획·데이터

2 프롬프트·컨텍스트

3 실행·배포


4 평가·관찰

5 개선·버전

| 3단계 / 실행·배포의 실패 경로

실패했을 때 어디로 흐르는가?

정상 경로



실패 경로




정상선만 있는 아키텍처는 운영 문서가 아닌 데모 문서

| 4단계 / 평가·관찰의 분포 기준

누가, 언제, 어떻게 실패하는가?

설명용 응답 지연 분포 · 실제 측정값 아님



품질

대표 성공·실패

운영

95백분위 · 오류율

자원·안전

토큰 · 비용 · 위험 신호

평균 점수와 함께 실패 분포·하위 집단·원본 실행 추적 확인

| 5단계 / 개선·버전의 판정 기록

다음 버전은 무엇을 검증하는가?

01

이전 기준선

현재 실패와
고정 조건

02

새 가설과 변경

검증할 가설과
바꿀 한 가지

03

실행 증거

비교 가능한
실행 추적

04

판정과 다음 버전

승격·보류·되돌리기와
다음 질문

‘더 좋아 보임’이 아닌 변경 이유·결과·결정의 연결

| 버전 변경의 최소 기록

VERSION	HYPOTHESIS	CHANGE	DECISION
v0.1.0	교환 절차 누락 감소	스키마와 예시 추가	기준선
v0.2.0	마찰 필드 완전성 향상	프롬프트 버전만 변경	승격
v0.2.1	지연 증가 없는 표현 축약	최대 길이 조정	보류

버전 번호보다 중요한 연결: 가설 → 변경 → 실행 추적 → 판정

| 서비스 페루프와 학기 프로젝트의 정렬

서비스 개선 단계

01	02	03	04	05
기획·데이터	프롬프트·맥락	실행·배포	평가·관찰	개선·버전

학기 마일스톤

W01-07	W08	W09-15	W16
온라인 운영 W04·06 녹화	온라인 제출 제출본 평가	실시간 온라인 구현·운영 검증	실시간 온라인 프로젝트 발표

W08 온라인 제출본 평가 · W16 실시간 온라인 프로젝트 발표

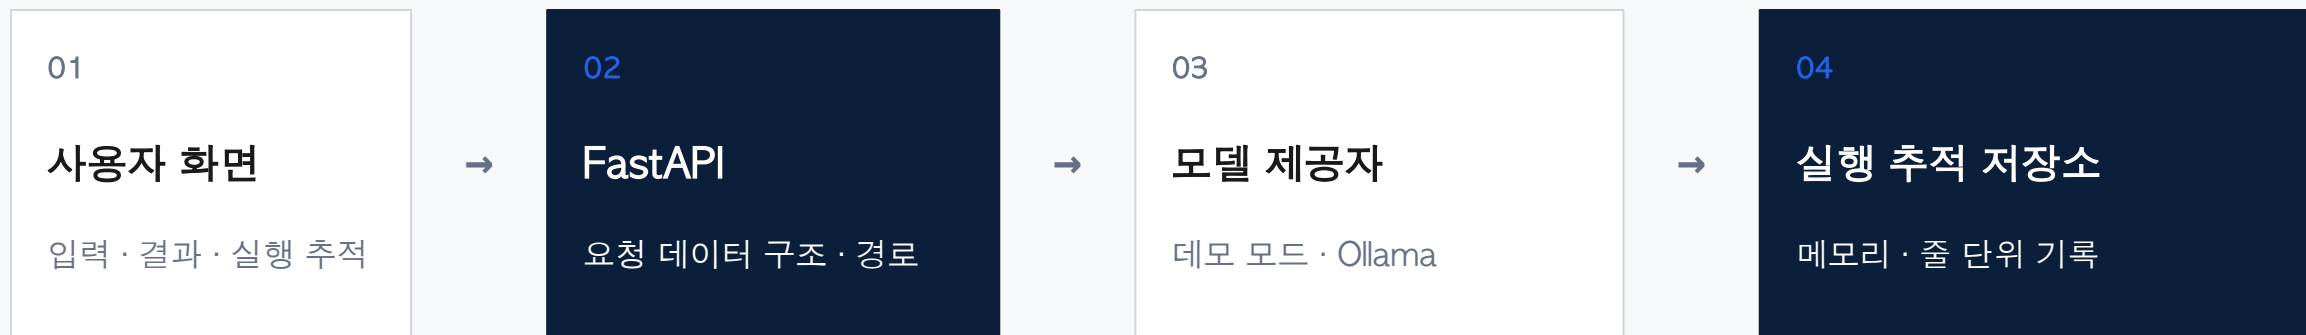
04

TRACE / 01 LAB

첫 운영 루프의 실행

Python 3.11.14 · FastAPI · 결정론적 데모 · Ollama · 실행 추적 · 비교

| TRACE/01의 서비스 계약



한 요청에서 생성 결과와 운영 메타데이터를 함께 반환

| 실습 완료의 다섯 증거



서비스 상태

GET /health → 정상 응답



실행 추적 2건

동일 입력의 기준선·변형



단일 변경

프롬프트 버전 또는 생성 무작위성



비교 판단

출력·상태·응답 지연·토큰



다음 가설

변경·기대·판정의 두 문장

| 16주 개발환경의 공통 기준

PYTHON 3.11.14

모든 주차의 기준 인터프리터

공통 기반

Jupyter · Requests · pandas · pytest

주차별 프로필

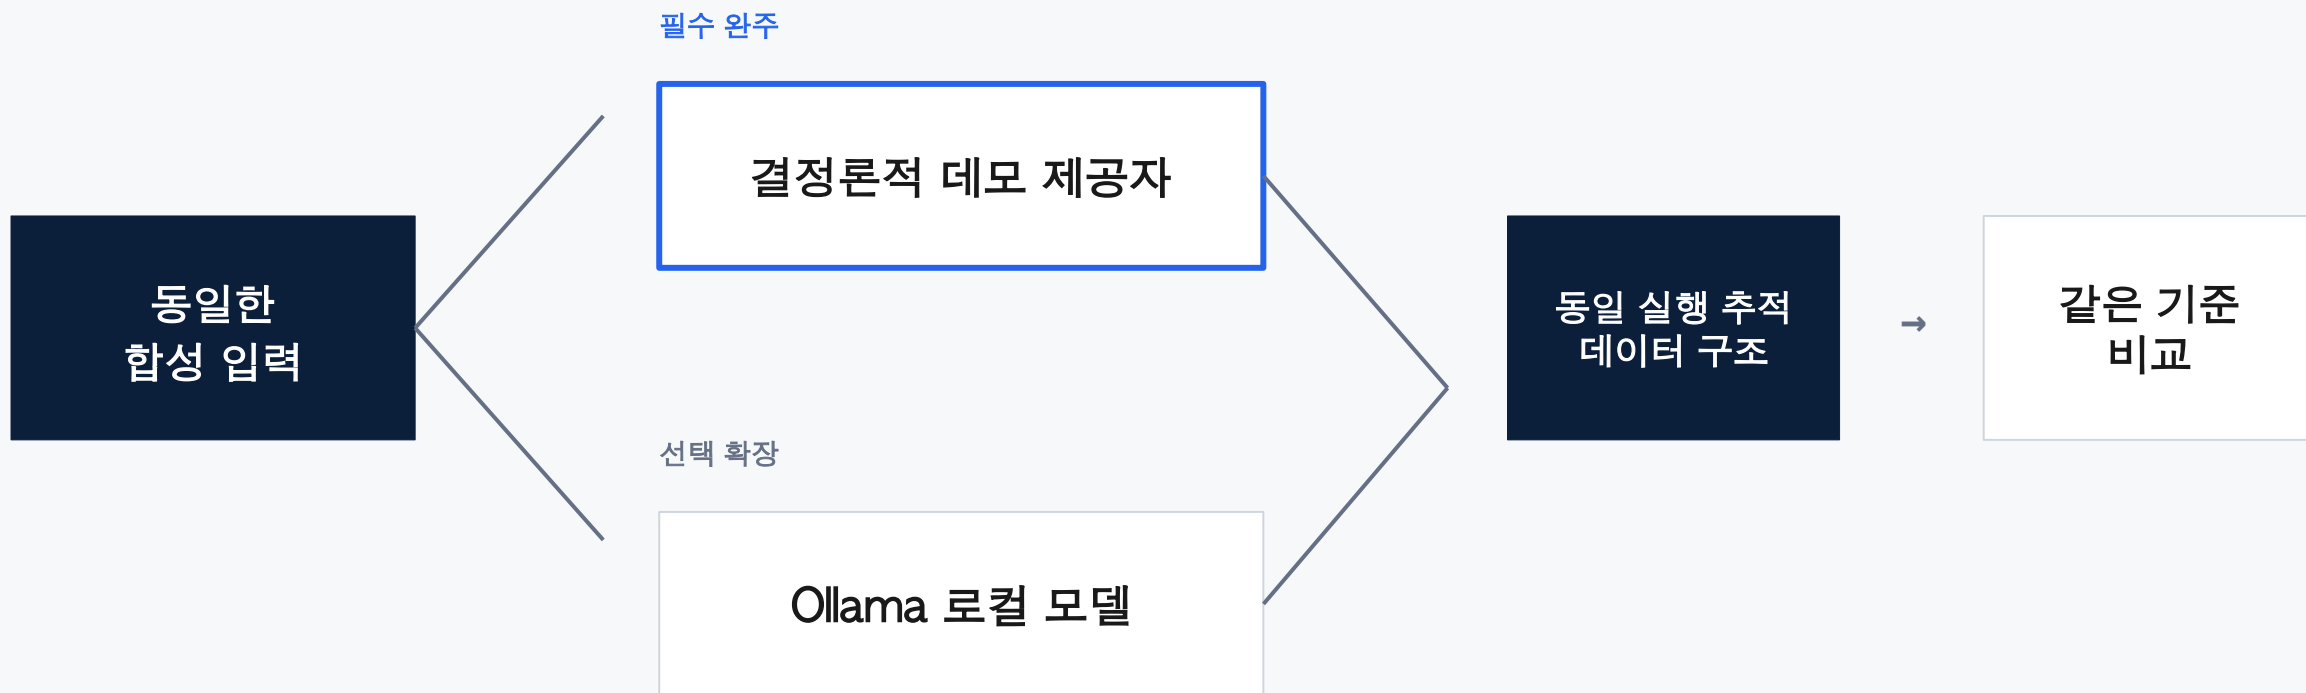
응용 프로그래밍 인터페이스 · 검색 증강 생성 · 미세조정 · 에이전트

버전 잠금

macOS · 64비트 Arm 아키텍처(ARM64) 등
검증된 조합


하나의 거대 환경 대신 공통 기반과 충돌 주차별 프로필

| 필수 완주와 선택 확장의 분기



설치 여부와 무관한 공통 실행 추적 · 같은 데이터 구조 · 같은 평가 기준

Visual Studio Code 환경과 테스트 증거



현장 확인

인터프리터

Python 3.11.14

자동 테스트

6 passed

환경 설정

.vscode 4종

| 응용 프로그래밍 인터페이스 요청 계약

TRACE/01 1.0.0 OAS 3.1
/openapi.json
Week 01: one request, one trace, one improvement loop.

default ^

GET /health Health

POST /api/v1/generate Generate

Parameters Try it out

No parameters

Request body required application/json

Example Value | Schema

```
{
  "text": "string",
  "task": "summarize",
  "provider": "demo",
  "temperature": 0.2
}
```

[계약 확인](#)[요청 경로](#)[POST /api/v1/generate](#)[본문 형식](#)[application/json](#)[잘못된 요청](#)[422 검증 오류](#)

| 네 관찰 경로의 역할

01

[/traces](#)

개별 실행과 원본 메타데이터

02

[/stats](#)

수업용 통계 집계와 비교

03

[/metrics](#)

Prometheus 수집 형식

04

[/docs](#)

요청·응답 데이터 구조

실행 한 건 · 사람의 비교 · 운영 수집 · 계약 확인의 서로 다른 관점

| 실습 사용자 화면의 입력 구성

01 입력
Input

02 프롬프트
Prompt

03 실행
Run

04 추적
Trace

05 개선
Improve

입력 · Input

82 / 6000

배송은 빨랐지만 추천 결과가 매번 달라서 비교하기 어려웠습니다. 어떤 프롬프트와 모델을 썼는지 기록되면 팀이 더 빠르게 개선할 수 있을 것 같아요.

작업

실행

온도

신호 추출

▼

Demo · 오프라인 규칙 엔진

▼

0.2

응답 · Output

정상

SIGNAL — 배송은 빨랐다는 관찰

FRICTION — 추천 결과가 매번 달라서 비교하기 어려웠습니다.

NEXT ACTION — 같은 입력 세트로 다음 버전을 비교하고 지표를 기록한다.

추적 식별자 · Trace ID

프롬프트 버전 · Prompt version

모델 · Model

ff2c901e8a16

w01.signal.v1

trace-demo-1

응답 지연 · Latency

추정 토큰 · Estimated tokens*

콘텐츠 지문 · Content fingerprint

| 실행 결과와 추적 증거의 동시 확인

입력 · Input82 / 6000

배송은 빨랐지만 추천 결과가 매번 달라서 비교하기 어려웠습니다. 어떤 프롬프트와 모델을 썼는지 기록되면 팀이 더 빠르게 개선할 수 있을 것 같아요.

작업

실행

온도

신호 추출

▼

Demo · 오프라인 규칙 엔진

▼

0.2

추적 실행 · Run trace

원문은 저장하지 않습니다. 12자리 콘텐츠 지문(content fingerprint)과 실행 메타데이터만 기록합니다.

응답 · Output정상

SIGNAL — 배송은 빨랐다는 관찰
FRICTION — 추천 결과가 매번 달라서 비교하기 어려웠습니다.
NEXT ACTION — 같은 입력 세트로 다음 버전을 비교하고 지표를 기록한다.

추적 식별자 · Trace ID	프롬프트 버전 · Prompt version	모델 · Model
ff2c901e8a16	w01.signal.v1	trace-demo-1
응답 지연 · Latency	추정 토큰 · Estimated tokens*	콘텐츠 지문 · Content fingerprint
0.12 ms	63	ffdf1925fe72

전체 실행 · Total runs

성공률 · Success rate

95백분위 응답 지연 · P95 latency

추정 토큰 · Estimated tokens

2

100%

0.2 ms

126

실행 추적 ff2c901e8a16

실행 상태

정상

응답 지연

0.12 ms

추정 토큰

63

| 기준선·변형의 단일 변수 실험

RUN A / BASELINE		Δ	RUN B / VARIANT
입력	동일 합성 고객 피드백	=	동일 합성 고객 피드백
작업·모델	구조 추출 · llama3.1:8b	=	구조 추출 · llama3.1:8b
생성 무작위성	온도 0.2	Δ	온도 0.8
관찰	데이터 구조 · 사실성 · 자연	$\leftrightarrow$	데이터 구조 · 사실성 · 자연

결정론적 데모는 기준선 · 생성 무작위성 차이는 Ollama 선택 경로에서 관찰

| 실행 화면 기반 판정 증거

입력 근거성

관찰됨

출력의 핵심 신호와 마찰 요인이 합성 입력에 근거

형식 계약

3개 필드

핵심 신호 · 마찰 요인 · 다음 행동의 구조화 출력

실행 상태

정상

오류 없이 결과와 실행 추적을 함께 반환

응답 지연

0.12 ms

현재 로컬 결정론적 데모 호출의 관찰값

가상 점수 대신 화면에서 확인한 상태·형식·응답 지연과 근거 판단

| 구조 추출의 판정 기준

01

핵심 신호

사용자가 실제로 말한 핵심 관찰

존재 · 입력 근거

출력 데이터 구조가 형식 평가의 최소 기준 · 내용의 근거성과 별도 판정

02

마찰 요인

결정이나 행동을 막는 구체적 불편

구체성 · 행동 연결

03

다음 행동

다음 실험 또는 제품 행동

담당 · 검증 가능

| 실패 유형별 복구 경로

422	요청 데이터 구조 오류	→	작업·제공자·온도 범위 확인
503	Ollama 연결 또는 모델 부재	→	데모로 완주 → Ollama 실행·모델 다운로드 확인
시간 초과	응답 제한시간 초과	→	실행 추적 확인 → 입력 길이·모델·제한시간 점검
차이 없음	두 실행의 비교 불가	→	동일 입력·평가축 고정 → 변수 하나만 변경

첫 포트폴리오 기록

- | | | |
|----|-------|----------------------------|
| 01 | 문제 후보 | 기말 프로젝트로 검증할 사용자·문제 후보 1개 |
| 02 | 실행 증거 | 오늘 만든 실행 추적 2건과 비교 판단 1개 |
| 03 | 교수 질문 | 다음 질의응답에서 확인할 질문 3개와 수정 이력 |