

# LLM 서비스 운영의 기본

LARGE LANGUAGE MODEL (LLM)

01 TRACE

02 COMPARE

03 EVALUATE

04 IMPROVE

실행 추적 · 비교 평가 · 16주 프로젝트 운영

ARTIFICIAL INTELLIGENCE (AI) · PRODUCT MANAGER (PM)

차성재 · 무신사 Core AI PM × 아주대 AI대학원 겸임교수

# 1주차의 위치

CURRENT / WEEK 01 · 실시간 온라인

## 09.04

### 오리엔테이션과 서비스 개선 사이클

한 번의 모델 호출을 어떻게 재현·  
비교·개선 가능한 서비스 실행으로  
바꾸는가

16-WEEK PORTFOLIO RAIL

W01-03

문제·기준

W04-05

데이터·근거

W06-08

기술·기획

W09-10

서비스·관찰

W11-14

평가·운영

W15-16

통합·발표

WEEK 01 / COMPLETION EVIDENCE

01 프로젝트 문제 후보 1개

02 기준선·변형 실행 추적 2건

03 단일 변수 비교와 다음 개선 가설

04 교수 설계 리뷰 질문 1-3개

매주 같은 위치의 로드맵에서 해당 주차만 파란으로 갱신

# | 16주 수업 일정

전 주차 온라인 운영 · 기본 실시간 강의 · W04·W06 녹화 영상 · W08 온라인 제출

W01-08 / DESIGN


|     |       |               |          |
|-----|-------|---------------|----------|
| W01 | 09.04 | 오리엔테이션·개선 사이클 | 현재 · 실시간 |
| W02 | 09.11 | 프롬프트 기준·버전    | 실시간 온라인  |
| W03 | 09.18 | 프롬프트 평가·오류    | 실시간 온라인  |
| W04 | 09.25 | 검색 근거 기준      | 녹화 · 추석  |
| W05 | 10.02 | 검색 품질·파이프라인   | 실시간 온라인  |
| W06 | 10.09 | 미세조정·데이터      | 녹화 · 한글날 |
| W07 | 10.16 | 선호 최적화·대안     | 실시간 온라인  |
| W08 | 10.23 | 기말 프로젝트 기획서   | 온라인 제출   |

W09-16 / OPERATE

|     |       |              |         |
|-----|-------|--------------|---------|
| W09 | 10.30 | 요청·응답 서비스 명세 | 실시간 온라인 |
| W10 | 11.06 | 관찰 가능한 배포    | 실시간 온라인 |
| W11 | 11.13 | 오프라인 평가      | 실시간 온라인 |
| W12 | 11.20 | 온라인 관찰·실험    | 실시간 온라인 |
| W13 | 11.27 | 안전성·거버넌스     | 실시간 온라인 |
| W14 | 12.04 | 비용·지연·용량     | 실시간 온라인 |
| W15 | 12.11 | 통합 검증·리허설    | 실시간 온라인 |
| W16 | 12.18 | 기말 프로젝트 발표   | 실시간 발표  |

W08 · 실시간 수업 없이 온라인 기획서 제출 평가 / W16 · 실시간 온라인 프로젝트 발표

# | 16주 포트폴리오 로드맵



문제 정의 · 실행 증거 · 평가 기준 · 운영 판단 · 버전 개선의 누적

# | 기획서 제출 패키지

화면 검토와 인쇄 제출을 함께 지원하는 세 가지 HTML 기준 문서

01

## 16주 과정 로드맵

현재 주차·학습 질문  
주차별 일정·누적 산출물  
온라인 영상 대체 일정

`curriculum/2026-2/web/  
course-roadmap.html`

02

## 2페이지 제안서

문제와 사용자·기준선  
입력·출력 명세  
해법·평가·교수 질문

`curriculum/2026-2/web/  
project-proposal-2pager.html`

03

## 제품 요구사항 문서 (PRD)

기능·비기능 요구사항  
데이터·권한·위험  
수락·승격·중단 기준

`curriculum/2026-2/web/  
project-prd.html`

W08 / ONLINE SUBMISSION

중간고사 없음 · 실시간 수업 없음 · 세 문서와 PPT 요약본의 온라인 제출로 평가

# | 교수 설계 리뷰와 수정 기록

초안 0.1 · 근거 확인 · 학생 결정 · 수정안 0.2

DRAFT 0.1

DESIGN REVIEW

DECISION

REVISION 0.2

현재 기획

교수 질문

학생 판단

문서 수정

가정과 선택지  
확인할 질문 1-3개

빈 근거와 경계  
반례·추가 확인

채택 · 보류 · 반박  
결정 이유

변경 전후와 근거  
남은 위험

질의응답은 시험이 아닌 상시 설계 리뷰 · 최종 선택과 책임은 학생에게 귀속

# | 공휴일 주차의 녹화 강의

W04 / 2026.09.25 · 추석

## 검색 근거 기준

---

실시간 온라인 강의 없음

녹화 강의영상 업로드로 대체

학습관리시스템 공지에 따른 시청·산출물 제출

완료 증거 · 데이터 출처·권한·검색 기준선

W06 / 2026.10.09 · 한글날

## 미세조정과 데이터

---

실시간 온라인 강의 없음

녹화 강의영상 업로드로 대체

학습관리시스템 공지에 따른 시청·산출물 제출

완료 증거 · 모델 적응 판단·데이터 제외 기준

# | AI 제품과 교육의 운영 경험

## 차성재

무신사 Core AI PM × 아주대 AI대학원 겸임교수

Artificial Intelligence (AI) · Product Manager (PM)

금융 · 자동화 머신러닝과 운영

의료 · 컴퓨터 비전과 데이터 운영

교육 · 거대 언어 모델 운영과 AI 컨택센터

커머스 · 에이전트형 AI 제품




문제 정의 · 제품 요구사항 · 평가 · 운영 지표의 연결

PRODUCT · EDUCATION · OPERATION



# | 정형 데이터에서 생성형 AI까지



도메인은 달라도 서비스 운영의 질문은 반복

# | AI 제품 운영의 공통 질문

## 정확도만으로 답할 수 없는 질문

현업에서는 한 번의 좋은 응답보다 같은 조건의 재실행, 실패의 관찰, 정책 통제와 변경 설명이 필요하다.


- |    |        |             |
|----|--------|-------------|
| 01 | 재현성    | 같은 조건의 재실행  |
| 02 | 관찰 가능성 | 실패 위치와 분포   |
| 03 | 통제 가능성 | 권한·정책·대체 경로 |
| 04 | 설명 가능성 | 변경 이유와 의사결정 |

모델 점수 · 서비스 행동 · 운영 증거의 분리

# | 두 라이프사이클의 관리 범위

| 비교 축   | 모델·시스템 수명주기                                                                                               | 수업의 서비스 개선 사이클                                              |
|--------|-----------------------------------------------------------------------------------------------------------|-------------------------------------------------------------|
| 단계 구조  | 1. 학습 (Training)<br>2. 평가 (Evaluation)<br>3. 배포 (Deployment)<br>4. 유지 (Maintenance)<br>5. 종료 (Retirement) | 1. 기획·데이터<br>2. 프롬프트·맥락<br>3. 실행·배포<br>4. 평가·관찰<br>5. 개선·버전 |
| 관리 단위  | 모델 또는 전체 인공지능 시스템<br>생성부터 유지·종료까지의 상태                                                                     | 프롬프트·맥락·코드·설정·정책<br>서비스 행동과 실행 증거                           |
| 수업의 사용 | 모델과 시스템의 전체 생애를<br>설명할 때 활용 가능한 분류                                                                        | 매주 실행을 재현·비교·평가하고<br>다음 버전을 설계하는 공통 좌표                      |

# | 수업 운영 프레임: 서비스 개선 사이클



## COURSE STANDARD

### 16주 산출물을 연결하는 교육용 운영 작표계

업계의 단일 표준을 주장하지 않는다. 이미 학습된 기반 모델을 포함한 서비스를 반복적으로 관찰하고 개선하기 위한 공통 프레임이다.

의사결정 기준    계속 · 교체 · 종료

# | 개선 여부를 판단하는 기준

01

**기준**

성공·금지 조건

02

**맥락**

사용자·업무·데이터

03

**버전**

변경 대상과 이유

04

**평가**

같은 축의 비교

다른 사람이 같은 기준으로 다시 확인할 수 있는 운영 조건

# | 1주차 완료 상태



실행 서비스

상태 확인과 사용자 화면 (User Interface, UI)



실행 추적 두 건

같은 입력의 기준선과 변형



단일 변수

프롬프트 버전 또는 생성 온도



비교 표


출력·상태·응답 지연·토큰



개선 가설

변경·기대 결과·확인 방법

# | 모델 호출과 실행 추적



한 번의 생성 결과 → 팀이 다시 확인할 수 있는 실험 단위

# | 기준 사례: 고객 피드백 도우미

## INPUT

“결제는 빨랐지만 교환 절차를 찾기 어려웠어요. 다음 주문 전에는 개선되면 좋겠어요.”

## OUTPUT FIELDS

- 01 고객 의견 요약
- 02 불편 사항·발생 구간  
후속 조치
- 03 상담 답변 초안

## TRACE METADATA

trace\_id  
prompt\_version  
provider / model  
status / latency  
token\_estimate  
content\_fingerprint



# | 모델 호출과 운영 구성요소

## VISIBLE

프롬프트 → 모델 → 응답

## OPERATING SYSTEM

평가 데이터

버전

평가

시간 초과

대체 경로

안전성

비용

책임자

배포 결정에는 평가 데이터·버전·오류·비용·책임자 정보가 필요

# 01


MODEL PERFORMANCE & SERVICE RELIABILITY

---

## 모델 성능과 서비스 신뢰성의 간극

규칙 기반 AI · 머신러닝 · 딥러닝 · 트랜스포머 · 사전학습

# | AI 기술의 발전과 운영 과제



기술이 발전할수록 관리해야 할 데이터·비용·안전 항목도 증가

# | 규칙 기반 시스템의 장점과 한계

## EXPLICIT RULES

### 명확한 규칙과 높은 통제력

---

동작을 직접 설명하고 통제하기 쉬움

작은 범위와 안정된 규칙에 강점

## EXCEPTION GROWTH

### 예외 처리 복잡도 증가

---

규칙 수와 상호작용이 빠르게 증가

모호한 언어·영상·패턴에 취약

# | 규칙 작성과 머신러닝 학습의 차이

BEFORE

## 사람이 규칙을 작성

---

도메인 규칙 → 코드 → 결과

오류 수정은 규칙의 직접 변경

AFTER

## 데이터에서 패턴 추정

---

데이터 + 목표 → 학습 → 모델

오류를 줄려면 데이터·학습 목표·모델 구조를 조정

# | 딥러닝 확산의 세 가지 기반

01

데이터

다양한 학습 신호와 충분한 규모

02

그래픽 처리 장치

Graphics Processing Unit (GPU) 기반  
병렬 연산

03

학습 알고리즘

역전파·아키텍처·최적화

데이터 · GPU 병렬 연산 · 학습 알고리즘

# | 특징 공학과 표현 학습

## HAND-CRAFTED FEATURE

### 수작업 특징 공학

---

원시 데이터 → 특징 추출 → 모델

도메인 전문가의 특징 설계가 성능을 좌우

## REPRESENTATION LEARNING


### 학습된 표현

---

원시 데이터 → 계층 표현 → 출력

데이터 품질과 학습 목표가 성능을 좌우

# | 순환 신경망(RNN)의 순차 처리 한계



토큰을 순서대로 처리하므로 병렬화가 어렵고 장거리 의존성 학습에 제약



# | 셀프 어텐션 (Self-Attention)의 문맥 계산

입력 토큰

고객

은

교환

절차

불편

현재 해석 위치

불편

01

질의(Query)

현재 위치가  
찾는 관계

02

키(Key)

각 토큰의  
비교 단서

03

값(Value)

선택된 정보의  
전달 내용

현재 토큰이 다른 토큰을 얼마나 참고할지 계산

# | 토큰 간 어텐션 가중치

|    | 고객  | 교환  | 절차  | 불편  | 개선  |
|----|-----|-----|-----|-----|-----|
| 고객 | 0.9 | 0.2 | 0.1 | 0.2 | 0.1 |
| 교환 | 0.2 | 0.9 | 0.6 | 0.2 | 0.2 |
| 절차 | 0.1 | 0.7 | 0.9 | 0.8 | 0.4 |
| 불편 | 0.2 | 0.2 | 0.8 | 0.9 | 0.6 |
| 개선 | 0.1 | 0.3 | 0.5 | 0.7 | 0.9 |

색이 진할수록  
해당 토큰을 더 크게 참고


설명용 예시이며 실제 모델의 어텐션 값이나  
인과 설명이 아님

# | 트랜스포머의 문맥 처리 흐름



Q=Query · K=Key · V=Value · FFN=Feed-Forward Network

# | 다음 토큰 예측 기반 사전학습



디코더 기반(Decoder-only) LLM의 대표 사전학습 방식

# | LLM의 대표 활용 과업

01

**생성**

초안·아이디어

02

**요약**

압축·핵심

03

**변환**

문체·형식

04

**분류**

레이블·경로

05

**코드**

생성·해석

여러 과업을 처리할 수 있어도 업무별 입력 형식과 평가 기준은 별도 관리

# | 모델 성능과 서비스 운영 요구사항

모델 성능 · MODEL PERFORMANCE

## 모델이 처리할 수 있는 과업

---

요약 · 번역 · 질의응답 · 코드 · 멀티모달

평가 데이터에서 확인한 과업 성능

서비스 운영 · SERVICE OPERATIONS

## 서비스가 지켜야 할 기준

---

사실성 · 최신성 · 권한 · 지연 · 비용 · 안전

운영 환경의 품질·보안·비용 기준

# | 같은 코드에서도 결과가 달라지는 이유

같은 코드라도 모델·프롬프트·검색 결과·생성 설정이 바뀌면 다른 결과

모델

외부 맥락

생성 설정

프롬프트

provider · tag · revision

retrieval · tool result

temperature · seed

template · example

제공자·모델 태그·개정

검색 결과·도구 반환값

온도·난수 시드

템플릿·예시·정책

모델·프롬프트·맥락·생성 설정을 한 실행 추적에 함께 기록

# | 제품·운영팀이 정할 서비스 기준

모델 성능  $\neq$  서비스 신뢰성

사용자

지원할 사용자와 업무

맥락

사용 상황과 참조 데이터

성공

품질·지연·비용 목표

경계

금지 행동·승인·책임

제품·운영팀이 성공 기준과 운영 경계를 정의



# 02

SERVICE INTERVENTION OPTIONS

## LLM 서비스 동작을 바꾸는 방법

프롬프트 · 검색 · 도구 · 모델 선택 · 사후학습

# | 변경 수단별 비용과 롤백 난이도

비용·시간

파랑 = 이번 가설을 가장 싸고 빠르게 검증할 첫 변경점



# | 프롬프트의 통제 범위

역할

응답 관점과 책임

지시

해야 할 일과 금지 행동

예시


입력·출력 패턴

출력 스키마

형식·필드·길이

모델 가중치를 바꾸지 않고 빠르게 수정·버전 관리·롤백 가능한 제어 지점

# | 검색 증강 생성의 외부 근거



검색 증강 생성 (Retrieval-Augmented Generation, RAG) 의 근거·최신성·권한 기준

# | 모델의 도구 요청과 실제 실행의 분리

모델 · MODEL

## 도구 호출 요청 생성

---

도구 이름과 인수를 생성

확률적 판단 · 외부 변경 없음

실행 환경 · RUNTIME

## 검증 후 실제 실행

---

스키마 검증 · 승인 · 실제 응용 프로그래밍 인터페이스  
호출

시간 초과 · 감사 · 먹등성

# | 모델 라우팅의 선택 축

| 요청 유형  | 우선 축    | 모델 선택 기준                |
|--------|---------|-------------------------|
| 짧은 분류  | 지연 · 비용 | 작은 모델 · 짧은 제한시간 · 일괄 처리 |
| 근거형 답변 | 품질 · 안전 | 검색 증강 생성 · 인용 · 보호 정책   |
| 복잡한 추론 | 품질 · 토큰 | 긴 맥락 · 상위 모델 · 예산       |
| 민감 데이터 | 권한 · 위치 | 로컬·사설망 · 로그 정책 · 마스킹    |

# | 지도 미세조정 (SFT)의 학습 흐름



지도 미세조정 (Supervised Fine-Tuning, SFT) · 반복 행동을 좋은 예시로 적응

# | SFT 학습 데이터의 필수 구성

01

지시

고객 피드백에서  
핵심 신호·마찰·다음 행동 추출

02

입력

실제 분포를 닮은 합성·검수 입력  
민감 원문 제외

03

기대 출력

고정 스키마  
근거 있는 값

잘못된 예시는 잘못된 행동을 더 일관되게 재현



# | 선호 데이터의 구조

선호 응답 · CHOSEN

## 짧고 근거 있는 응답

---

요청한 스키마 준수

입력에 없는 사실 없음

실행 가능한 다음 행동

비선호 응답 · REJECTED

## 그렇듯하지만 불리한 응답


---

형식 누락

새 사실 추가

과도한 상황함


# | 인간 피드백 기반 강화학습의 대표 경로



Reinforcement Learning from Human Feedback (RLHF) · Proximal Policy Optimization (PPO)

# | RLHF와 DPO의 학습 경로 비교

PPO 기반 RLHF



Reinforcement Learning from Human Feedback · Proximal Policy Optimization

직접 선호 최적화(DPO)




Direct Preference Optimization (DPO) · 참조 정책과 선호 쌍의 직접 최적화

# | LoRA 어댑터의 학습 범위



+



작은 변경 단위 · 독립 저장 · 교체 가능한 실험

Low-Rank Adaptation (LoRA) · Parameter-Efficient Fine-Tuning (PEFT)

# | 변경 수단 선택 순서

가장 낮은 비용의 검증에서 시작해 근거가 쌓일 때 다음 변경으로 이동

|    |       |                          |
|----|-------|--------------------------|
| 01 | 기준선   | 현재 품질·비용·응답 지연·실패 분포의 기록 |
| 02 | 프롬프트  | 모델 가중치 밖의 지시·예시·출력 형식 변경 |
| 03 | 검색·도구 | 외부 사실 근거와 실제 행동의 연결      |
| 04 | 모델 선택 | 능력·비용·지연·배포 제약의 교체 검증    |
| 05 | 미세조정  | 반복 행동 패턴을 가중치에 반영할 근거 확인 |

데이터·평가셋·배포 이득이 없으면 미세조정보다 앞 단계의 개선

# 03

OPERATING ASSETS

---

## LLM 서비스 운영에서 관리할 항목

코드 · 데이터 · 모델 · 프롬프트 · 맥락 · 실행 추적 · 평가

# | DevOps·MLOps·LLMOps 관리 대상 비교

## DevOps

CODE · BUILD · RELEASE · RUNTIME

---

Development and Operations · 코드의 빌드·테스트·배포·관찰

## MLOps

DATA · FEATURE · MODEL · EXPERIMENT

---

Machine Learning Operations · 데이터·학습·모델의 버전과 품질 관문

## LLMOps

PROMPT · CONTEXT · TRACE · EVALUATION

---

Large Language Model Operations · 맥락·응답·피드백·보호 정책

대체 관계가 아니라 운영 대상과 증거 구조의 누적

# | LLM 서비스에서 추가로 관리할 정보

EXECUTION KEY

**TRACE ID**

한 번의 실행을  
다시 찾는 식별자

ff2c901e8a16

|    |          |                    |
|----|----------|--------------------|
| 01 | 프롬프트 버전  | 템플릿 · 예시 · 정책      |
| 02 | 외부 맥락 참조 | 검색 문서 · 도구 반환값     |
| 03 | 응답과 운영 값 | 출력 · 상태 · 응답 지연    |
| 04 | 평가와 피드백  | 점수 · 오류 유형 · 검토 결과 |



# | 같은 코드에서도 달라지는 실행 결과

같은 코드 · SAME CODE

## 커밋 a1b2c3

---

동일 접근 경로

동일 요청 스키마

동일 애플리케이션 코드

다른 실행 · DIFFERENT RUN

## 프롬프트 · 맥락 · 모델 · 설정

---

서로 다른 출력

서로 다른 응답 지연·토큰·상태

서로 다른 품질 평가

# | LLM 실행 추적의 필수 필드

추적 식별자 · TRACE ID

**request-specific ID**

---

과업 · 설정

**extract / t=0.2**

---

출력

**execution evidence**

---

프롬프트 버전

**w01.signal.v1**

---

상태 · 응답 지연

**ok / runtime value**

---

토큰

**provider count / estimate**

---

제공자 · 모델

**demo / trace-demo-1**

---

콘텐츠 참조

**sha256:ffdf...fe72**

---

생성 시각

**UTC timestamp**

---

---

Trace ID = 버전 정보와 실행 결과를 연결하는 공통 식별자 · UTC = Coordinated Universal Time

---

# | 서비스 운영의 다섯 평가 기준

|    |       |                                                                         |
|----|-------|-------------------------------------------------------------------------|
| 01 | 품질    | 업무 정답 · 근거 · 형식 · 유용성                                                   |
| 02 | 응답 지연 | 평균 · 50번째 백분위 · 95번째 백분위 · 시간 초과                                        |
| 03 | 비용    | 토큰 · 모델 · 도구 · 캐시                                                       |
| 04 | 안전성   | 개인 식별 정보(Personally Identifiable Information, PII)<br>프롬프트 주입 · 권한 · 감사 |
| 05 | 재현성   | 환경 · 버전 · 실행 추적 · 커밋                                                    |

# | 운영 지표의 상충 관계

한 지표의 개선은 다른 지표의 비용을 함께 확인할 때만 운영 판단으로 완성

| 판단 축       | 변경 레버           | 함께 확인할 손실    |
|------------|-----------------|--------------|
| 품질 ↔ 비용    | 상위 모델 · 긴 맥락    | 요청당 비용 · 처리량 |
| 품질 ↔ 응답 시간 | 검색 · 도구 · 검증 단계 | 대기시간 · 시간 초과 |
| 안전 ↔ 처리 범위 | 차단 강도 · 사람 검토   | 정상 요청 누락     |
| 재사용 ↔ 최신성  | 캐시 적중 · 응답 재사용  | 정보 노후화       |


네 관계는 고정 법칙이 아니라 실험 전에 함께 관찰할 위험 가설

# | 업무별 품질 평가 기준

| 업무       | 우선 품질 축           | 대표 실패              |
|----------|-------------------|--------------------|
| 요약       | 충실성 · 압축률 · 핵심 보존 | 새 사실 추가 · 중요 정보 누락 |
| 정보 추출    | 스키마 준수 · 필드 정확성   | 필드 누락 · 근거 없는 값    |
| 검색 증강 답변 | 근거성 · 인용 정확도      | 근거 미검색 · 잘못된 인용    |
| 에이전트 행동  | 과업 성공 · 정책 준수     | 권한 없는 실행 · 중복 행동   |

# | 평균과 꼬리 지연시간

설명용 분포 · 실제 측정값 아님



# | LLM 요청 비용의 구성

$$\text{요청 비용} = \text{생성} + \text{워크플로} + \text{실패} - \text{재사용}$$

| 생성          | 워크플로         | 실패                 | 재사용            |
|-------------|--------------|--------------------|----------------|
| 입력·맥락·출력 토큰 | 검색·재순위·검증·도구 | 재시도·대체 경로<br>시간 초과 | 캐시·일괄 처리·모델 선택 |

모델 단가만이 아니라 한 요청이 실제로 거치는 전체 경로

# | 입력부터 저장까지의 보안·안전 기준

입력

개인 식별 정보

정책 분류

프롬프트 주입

실행

도구 허용목록

시간 초과

사람 검토

출력

근거 연결

금지 표현

감사 로그

저장

원문 최소화

보존 기간

접근 통제



# | 실행 결과 재현에 필요한 다섯 가지 정보



환경

Python · 패키지 · 운영체제 · 가속기



입력

평가 데이터 개정 · 콘텐츠 지문



지시

프롬프트 식별자 · 버전 · 스키마



실행


제공자 · 모델 · 설정



코드

커밋 · 접근 경로 · 정책

# | LLM 서비스 개선 사이클



## COURSE STANDARD

관찰 결과가 다음 기획과 변경  
가설의 입력

품질·지연·비용·안전·재현성은 한 단계가 아니라 전 단계를 가로지르는 판단 축이다.  
특정 마지막 노드는 없다.

의사결정 기준    계속 · 교체 · 종료

# | 1단계 / 기획·데이터의 성공 기준

## PROJECT BRIEF

### 누구의 어떤 결정을 돕는가?

모델 선택보다 먼저 문제·데이터·평가의 범위를  
프로젝트 브리프로 고정

01

대상 사용자와  
지원할 의사결정

02

대표 입력과  
기대 행동

03

성공·금지 조건과  
평가 데이터

04

데이터 권한·개인정보·  
보존 경계

## | 2단계 / 프롬프트·맥락의 버전 관리

# 02

OPERATING QUESTION

### 무엇이 바뀌었고 왜 바뀌었는가?

01

프롬프트 식별자·버전·책임자

02

입출력 스키마·예시

03

검색·도구 맥락 참조

읽기 좋은 프롬프트보다 고정 평가 데이터에서 비교 가능한 프롬프트

1 기획·데이터

2 프롬프트·컨텍스트

3 실행·배포


4 평가·관찰

5 개선·버전

# | 3단계 / 실행·배포의 실패 경로

실패했을 때 어디로 흐르는가?

정상 경로



실패 경로




운영 문서에는 정상 흐름과 오류·재시도·대체 경로를 함께 기록

# | 4단계 / 오프라인 평가와 운영 모니터링

누가, 언제, 어떻게 실패하는가?

설명용 응답 자연 분포 · 실제 측정값 아님



품질

대표 성공·실패

운영

95번째 백분위 · 오류율

자원·안전

토큰 · 비용 · 위험 신호

평균 점수와 함께 실패 분포·하위 집단·원본 실행 추적 확인

# | 5단계 / 버전 변경 의사결정 기록

다음 버전은 무엇을 검증하는가?

01

이전 기준선

현재 실패와  
고정 조건

02

새 가설과 변경

검증할 가설과  
바꿀 한 가지

03

실행 증거

비교 가능한  
실행 추적

04

평가와 다음 버전

승격·보류·되돌리기와  
다음 질문

‘더 좋아 보임’이 아닌 변경 이유·결과·결정의 연결

# | 버전 변경의 최소 기록

| VERSION | HYPOTHESIS     | CHANGE      | DECISION |
|---------|----------------|-------------|----------|
| v0.1.0  | 교환 절차 누락 감소    | 스키마와 예시 추가  | 기준선      |
| v0.2.0  | 마찰 필드 완전성 향상   | 프롬프트 버전만 변경 | 승격       |
| v0.2.1  | 지연 증가 없는 표현 축약 | 최대 길이 조정    | 보류       |

버전 번호보다 중요한 연결: 가설 → 변경 → 실행 추적 → 의사결정



# | 서비스 개선 단계와 학기 일정

서비스 개선 단계

|        |         |       |       |       |
|--------|---------|-------|-------|-------|
| 01     | 02      | 03    | 04    | 05    |
| 기획·데이터 | 프롬프트·맥락 | 실행·배포 | 평가·관찰 | 개선·버전 |

학기 마일스톤

|                     |                  |                     |                    |
|---------------------|------------------|---------------------|--------------------|
| W01-07              | W08              | W09-15              | W16                |
| 온라인 운영<br>W04·06 녹화 | 온라인 제출<br>제출본 평가 | 실시간 온라인<br>구현·운영 검증 | 실시간 온라인<br>프로젝트 발표 |

W08 온라인 제출본 평가 · W16 실시간 온라인 프로젝트 발표

# 04

TRACE / 01 LAB

## 첫 LLM 서비스 실행과 기록

Python 3.11.14 · Demo 기준선 · Qwen3 4B Instruct · 실행 추적과 비교

# | 오늘 실습의 순서와 완료 기준



개발환경 준비

Python 3.11.14 · .venv 선택



테스트와 서버 실행

자동 테스트 실패 0건 · GET /health 정상



Demo 기준선 2회

같은 입력의 실행 추적 2건



Ollama 선택 실행


qwen3:4b-instruct · Thinking OFF



비교표와 다음 가설

비교 판단 1건 · 변경 가설 1개

# | TRACE/01 실행 구조와 실습 파일



가이드 · week01/VS\_CODE\_GUIDE.md  
노트북 · week01/lab/week01\_trace01\_lab.ipynb

# | Python 3.11 개발환경 준비

TERMINAL / REPOSITORY ROOT

```
uv python install 3.11.14
uv venv --python 3.11.14 \
  --allow-existing .venv
uv pip install --python .venv/bin/python \
  -r requirements.txt
.venv/bin/python -m pytest -q \
  week01/lab/tests
```

## 3.11.14

VS Code

저장소 루트


llmops-16week

Environment: Bootstrap

Python: Select Interpreter

Tasks: Run Test Task

# | TRACE/01 서버의 두 실행 경로



사용자 화면 · <http://127.0.0.1:8000> | 상태 · GET /health | 서버 터미널 유지

# | VS Code 개발환경과 테스트 결과

```

week01 > # VS_CODE_GUIDE.md > # Week 01: VS Code 실행 가이드
1 # Week 01 - VS Code 실행 가이드
2
3 저장소 루트를 Visual Studio Code(VS Code)로 열린 'TRACE/01' 서버, 응용 프로그래밍 인터페이스(API) 테스트, 노트북을 하나의 '.venv'에서 실행할 수 있다. 기존 환경은 **macOS · zsh · uv · CPython 3.11.14**이다.
4
5 ## 1. 최초 환경 준비
6
7 1. VS Code에서 'llmops-16week' 저장소 루트를 연다.
8 2. 추천 확장 프로그램 Python, Pylance, Jupyter, Ruff를 설치한다.
9 3. Command Palette에서 'Tasks: Run Task' -> 'Environment: Bootstrap'을 실행한다.
10 4. 상태 표시줄의 Python 인터프리터가 '.venv/bin/python'인지 확인한다. 아니면 'Python: Select Interpreter'에서 직접 선택한다.
11
12 같은 준비를 터미널에서 수행할 때는 다음 명령을 사용한다.
13
14 ```bash
15 uv python install 3.11.14
16 uv venv --python 3.11.14 --allow-existing .venv
17 uv pip install --python .venv/bin/python -r requirements.txt
18 ```
19
20 ## 2. 서비스 실행과 확인
21
22 실행 횟수를 0부터 직접 기록하려면 'Tasks: Run Task' -> 'Week 01: Run TRACE/01'을 선택한다. 서버와 자동 요청을 한 번에 확인하려면 'Week 01: Start and smoke'를 사용한다. 후자는 합성 고객 피드백을 'demo' 제공자에 한 번 보내므로 사용자 확인의 전체 실행이 1부터 시작한다.
23
24 - 서비스 확인: <http://127.0.0.1:8080>
25 - OpenAPI 문서: <http://127.0.0.1:8080/docs>
26 - 실행 trace: <http://127.0.0.1:8080/api/v1/traces>
27 - 실행 설정: <http://127.0.0.1:8080/api/v1/config>
28 - 수집물 통계: <http://127.0.0.1:8080/api/v1/stats>
29 - 운영 지표: <http://127.0.0.1:8080/metrics>
30
31 서버 종료는 Command Palette의 'Tasks: Terminate Task' -> 'Week 01: Run TRACE/01'을 선택한다.
32
33 ## 3. 테스트와 디버깅
34
35 - 전체 응용 프로그래밍 인터페이스 테스트: 'Testing' 패널 또는 'Tasks: Run Test Task' 실행
36 - 코드 품질 검사: 'Tasks: Run Task' -> 'Course: Ruff check'
37 - 서버 중단점 디버깅: 'Run and Debug' -> 'Week 01: Debug TRACE/01'
38
39
40 Problems Output Debug Console Terminal Ports Jupyter
41
42 (.venv) sungjae-cha@chaseongjaeui-MacBookPro-2 llmops-16week % ./venv/bin
43 /python -V 66 ./venv/bin/python -m pytest -q ./week01/lab/tests
44 Python 3.11.14
45 ..... [100%]
46 8 passed in 0.28s
47 o (.venv) sungjae-cha@chaseongjaeui-MacBookPro-2 llmops-16week %
  
```

실제 검증

실행 위치

llmops-16week

인터프리터

Python 3.11.14

자동 테스트

8 passed · 0 failed

# | API 요청과 운영 확인 주소

## TRACE/01 1.0.0 OAS 3.1

/openapi.json

Week 01: one request, one trace, one improvement loop.

### default ^

|      |                  |                |   |
|------|------------------|----------------|---|
| GET  | /health          | Health         | ▼ |
| GET  | /api/v1/config   | Runtime Config | ▼ |
| POST | /api/v1/generate | Generate       | ▼ |
| GET  | /api/v1/traces   | Traces         | ▼ |
| GET  | /api/v1/stats    | Stats          | ▼ |
| GET  | /metrics         | Metrics        | ▼ |

### Schemas ^

GenerateRequest ▾ Expand all **object**

기준 경로

서비스 상태

GET /health

현재 설정

GET /api/v1/config

생성 요청

POST /api/v1/generate



# | 실행 기록과 운영 지표의 정확한 경로

01

`/api/v1/config`

모델 · Thinking 요청값  
컨텍스트 · 출력 상한

02

`/api/v1/traces`

최근 실행 추적과  
요청별 메타데이터

03

`/api/v1/stats`

성공률 · 평균·95백분위  
응답 지연 · 추정 토큰

04

`/metrics`  
`/docs`

Prometheus 지표  
OpenAPI 데이터 구조

축약 경로가 아닌 서버에 구현된 전체 경로 사용

# | Demo 기준선 실행 화면

배송은 빨랐지만 추천 결과가 매번 달라서 비교하기 어려웠습니다. 어떤 프롬프트와 모델을 썼는지 기록되면 팀이 더 빠르게 개선할 수 있을 것 같아요.

작업
실행
온도
0.2

신호 추출
Demo · 오프라인 규칙 엔진

수업용 Ollama 설정
qwen3:4b-instruct
Thinking OFF · 출력 상한 128 · 컨텍스트 2048 · 유지 30m

추적 실행 · Run trace

원문은 저장하지 않습니다. 12자리 콘텐츠 지문(content fingerprint)과 실행 메타데이터만 기록합니다.

SIGNAL — 배송은 빨랐다는 관찰  
 FRICTION — 추천 결과가 매번 달라서 비교하기 어려웠습니다.  
 NEXT ACTION — 같은 입력 세트로 다음 버전을 비교하고 지표를 기록한다.

|                           |                              |                    |
|---------------------------|------------------------------|--------------------|
| 추적 식별자 · Trace ID         | 프롬프트 버전 · Prompt version     | 모델 · Model         |
| 33fab1e5a681              | w01.signal.v1                | trace-demo-1       |
| Thinking 요청값              | 응답 지연 · Latency              | 모델 적재 · Load       |
| OFF                       | 0.15 ms                      | —                  |
| 추정 토큰 · Estimated tokens* | 출력 상한 · Output limit         | 모델 생성 · Generation |
| 63                        | —                            | —                  |
| 종료 사유 · Finish reason     | 콘텐츠 지문 · Content fingerprint |                    |
| —                         | ffdf1925fe72                 |                    |

기준선 실행

제공자

Demo

응답 지연

현재 실행값

완료 증거

Trace ID · 지문

# | Qwen3 4B 응답 시간 설정

qwen3:4b-instruct

**MODEL**

Thinking 전용이 아닌 지시 수행 모델

Thinking 요청값

**false**

별도 추론 출력을 요청하지 않는 API 설정

입력·출력 한도

**2048 · 128**

짧은 수업 입력의 컨텍스트와 최대 생성 토큰

메모리·재현

**30m · seed 42**

반복 호출의 재적재 감소와 비교 조건 고정

--hidethinking은 표시만 숨기는 옵션 · 속도 설정은 비추론 모델과 think:false의 조합

# | Qwen3 Instruct 실행 결과

배송은 빨랐지만 추천 결과가 매번 달라서 비교하기 어려웠습니다. 어떤 프롬프트와 모델을 썼는지 기록되면 팀이 더 빠르게 개선할 수 있을 것 같아요.

SIGNAL: 추천 결과가 매번 달라서 비교하기 어려웠습니다.  
 FRICTION: 어떤 프롬프트와 모델을 썼는지 기록되지 않음.  
 NEXT ACTION: 프롬프트와 모델 사용 기록을 체계적으로 기록할 것.

작업 실행 온도

신호 추출 ▼ Ollama · 로컬 언어 모델 ▼ 0.2

수업용 Ollama 설정 **qwen3:4b-instruct**  
 Thinking OFF · 출력 상한 128 · 컨텍스트 2048 · 유지 30m

추적 실행 · Run trace

원문은 저장하지 않습니다. 12자리 콘텐츠 지문(content fingerprint)과 실행 메타데이터만 기록합니다.

| 추적 식별자 · Trace ID         | 프롬프트 버전 · Prompt version     | 모델 · Model            |
|---------------------------|------------------------------|-----------------------|
| 18cb16bc00ab              | w01.signal.v1                | qwen3:4b-instruct     |
| Thinking 요청값              | 응답 지연 · Latency              | 모델 적재 · Load          |
| OFF                       | 1950.65 ms                   | 12.80 ms              |
| 추정 토큰 · Estimated tokens* | 출력 상한 · Output limit         | 모델 생성 · Generation    |
| 67                        | 128                          | 922.89 ms · 70 tokens |
| 종료 사유 · Finish reason     | 콘텐츠 지문 · Content fingerprint |                       |
| stop                      | ffdf1925fe72                 |                       |

실행 예시 · 환경별 차이

모델

qwen3:4b-instruct

Thinking

OFF

종료 사유

stop

# | Demo와 Ollama 실행 경로 비교

| RUN A / BASELINE |                     | Δ | RUN B / VARIANT            |
|------------------|---------------------|---|----------------------------|
| 입력               | 동일 합성 고객 피드백        | = | 동일 합성 고객 피드백               |
| 작업·온도            | extract · 0.2       | = | extract · 0.2              |
| 제공자·모델           | demo · trace-demo-1 | ≠ | ollama · qwen3:4b-instruct |
| 확인               | 형식 · 근거 · 상태 · 지연   | ↔ | 형식 · 근거 · 적재 · 생성          |

운영 경로 비교이며 모델 성능의 우열 결론은 아님

# | 실습 노트북 실행 순서

| 순서 | 노트북 단계                   | 완료 증거                                    |
|----|--------------------------|------------------------------------------|
| 01 | Python 버전과 서버 주소         | .venv/bin/python · http://127.0.0.1:8000 |
| 02 | 상태와 현재 설정                | /health 정상 · /api/v1/config 설정 확인        |
| 03 | Demo 기준선 2회              | 같은 입력 · 같은 프롬프트 · 추적 식별자 2건              |
| 04 | 실행 추적 비교표                | 모델 · 온도 · Thinking · 지연 · 콘텐츠 지문         |
| 05 | traces · stats · metrics | 개별 실행 · 집계 · 수집 지표의 차이                   |
| 06 | 선택형 Ollama 실행            | qwen3:4b-instruct · 종료 사유 · 다음 변경        |

# | Ollama 오류와 지연 점검

**503 /  
MODEL**

모델 태그 불일치

→

ollama list → qwen3:4b-instruct 설치 → .env 재실행

**503 /  
SERVER**

Ollama 연결 실패

→

/api/version 확인 → 앱 또는 ollama serve 하나만 실행

**SLOW**

응답 시간 과다

→

/api/v1/config · ollama ps → 두 번째 호출과 비교

**LENGTH**

출력 상한 도달

→

finish\_reason=length → 192 또는 256으로 상향

**422**

요청 데이터 구조 오류

→

/docs → task · provider · temperature 범위 확인

# 첫 실습 운영 기록

01      환경      Python · Ollama 버전 · 모델 태그 · Thinking 요청값

---

02      실행 증거      Demo 추적 2건 · Ollama 선택 추적 1건 · 비교 판단

---

03      다음 변경      바꿀 변수 1개 · 기대 결과 · 확인 방법 · 교수 질문

---