

LLM 서비스 운영의 기본

LARGE LANGUAGE MODEL (LLM)

01 TRACE

02 COMPARE

03 EVALUATE

04 IMPROVE

실행 추적 · 비교 평가 · 16주 프로젝트 운영

ARTIFICIAL INTELLIGENCE (AI) · PRODUCT MANAGER (PM)

차성재 · 무신사 Core AI PM × AI 대학원 겸임교수

1주차의 위치

CURRENT / WEEK 01 · 실시간 온라인

09.04

오리엔테이션과 서비스 개선 사이클

한 번의 모델 호출을 어떻게 재현·
비교·개선 가능한 서비스 실행으로
바꾸는가

16-WEEK PORTFOLIO RAIL

W01-03

문제·기준

W04-05

데이터·근거

W06-08

기술·기획

W09-10

서비스·관찰

W11-14

평가·운영

W15-16

통합·발표

WEEK 01 / COMPLETION EVIDENCE

01 프로젝트 문제 후보 1개

02 기준선·변형 실행 추적 2건

03 단일 변수 비교와 다음 개선 가설

04 교수 설계 리뷰 질문 1-3개

매주 같은 위치의 로드맵에서 해당 주차만 파랑으로 갱신

| 16주 수업 일정

전 주차 온라인 운영 · 기본 실시간 강의 · W04·W06 녹화 영상 · W08 온라인 제출

W01-08 / DESIGN


W01	09.04	오리엔테이션·개선 사이클	현재 · 실시간
W02	09.11	프롬프트 기준·버전	실시간 온라인
W03	09.18	프롬프트 평가·오류	실시간 온라인
W04	09.25	검색 근거 기준	녹화 · 추석
W05	10.02	검색 품질·파이프라인	실시간 온라인
W06	10.09	미세조정·데이터	녹화 · 한글날
W07	10.16	선호 최적화·대안	실시간 온라인
W08	10.23	기말 프로젝트 기획서	온라인 제출

W09-16 / OPERATE

W09	10.30	요청·응답 서비스 명세	실시간 온라인
W10	11.06	관찰 가능한 배포	실시간 온라인
W11	11.13	오프라인 평가	실시간 온라인
W12	11.20	온라인 관찰·실험	실시간 온라인
W13	11.27	안전성·거버넌스	실시간 온라인
W14	12.04	비용·지연·용량	실시간 온라인
W15	12.11	통합 검증·리허설	실시간 온라인
W16	12.18	기말 프로젝트 발표	실시간 발표

W08 · 실시간 수업 없이 온라인 기획서 제출 평가 / W16 · 실시간 온라인 프로젝트 발표

| 16주 포트폴리오 로드맵



문제 정의 · 실행 증거 · 평가 기준 · 운영 판단 · 버전 개선의 누적

| 기획서 제출 패키지

화면 검토와 인쇄 제출을 함께 지원하는 세 가지 HTML 기준 문서

01

16주 과정 로드맵

현재 주차·학습 질문
주차별 일정·누적 산출물
온라인 영상 대체 일정

`curriculum/2026-2/web/
course-roadmap.html`

02

2페이지 제안서

문제와 사용자·기준선
입력·출력 명세
해법·평가·교수 질문

`curriculum/2026-2/web/
project-proposal-2pager.html`

03

제품 요구사항 문서 (PRD)

기능·비기능 요구사항
데이터·권한·위험
수락·승격·중단 기준

`curriculum/2026-2/web/
project-prd.html`

W08 / ONLINE SUBMISSION

중간고사 없음 · 실시간 수업 없음 · 세 문서와 PPT 요약본의 온라인 제출로 평가

| 교수 설계 리뷰와 수정 기록

초안 0.1 · 근거 확인 · 학생 결정 · 수정안 0.2

DRAFT 0.1

DESIGN REVIEW

DECISION

REVISION 0.2

현재 기획

교수 질문

학생 판단

문서 수정

가정과 선택지
확인할 질문 1-3개

빈 근거와 경계
반례·추가 확인

채택 · 보류 · 반박
결정 이유

변경 전후와 근거
남은 위험

질의응답은 시험이 아닌 상시 설계 리뷰 · 최종 선택과 책임은 학생에게 귀속

| 공휴일 주차의 녹화 강의

W04 / 2026.09.25 · 추석

검색 근거 기준

실시간 온라인 강의 없음

녹화 강의영상 업로드로 대체

학습관리시스템 공지에 따른 시청·산출물 제출

완료 증거 · 데이터 출처·권한·검색 기준선

W06 / 2026.10.09 · 한글날

미세조정과 데이터

실시간 온라인 강의 없음

녹화 강의영상 업로드로 대체

학습관리시스템 공지에 따른 시청·산출물 제출

완료 증거 · 모델 적응 판단·데이터 제외 기준

| AI 제품과 교육의 운영 경험

차성재

무신사 Core AI PM × AI 대학원 겸임교수

Artificial Intelligence (AI) · Product Manager (PM)

금융 · 자동화 머신러닝과 운영

의료 · 컴퓨터 비전과 데이터 운영

교육 · 거대 언어 모델 운영과 AI 컨택센터


커머스 · 에이전트형 AI 제품



문제 정의 · 제품 요구사항 · 평가 · 운영 지표의 연결

PRODUCT · EDUCATION · OPERATION

| 정형 데이터에서 생성형 AI까지



도메인은 달라도 서비스 운영의 질문은 반복

| AI 제품 운영의 공통 질문

정확도만으로 답할 수 없는 질문

현업에서는 한 번의 좋은 응답보다 같은 조건의 재실행, 실패의 관찰, 정책 통제와 변경 설명이 필요하다.


- | | | |
|----|--------|-------------|
| 01 | 재현성 | 같은 조건의 재실행 |
| 02 | 관찰 가능성 | 실패 위치와 분포 |
| 03 | 통제 가능성 | 권한·정책·대체 경로 |
| 04 | 설명 가능성 | 변경 이유와 의사결정 |

모델 점수 · 서비스 행동 · 운영 증거의 분리

| 두 라이프사이클의 관리 범위

비교 축	모델·시스템 수명주기	수업의 서비스 개선 사이클
단계 구조	1. 학습 (Training) 2. 평가 (Evaluation) 3. 배포 (Deployment) 4. 유지 (Maintenance) 5. 종료 (Retirement)	1. 기획·데이터 2. 프롬프트·맥락 3. 실행·배포 4. 평가·관찰 5. 개선·버전
관리 단위	모델 또는 전체 인공지능 시스템 생성부터 유지·종료까지의 상태	프롬프트·맥락·코드·설정·정책 서비스 행동과 실행 증거
수업의 사용	모델과 시스템의 전체 생애를 설명할 때 활용 가능한 분류	매주 실행을 재현·비교·평가하고 다음 버전을 설계하는 공통 좌표

| 수업 운영 프레임: 서비스 개선 사이클



COURSE STANDARD

16주 산출물을 연결하는 교육용 운영 작표계

업계의 단일 표준을 주장하지 않는다. 이미 학습된 기반 모델을 포함한 서비스를 반복적으로 관찰하고 개선하기 위한 공통 프레임이다.

의사결정 기준 계속 · 교체 · 종료

| 개선 여부를 판단하는 기준

01

기준

성공·금지 조건

02

맥락

사용자·업무·데이터

03

버전

변경 대상과 이유

04

평가

같은 축의 비교

다른 사람이 같은 기준으로 다시 확인할 수 있는 운영 조건

| 1주차 완료 상태



실행 서비스

상태 확인과 사용자 화면 (User Interface, UI)



실행 추적 두 건

같은 입력의 기준선과 변형



단일 변수

프롬프트 버전 또는 생성 온도



비교 표


출력·상태·응답 지연·토큰



개선 가설

변경·기대 결과·확인 방법

| 모델 호출과 실행 추적



한 번의 생성 결과 → 팀이 다시 확인할 수 있는 실험 단위

| 기준 사례: 고객 피드백 도우미

INPUT

“결제는 빨랐지만 교환 절차를 찾기 어려웠어요. 다음 주문 전에는 개선되면 좋겠어요.”

OUTPUT FIELDS

- 01 고객 의견 요약
- 02 불편 사항·발생 구간
후속 조치
- 03 상담 답변 초안

TRACE METADATA

trace_id
prompt_version
provider / model
status / latency
token_estimate
content_fingerprint

| 모델 호출과 운영 구성요소

VISIBLE

프롬프트 → 모델 → 응답

OPERATING SYSTEM

평가 데이터

버전

평가

시간 초과

대체 경로

안전성

비용

책임자

배포 결정에는 평가 데이터·버전·오류·비용·책임자 정보가 필요


01

MODEL PERFORMANCE & SERVICE RELIABILITY

모델 성능과 서비스 신뢰성의 간극

규칙 기반 AI · 머신러닝 · 딥러닝 · 트랜스포머 · 사전학습

| AI 기술의 발전과 운영 과제



기술이 발전할수록 관리해야 할 데이터·비용·안전 항목도 증가

| 규칙 기반 시스템의 장점과 한계

EXPLICIT RULES

명확한 규칙과 높은 통제력

동작을 직접 설명하고 통제하기 쉬움

작은 범위와 안정된 규칙에 강점

EXCEPTION GROWTH

예외 처리 복잡도 증가

규칙 수와 상호작용이 빠르게 증가

모호한 언어·영상·패턴에 취약

| 규칙 작성과 머신러닝 학습의 차이

BEFORE

사람이 규칙을 작성

도메인 규칙 → 코드 → 결과

오류 수정은 규칙의 직접 변경

AFTER

데이터에서 패턴 추정

데이터 + 목표 → 학습 → 모델

오류를 줄려면 데이터·학습 목표·모델 구조를 조정

| 딥러닝 확산의 세 가지 기반

01

데이터

다양한 학습 신호와 충분한 규모

02

그래픽 처리 장치

Graphics Processing Unit (GPU) 기반
병렬 연산

03

학습 알고리즘

역전파·아키텍처·최적화

데이터 · GPU 병렬 연산 · 학습 알고리즘

| 특징 공학과 표현 학습

HAND-CRAFTED FEATURE

수작업 특징 공학

원시 데이터 → 특징 추출 → 모델

도메인 전문가의 특징 설계가 성능을 좌우


REPRESENTATION LEARNING

학습된 표현

원시 데이터 → 계층 표현 → 출력

데이터 품질과 학습 목표가 성능을 좌우

| 순환 신경망(RNN)의 순차 처리 한계



토큰을 순서대로 처리하므로 병렬화가 어렵고 장거리 의존성 학습에 제약

| 셀프 어텐션 (Self-Attention)의 문맥 계산

입력 토큰

고객

은

교환

절차

불편

현재 해석 위치

불편

01

질의(Query)

현재 위치가
찾는 관계

02

키(Key)

각 토큰의
비교 단서

03

값(Value)

선택된 정보의
전달 내용

현재 토큰이 다른 토큰을 얼마나 참고할지 계산

| 토큰 간 어텐션 가중치

	고객	교환	절차	불편	개선
고객	0.9	0.2	0.1	0.2	0.1
교환	0.2	0.9	0.6	0.2	0.2
절차	0.1	0.7	0.9	0.8	0.4
불편	0.2	0.2	0.8	0.9	0.6
개선	0.1	0.3	0.5	0.7	0.9

색이 진할수록
해당 토큰을 더 크게 참고


설명용 예시이며 실제 모델의 어텐션 값이나
인과 설명이 아님

| 트랜스포머의 문맥 처리 흐름



Q=Query · K=Key · V=Value · FFN=Feed-Forward Network

| 다음 토큰 예측 기반 사전학습



디코더 기반(Decoder-only) LLM의 대표 사전학습 방식

| LLM의 대표 활용 과업

01

생성

초안·아이디어

02

요약

압축·핵심

03

변환

문체·형식

04

분류

레이블·경로

05

코드

생성·해석

여러 과업을 처리할 수 있어도 업무별 입력 형식과 평가 기준은 별도 관리

| 모델 성능과 서비스 운영 요구사항

모델 성능 · MODEL PERFORMANCE

모델이 처리할 수 있는 과업

요약 · 번역 · 질의응답 · 코드 · 멀티모달

평가 데이터에서 확인한 과업 성능

서비스 운영 · SERVICE OPERATIONS

서비스가 지켜야 할 기준

사실성 · 최신성 · 권한 · 지연 · 비용 · 안전

운영 환경의 품질·보안·비용 기준

| 같은 코드에서도 결과가 달라지는 이유

같은 코드라도 모델·프롬프트·검색 결과·생성 설정이 바뀌면 다른 결과

모델

외부 맥락

생성 설정

프롬프트

provider · tag · revision

retrieval · tool result

temperature · seed

template · example

제공자·모델 태그·개정

검색 결과·도구 반환값

온도·난수 시드

템플릿·예시·정책

모델·프롬프트·맥락·생성 설정을 한 실행 추적에 함께 기록

| 제품·운영팀이 정할 서비스 기준

모델 성능 $\neq$ 서비스 신뢰성

사용자

지원할 사용자와 업무

맥락

사용 상황과 참조 데이터

성공

품질·지연·비용 목표

경계

금지 행동·승인·책임

제품·운영팀이 성공 기준과 운영 경계를 정의

02

SERVICE INTERVENTION OPTIONS

LLM 서비스 동작을 바꾸는 방법

프롬프트 · 검색 · 도구 · 모델 선택 · 사후학습

| 변경 수단별 비용과 롤백 난이도

비용·시간

파랑 = 이번 가설을 가장 싸고 빠르게 검증할 첫 변경점



| 프롬프트의 통제 범위

역할

응답 관점과 책임

지시

해야 할 일과 금지 행동

예시


입력·출력 패턴

출력 스키마

형식·필드·길이

모델 가중치를 바꾸지 않고 빠르게 수정·버전 관리·롤백 가능한 제어 지점

| 검색 증강 생성의 외부 근거



검색 증강 생성 (Retrieval-Augmented Generation, RAG) 의 근거·최신성·권한 기준

| 모델의 도구 요청과 실제 실행의 분리

모델 · MODEL

도구 호출 요청 생성

도구 이름과 인수를 생성

확률적 판단 · 외부 변경 없음

실행 환경 · RUNTIME

검증 후 실제 실행

스키마 검증 · 승인 · 실제 응용 프로그래밍 인터페이스
호출

시간 초과 · 감사 · 먹등성

| 모델 라우팅의 선택 축

요청 유형	우선 축	모델 선택 기준
짧은 분류	지연 · 비용	작은 모델 · 짧은 제한시간 · 일괄 처리
근거형 답변	품질 · 안전	검색 증강 생성 · 인용 · 보호 정책
복잡한 추론	품질 · 토큰	긴 맥락 · 상위 모델 · 예산
민감 데이터	권한 · 위치	로컬·사설망 · 로그 정책 · 마스킹

| 지도 미세조정 (SFT)의 학습 흐름



지도 미세조정 (Supervised Fine-Tuning, SFT) · 반복 행동을 좋은 예시로 적응

| SFT 학습 데이터의 필수 구성

01

지시

고객 피드백에서
핵심 신호·마찰·다음 행동 추출

02

입력

실제 분포를 담은 합성·검수 입력
민감 원문 제외

03

기대 출력

고정 스키마
근거 있는 값

잘못된 예시는 잘못된 행동을 더 일관되게 재현

| 선호 데이터의 구조

선호 응답 · CHOSEN

짧고 근거 있는 응답

요청한 스키마 준수

입력에 없는 사실 없음

실행 가능한 다음 행동

비선호 응답 · REJECTED


그렇듯하지만 불리한 응답

형식 누락

새 사실 추가

과도한 상황함


| 인간 피드백 기반 강화학습의 대표 경로



Reinforcement Learning from Human Feedback (RLHF) · Proximal Policy Optimization (PPO)

| RLHF와 DPO의 학습 경로 비교

PPO 기반 RLHF



Reinforcement Learning from Human Feedback · Proximal Policy Optimization

직접 선호 최적화(DPO)




Direct Preference Optimization (DPO) · 참조 정책과 선호 쌍의 직접 최적화

| LoRA 어댑터의 학습 범위



+



작은 변경 단위 · 독립 저장 · 교체 가능한 실험

Low-Rank Adaptation (LoRA) · Parameter-Efficient Fine-Tuning (PEFT)

| 변경 수단 선택 순서

가장 낮은 비용의 검증에서 시작해 근거가 쌓일 때 다음 변경으로 이동

01	기준선	현재 품질·비용·응답 지연·실패 분포의 기록
02	프롬프트	모델 가중치 밖의 지시·예시·출력 형식 변경
03	검색·도구	외부 사실 근거와 실제 행동의 연결
04	모델 선택	능력·비용·지연·배포 제약의 교체 검증
05	미세조정	반복 행동 패턴을 가중치에 반영할 근거 확인

데이터·평가셋·배포 이득이 없으면 미세조정보다 앞 단계의 개선

03

OPERATING ASSETS

LLM 서비스 운영에서 관리할 항목

코드 · 데이터 · 모델 · 프롬프트 · 맥락 · 실행 추적 · 평가

| DevOps·MLOps·LLMOps 관리 대상 비교

DevOps

CODE · BUILD · RELEASE · RUNTIME

Development and Operations · 코드의 빌드·테스트·배포·관찰

MLOps

DATA · FEATURE · MODEL · EXPERIMENT

Machine Learning Operations · 데이터·학습·모델의 버전과 품질 관문

LLMOps

PROMPT · CONTEXT · TRACE · EVALUATION

Large Language Model Operations · 맥락·응답·피드백·보호 정책

대체 관계가 아니라 운영 대상과 증거 구조의 누적

| LLM 서비스에서 추가로 관리할 정보

EXECUTION KEY

TRACE ID

한 번의 실행을
다시 찾는 식별자

ff2c901e8a16

01	프롬프트 버전	템플릿 · 예시 · 정책
02	외부 맥락 참조	검색 문서 · 도구 반환값
03	응답과 운영 값	출력 · 상태 · 응답 지연
04	평가와 피드백	점수 · 오류 유형 · 검토 결과

| 같은 코드에서도 달라지는 실행 결과

같은 코드 · SAME CODE

커밋 a1b2c3

동일 접근 경로

동일 요청 스키마

동일 애플리케이션 코드

다른 실행 · DIFFERENT RUN

프롬프트 · 맥락 · 모델 · 설정

서로 다른 출력

서로 다른 응답 지연·토큰·상태

서로 다른 품질 평가

| LLM 실행 추적의 필수 필드

추적 식별자 · TRACE ID

request-specific ID

과업 · 설정

extract / t=0.2

출력

execution evidence

프롬프트 버전

w01.signal.v1

상태 · 응답 지연

ok / runtime value

토큰

provider count / estimate

제공자 · 모델

demo / trace-demo-1

콘텐츠 참조

sha256:ffdf...fe72

생성 시각

UTC timestamp

Trace ID = 버전 정보와 실행 결과를 연결하는 공통 식별자 · UTC = Coordinated Universal Time

| 서비스 운영의 다섯 평가 기준

01 품질

업무 정답 · 근거 · 형식 · 유용성

02 응답 지연

평균 · 50번째 백분위 · 95번째 백분위 · 시간 초과

03 비용

토큰 · 모델 · 도구 · 캐시

04 안전성

개인 식별 정보(Personally Identifiable Information, PII)
프롬프트 주입 · 권한 · 감사

05 재현성

환경 · 버전 · 실행 추적 · 커밋

| 운영 지표의 상충 관계

한 지표의 개선은 다른 지표의 비용을 함께 확인할 때만 운영 판단으로 완성

판단 축	변경 레버	함께 확인할 손실
품질 ↔ 비용	상위 모델 · 긴 맥락	요청당 비용 · 처리량
품질 ↔ 응답 시간	검색 · 도구 · 검증 단계	대기시간 · 시간 초과
안전 ↔ 처리 범위	차단 강도 · 사람 검토	정상 요청 누락
재사용 ↔ 최신성	캐시 적중 · 응답 재사용	정보 노후화


네 관계는 고정 법칙이 아니라 실험 전에 함께 관찰할 위험 가설

| 업무별 품질 평가 기준

업무	우선 품질 축	대표 실패
요약	충실성 · 압축률 · 핵심 보존	새 사실 추가 · 중요 정보 누락
정보 추출	스키마 준수 · 필드 정확성	필드 누락 · 근거 없는 값
검색 증강 답변	근거성 · 인용 정확도	근거 미검색 · 잘못된 인용
에이전트 행동	과업 성공 · 정책 준수	권한 없는 실행 · 중복 행동

| 평균과 꼬리 지연시간

설명용 분포 · 실제 측정값 아님



| LLM 요청 비용의 구성

$$\text{요청 비용} = \text{생성} + \text{워크플로} + \text{실패} - \text{재사용}$$

생성	워크플로	실패	재사용
입력·맥락·출력 토큰	검색·재순위·검증·도구	재시도·대체 경로 시간 초과	캐시·일괄 처리·모델 선택

모델 단가만이 아니라 한 요청이 실제로 거치는 전체 경로

| 입력부터 저장까지의 보안·안전 기준

입력

개인 식별 정보

정책 분류

프롬프트 주입

실행

도구 허용목록

시간 초과

사람 검토

출력

근거 연결

금지 표현

감사 로그

저장

원문 최소화

보존 기간

접근 통제

| 실행 결과 재현에 필요한 다섯 가지 정보



환경

Python · 패키지 · 운영체제 · 가속기



입력

평가 데이터 개정 · 콘텐츠 지문



지시

프롬프트 식별자 · 버전 · 스키마



실행


제공자 · 모델 · 설정



코드

커밋 · 접근 경로 · 정책

| LLM 서비스 개선 사이클



COURSE STANDARD

관찰 결과가 다음 기획과 변경
가설의 입력

품질·지연·비용·안전·재현성은 한 단계가 아니라 전 단계를 가로지르는 판단 축이다.
특정 마지막 노드는 없다.

의사결정 기준 계속 · 교체 · 종료

| 1단계 / 기획·데이터의 성공 기준

PROJECT BRIEF

누구의 어떤 결정을 돕는가?

모델 선택보다 먼저 문제·데이터·평가의 범위를
프로젝트 브리프로 고정

01

대상 사용자와
지원할 의사결정

02

대표 입력과
기대 행동

03

성공·금지 조건과
평가 데이터

04

데이터 권한·개인정보·
보존 경계

| 2단계 / 프롬프트·맥락의 버전 관리

02

OPERATING QUESTION

무엇이 바뀌었고 왜 바뀌었는가?

01

프롬프트 식별자·버전·책임자

02

입출력 스키마·예시

03

검색·도구 맥락 참조

읽기 좋은 프롬프트보다 고정 평가 데이터에서 비교 가능한 프롬프트

1 기획·데이터

2 프롬프트·컨텍스트

3 실행·배포


4 평가·관찰

5 개선·버전

| 3단계 / 실행·배포의 실패 경로

실패했을 때 어디로 흐르는가?

정상 경로



실패 경로




운영 문서에는 정상 흐름과 오류·재시도·대체 경로를 함께 기록

| 4단계 / 오프라인 평가와 운영 모니터링

누가, 언제, 어떻게 실패하는가?

설명용 응답 지연 분포 · 실제 측정값 아님



품질

대표 성공·실패

운영

95번째 백분위 · 오류율

자원·안전

토큰 · 비용 · 위험 신호

평균 점수와 함께 실패 분포·하위 집단·원본 실행 추적 확인

| 5단계 / 버전 변경 의사결정 기록

다음 버전은 무엇을 검증하는가?

01

이전 기준선

현재 실패와
고정 조건

02

새 가설과 변경

검증할 가설과
바꿀 한 가지

03

실행 증거

비교 가능한
실행 추적

04

평가와 다음 버전

승격·보류·되돌리기와
다음 질문

‘더 좋아 보임’이 아닌 변경 이유·결과·결정의 연결

| 버전 변경의 최소 기록

VERSION	HYPOTHESIS	CHANGE	DECISION
v0.1.0	교환 절차 누락 감소	스키마와 예시 추가	기준선
v0.2.0	마찰 필드 완전성 향상	프롬프트 버전만 변경	승격
v0.2.1	지연 증가 없는 표현 축약	최대 길이 조정	보류

버전 번호보다 중요한 연결: 가설 → 변경 → 실행 추적 → 의사결정

| 서비스 개선 단계와 학기 일정

서비스 개선 단계

01	02	03	04	05
기획·데이터	프롬프트·맥락	실행·배포	평가·관찰	개선·버전

학기 마일스톤

W01-07	W08	W09-15	W16
온라인 운영 W04·06 녹화	온라인 제출 제출본 평가	실시간 온라인 구현·운영 검증	실시간 온라인 프로젝트 발표

W08 온라인 제출본 평가 · W16 실시간 온라인 프로젝트 발표

04

TRACE / 01 LAB

첫 LLM 서비스 실행과 기록

Python 3.11.14 · Demo 기준선 · Qwen3 4B Instruct · 실행 추적과 비교

| 오늘 실습의 순서와 완료 기준



개발환경 준비

Python 3.11.14 · .venv 선택



테스트와 서버 실행

자동 테스트 실패 0건 · GET /health 정상



Demo 기준선 2회

같은 입력의 실행 추적 2건



Ollama 선택 실행

qwen3:4b-instruct · Thinking OFF



비교표와 다음 가설

비교 판단 1건 · 변경 가설 1개

| TRACE/01 실행 구조와 실습 파일



가이드 · week01/VS_CODE_GUIDE.md
노트북 · week01/lab/week01_trace01_lab.ipynb

| Python 3.11 개발환경 준비

TERMINAL / REPOSITORY ROOT

```
uv python install 3.11.14
uv venv --python 3.11.14 \
  --allow-existing .venv
uv pip install --python .venv/bin/python \
  -r requirements.txt
.venv/bin/python -m pytest -q \
  week01/lab/tests
```

3.11.14

VS Code

저장소 루트


llmops-16week

Environment: Bootstrap

Python: Select Interpreter

Tasks: Run Test Task

| TRACE/01 서버의 두 실행 경로



사용자 화면 · <http://127.0.0.1:8000> | 상태 · GET /health | 서버 터미널 유지

| VS Code 개발환경과 테스트 결과

```

week01 > # VS_CODE_GUIDE.md > # Week 01: VS Code 실행 가이드
1 # Week 01 - VS Code 실행 가이드
2
3 저장소 루트를 Visual Studio Code(VS Code)로 열린 'TRACE/01' 서버, 응용 프로그래밍 인터페이스(API) 테스트, 노트북을 하나의 '.venv'에서 실행할 수 있다. 기존 환경은 **macOS · zsh · uv · CPython 3.11.14**이다.
4
5 ## 1. 최초 환경 준비
6
7 1. VS Code에서 'llmops-16week' 저장소 루트를 연다.
8 2. 추천 확장 프로그램 Python, Pylance, Jupyter, Ruff를 설치한다.
9 3. Command Palette에서 'Tasks: Run Task' -> 'Environment: Bootstrap'을 실행한다.
10 4. 상태 표시줄의 Python 인터프리터가 '.venv/bin/python'인지 확인한다. 아니면 'Python: Select Interpreter'에서 직접 선택한다.
11
12 같은 준비를 터미널에서 수행할 때는 다음 명령을 사용한다.
13
14 ```bash
15 uv python install 3.11.14
16 uv venv --python 3.11.14 --allow-existing .venv
17 uv pip install --python .venv/bin/python -r requirements.txt
18 ```
19
20 ## 2. 서비스 실행과 확인
21
22 실행 횟수를 0부터 직접 기록하려면 'Tasks: Run Task' -> 'Week 01: Run TRACE/01'을 선택한다. 서버와 자동 요청을 한 번에 확인하려면 'Week 01: Start and smoke'를 사용한다. 후자는 합성 고객 피드백을 'demo' 제공자에 한 번 보내므로 사용자 확인의 전체 실행이 1부터 시작한다.
23
24 - 서비스 확인: <http://127.0.0.1:8080>
25 - OpenAPI 명세 문서: <http://127.0.0.1:8080/docs>
26 - 실행 trace: <http://127.0.0.1:8080/api/v1/traces>
27 - 실행 설정: <http://127.0.0.1:8080/api/v1/config>
28 - 수집물 통계: <http://127.0.0.1:8080/api/v1/stats>
29 - 운영 지표: <http://127.0.0.1:8080/metrics>
30
31 서버 종료는 Command Palette의 'Tasks: Terminate Task' -> 'Week 01: Run TRACE/01'을 선택한다.
32
33 ## 3. 테스트와 디버깅
34
35 - 전체 응용 프로그래밍 인터페이스 테스트: 'Testing' 패널 또는 'Tasks: Run Test Task' 실행
36 - 코드 품질 검사: 'Tasks: Run Task' -> 'Course: Ruff check'
37 - 서버 중단점 디버깅: 'Run and Debug' -> 'Week 01: Debug TRACE/01'
38
39
40
41
42
43
44
45
46
47
48
49
50
51
52
53
54
55
56
57
58
59
60
61
62
63
64
65
66
67
68
69
70
71
72
73
74
75
76
77
78
79
80
81
82
83
84
85
86
87
88
89
90
91
92
93
94
95
96
97
98
99
100
101
102
103
104
105
106
107
108
109
110
111
112
113
114
115
116
117
118
119
120
121
122
123
124
125
126
127
128
129
130
131
132
133
134
135
136
137
138
139
140
141
142
143
144
145
146
147
148
149
150
151
152
153
154
155
156
157
158
159
160
161
162
163
164
165
166
167
168
169
170
171
172
173
174
175
176
177
178
179
180
181
182
183
184
185
186
187
188
189
190
191
192
193
194
195
196
197
198
199
200
201
202
203
204
205
206
207
208
209
210
211
212
213
214
215
216
217
218
219
220
221
222
223
224
225
226
227
228
229
230
231
232
233
234
235
236
237
238
239
240
241
242
243
244
245
246
247
248
249
250
251
252
253
254
255
256
257
258
259
260
261
262
263
264
265
266
267
268
269
270
271
272
273
274
275
276
277
278
279
280
281
282
283
284
285
286
287
288
289
290
291
292
293
294
295
296
297
298
299
300
301
302
303
304
305
306
307
308
309
310
311
312
313
314
315
316
317
318
319
320
321
322
323
324
325
326
327
328
329
330
331
332
333
334
335
336
337
338
339
340
341
342
343
344
345
346
347
348
349
350
351
352
353
354
355
356
357
358
359
360
361
362
363
364
365
366
367
368
369
370
371
372
373
374
375
376
377
378
379
380
381
382
383
384
385
386
387
388
389
390
391
392
393
394
395
396
397
398
399
400
401
402
403
404
405
406
407
408
409
410
411
412
413
414
415
416
417
418
419
420
421
422
423
424
425
426
427
428
429
430
431
432
433
434
435
436
437
438
439
440
441
442
443
444
445
446
447
448
449
450
451
452
453
454
455
456
457
458
459
460
461
462
463
464
465
466
467
468
469
470
471
472
473
474
475
476
477
478
479
480
481
482
483
484
485
486
487
488
489
490
491
492
493
494
495
496
497
498
499
500
501
502
503
504
505
506
507
508
509
510
511
512
513
514
515
516
517
518
519
520
521
522
523
524
525
526
527
528
529
530
531
532
533
534
535
536
537
538
539
540
541
542
543
544
545
546
547
548
549
550
551
552
553
554
555
556
557
558
559
560
561
562
563
564
565
566
567
568
569
570
571
572
573
574
575
576
577
578
579
580
581
582
583
584
585
586
587
588
589
590
591
592
593
594
595
596
597
598
599
600
601
602
603
604
605
606
607
608
609
610
611
612
613
614
615
616
617
618
619
620
621
622
623
624
625
626
627
628
629
630
631
632
633
634
635
636
637
638
639
640
641
642
643
644
645
646
647
648
649
650
651
652
653
654
655
656
657
658
659
660
661
662
663
664
665
666
667
668
669
670
671
672
673
674
675
676
677
678
679
680
681
682
683
684
685
686
687
688
689
690
691
692
693
694
695
696
697
698
699
700
701
702
703
704
705
706
707
708
709
710
711
712
713
714
715
716
717
718
719
720
721
722
723
724
725
726
727
728
729
730
731
732
733
734
735
736
737
738
739
740
741
742
743
744
745
746
747
748
749
750
751
752
753
754
755
756
757
758
759
760
761
762
763
764
765
766
767
768
769
770
771
772
773
774
775
776
777
778
779
780
781
782
783
784
785
786
787
788
789
790
791
792
793
794
795
796
797
798
799
800
801
802
803
804
805
806
807
808
809
810
811
812
813
814
815
816
817
818
819
820
821
822
823
824
825
826
827
828
829
830
831
832
833
834
835
836
837
838
839
840
841
842
843
844
845
846
847
848
849
850
851
852
853
854
855
856
857
858
859
860
861
862
863
864
865
866
867
868
869
870
871
872
873
874
875
876
877
878
879
880
881
882
883
884
885
886
887
888
889
890
891
892
893
894
895
896
897
898
899
900
901
902
903
904
905
906
907
908
909
910
911
912
913
914
915
916
917
918
919
920
921
922
923
924
925
926
927
928
929
930
931
932
933
934
935
936
937
938
939
940
941
942
943
944
945
946
947
948
949
950
951
952
953
954
955
956
957
958
959
960
961
962
963
964
965
966
967
968
969
970
971
972
973
974
975
976
977
978
979
980
981
982
983
984
985
986
987
988
989
990
991
992
993
994
995
996
997
998
999
1000
1001
1002
1003
1004
1005
1006
1007
1008
1009
1010
1011
1012
1013
1014
1015
1016
1017
1018
1019
1020
1021
1022
1023
1024
1025
1026
1027
1028
1029
1030
1031
1032
1033
1034
1035
1036
1037
1038
1039
1040
1041
1042
1043
1044
1045
1046
1047
1048
1049
1050
1051
1052
1053
1054
1055
1056
1057
1058
1059
1060
1061
1062
1063
1064
1065
1066
1067
1068
1069
1070
1071
1072
1073
1074
1075
1076
1077
1078
1079
1080
1081
1082
1083
1084
1085
1086
1087
1088
1089
1090
1091
1092
1093
1094
1095
1096
1097
1098
1099
1100
1101
1102
1103
1104
1105
1106
1107
1108
1109
1110
1111
1112
1113
1114
1115
1116
1117
1118
1119
1120
1121
1122
1123
1124
1125
1126
1127
1128
1129
1130
1131
1132
1133
1134
1135
1136
1137
1138
1139
1140
1141
1142
1143
1144
1145
1146
1147
1148
1149
1150
1151
1152
1153
1154
1155
1156
1157
1158
1159
1160
1161
1162
1163
1164
1165
1166
1167
1168
1169
1170
1171
1172
1173
1174
1175
1176
1177
1178
1179
1180
1181
1182
1183
1184
1185
1186
1187
1188
1189
1190
1191
1192
1193
1194
1195
1196
1197
1198
1199
1200
1201
1202
1203
1204
1205
1206
1207
1208
1209
1210
1211
1212
1213
1214
1215
1216
1217
1218
1219
1220
1221
1222
1223
1224
1225
1226
1227
1228
1229
1230
1231
1232
1233
1234
1235
1236
1237
1238
1239
1240
1241
1242
1243
1244
1245
1246
1247
1248
1249
1250
1251
1252
1253
1254
1255
1256
1257
1258
1259
1260
1261
1262
1263
1264
1265
1266
1267
1268
1269
1270
1271
1272
1273
1274
1275
1276
1277
1278
1279
1280
1281
1282
1283
1284
1285
1286
1287
1288
1289
1290
1291
1292
1293
1294
1295
1296
1297
1298
1299
1300
1301
1302
1303
1304
1305
1306
1307
1308
1309
1310
1311
1312
1313
1314
1315
1316
1317
1318
1319
1320
1321
1322
1323
1324
1325
1326
1327
1328
1329
1330
1331
1332
1333
1334
1335
1336
1337
1338
1339
1340
1341
1342
1343
1344
1345
1346
1347
1348
1349
1350
1351
1352
1353
1354
1355
1356
1357
1358
1359
1360
1361
1362
1363
1364
1365
1366
1367
1368
1369
1370
1371
1372
1373
1374
1375
1376
1377
1378
1379
1380
1381
1382
1383
1384
1385
1386
1387
1388
1389
1390
1391
1392
1393
1394
1395
1396
1397
1398
1399
1400
1401
1402
1403
1404
1405
1406
1407
1408
1409
1410
1411
1412
1413
1414
1415
1416
1417
1418
1419
1420
1421
1422
1423
1424
1425
1426
1427
1428
1429
1430
1431
1432
1433
1434
1435
1436
1437
1438
1439
1440
1441
1442
1443
1444
1445
1446
1447
1448
1449
1450
1451
1452
1453
1454
1455
1456
1457
1458
1459
1460
1461
1462
1463
1464
1465
1466
1467
1468
1469
1470
1471
1472
1473
1474
1475
1476
1477
1478
1479
1480
1481
1482
1483
1484
1485
1486
1487
1488
1489
1490
1491
1492
1493
1494
1495
1496
1497
1498
1499
1500
1501
1502
1503
1504
1505
1506
1507
1508
1509
1510
1511
1512
1513
1514
1515
1516
1517
1518
1519
1520
1521
1522
1523
1524
1525
1526
1527
1528
1529
1530
1531
1532
1533
1534
1535
1536
1537
1538
1539
1540
1541
1542
1543
1544
1545
1546
1547
1548
1549
1550
1551
1552
1553
1554
1555
1556
1557
1558
1559
1560
1561
1562
1563
1564
1565
1566
1567
1568
1569
1570
1571
1572
1573
1574
1575
1576
1577
1578
1579
1580
1581
1582
1583
1584
1585
1586
1587
1588
1589
1590
1591
1592
1593
1594
1595
1596
1597
1598
1599
1600
1601
1602
1603
1604
1605
1606
1607
1608
1609
1610
1611
1612
1613
1614
1615
1616
1617
1618
1619
1620
1621
1622
1623
1624
1625
1626
1627
1628
1629
1630
1631
1632
1633
1634
1635
1636
1637
1638
1639
1640
1641
1642
1643
1644
1645
1646
1647
1648
1649
1650
1651
1652
1653
1654
1655
1656
1657
1658
1659
1660
1661
1662
1663
1664
1665
1666
1667
1668
1669
1670
1671
1672
1673
1674
1675
1676
1677
1678
1679
1680
1681
1682
1683
1684
1685
1686
1687
1688
1689
1690
1691
1692
1693
1694
1695
1696
1697
1698
1699
1700
1701
1702
1703
1704
1705
1706
1707
1708
1709
1710
1711
1712
1713
1714
1715
1716
1717
1718
1719
1720
1721
1722
1723
1724
1725
1726
1727
1728
1729
1730
1731
1732
1733
1734
1735
1736
1737
1738
1739
1740
1741
1742
1743
1744
1745
1746
1747
1748
1749
1750
1751
1752
1753
1754
1755
1756
1757
1758
1759
1760
1761
1762
1763
1764
1765
1766
1767
1768
1769
1770
1771
1772
1773
1774
1775
1776
1777
1778
1779
1780
1781
1782
1783
1784
1785
1786
1787
1788
1789
1790
1791
1792
1793
1794
1795
1796
1797
1798
1799
1800
1801
1802
1803
1804
1805
1806
1807
1808
1809
1810
1811
1812
1813
1814
1815
1816
1817
1818
1819
1820
1821
1822
1823
1824
1825
1826
1827
1828
1829
1830
1831
1832
1833
1834
1835
1836
1837
1838
1839
1840
1841
1842
1843
1844
1845
1846
1847
1848
1849
1850
1851
1852
1853
1854
1855
1856
1857
1858
1859
1860
1861
1862
1863
1864
1865
1866
1867
1868
1869
1870
1871
1872
1873
1874
1875
1876
1877
1878
1879
1880
1881
1882
1883
1884
1885
1886
1887
1888
1889
1890
1891
1892
1893
1894
1895
1896
1897
1898
1899
1900
1901
1902
1903
1904
1905
1906
1907
1908
1909
1910
1911
1912
1913
1914
1915
1916
1917
1918
1919
1920
1921
1922
1923
1924
1925
1926
1927
1928
1929
1930
1931
1932
1933
1934
1935
1936
1937
1938
1939
1940
1941
1942
1943
1944
1945
1946
1947
1948
1949
1950
1951
1952
1953
1954
1955
1956
1957
1958
1959
1960
1961
1962
1963
1964
1965
1966
1967
1968
1969
1970
1971
1972
1973
1974
1975
1976
1977
1978
1979
1980
1981
1982
1983
1984
1985
1986
1987
1988
1989
1990
1991
1992
1993
1994
1995
1996
1997
1998
1999
2000
2001
2002
2003
2004
2005
2006
2007
2008
2009
2010
2011
2012
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
2023
2024
2025
2026
2027
2028
2029
2030
2031
2032
2033
2034
2035
2036
2037
2038
2039
2040
2041
2042
2043
2044
2045
2046
2047
2048
2049
2050
2051
2052
2053
2054
2055
2056
2057
2058
2059
2060
2061
2062
2063
2064
2065
2066
2067
2068
2069
2070
2071
2072
2073
2074
2075
2076
2077
2078
2079
2080
2081
2082
2083
2084
2085
2086
2087
2088
2089
2090
2091
2092
2093
2094
2095
2096
2097
2098
2099
2100
2101
2102
2103
2104
2105
2106
2107
2108
2109
2110
2111
2112
2113
2114
2115
2116
2117
2118
2119
2120
2121
2122
2123
2124
2125
2126
2127
2128
2129
2130
2131
2132
2133
2134
2135
2136
2137
2138
2139
2140
2141
2142
2143
2144
2145
2146
2147
2148
2149
2150
2151
2152
2153
2154
2155
2156
2157
2158
2159
2160
2161
2162
2163
2164
2165
2166
2167
2168
2169
2170
2171
2172
2173
2174
2175
2176
2177
2178
2179
2180
2181
2182
2183
2184
2185
2186
2187
2188
2189
2190
2191
2192
2193
2194
2195
2196
2197
2198
2199
2200
2201
2202
2203
2204
2205
2206
2207
2208
2209
2210
2211
2212
2213
2214
2215
2216
2217
2218
2219
2220
2221
2222
2223
2224
2225
2226
2227
2228
2229
2230
2231
2232
2233
2234
2235
2236
2237
2238
2239
2240
2241
2242
2243
2244
2245
2246
2247
2248
2249
2250
2251
2252
2253
2254
2255
2256
2257
2258
2259
2260
2261
2262
2263
2264
2265
2266
2267
2268
2269
2270
2271
2272
2273
2274
2275
2276
2277
2278
2279
2280
2281
2282
2283
2284
2285
2286
2287
2288
2289
2290
2291
2292
2293
2294
2295
2296
2297
2298
2299
2300
2301
2302
2303
2304
2305
2306
2307
2308
2309
2310
2311
2312
2313
2314
2315
2316
2317
2318
2319
2320
2321
2322
2323
2324
2325
2326
2327
2328
2329
2330
2331
2332
2333
2334
2335
2336
2337
2338
2339
2340
2341
2342
2343
2344
2345
2346
2347
2348
2349
2350
2351
2352
2353
2354
2355
2356
2357
2358
2359
2360
2361
2362
2363
2364
2365
2366
2367
2368
2369
2370
2371
2372
2373
2374
2375
2376
2377
2378
2379
2380
2381
2382
2383
2384
2385
2386
2387
2388
2389
2390
2391
2392
2393
2394
2395
2396
2397
2398
2399
2400
2401
2402
2403
2404
2405
2406
2407
2408
2409
2410
2411
2412
2413
2414
2415
2416
2417
2418
2419
2420
2421
2422
2423
2424
2425
2426
2427
2428
2429
2430
2431
2432
2433
2434
2435
2436
2437
2438
2439
2440
2441
2442
2443
2444
2445
2446
2447
2448
2449
2450
2451
2452
2453
2454
2455
2456
2457
2458
2459
2460
2461
2462
2463
2464
2465
2466
2467
2468
2469
2470
2471
2472
2473
2474
2475
2476
2477
2478
2479
2480
2481
2482
2483
2484
2485
2486
2487
2488
2489
2490
2491
2492
2493
2494
2495
2496
2497
2498
2499
2500
2501
2502
2503
2504
2505
2506
2507
2508
2509
2510
2511
2512
2513
2514
2515
2516
2517
2518
2519

```

| API 요청과 운영 확인 주소

TRACE/01 1.0.0 OAS 3.1

/openapi.json

Week 01: one request, one trace, one improvement loop.

default

GET

/health

Health

▼

GET

/api/v1/config

Runtime Config

▼

POST

/api/v1/generate

Generate

▼

GET

/api/v1/traces

Traces

▼

GET

/api/v1/stats

Stats

▼

GET

/metrics

Metrics

▼

Schemas

GenerateRequest

Expand all

object

기준 경로

서비스 상태

GET /health

현재 설정

GET /api/v1/config

생성 요청

POST /api/v1/generate

| 실행 기록과 운영 지표의 정확한 경로

01

`/api/v1/config`

모델 · Thinking 요청값
컨텍스트 · 출력 상한

02

`/api/v1/traces`

최근 실행 추적과
요청별 메타데이터

03

`/api/v1/stats`

성공률 · 평균·95백분위
응답 지연 · 추정 토큰

04

`/metrics`
`/docs`

Prometheus 지표
OpenAPI 데이터 구조

축약 경로가 아닌 서버에 구현된 전체 경로 사용

| Demo 기준선 실행 화면

배송은 빨랐지만 추천 결과가 매번 달라서 비교하기 어려웠습니다. 어떤 프롬프트와 모델을 썼는지 기록되면 팀이 더 빠르게 개선할 수 있을 것 같아요.

작업

실행

온도

신호 추출

Demo · 오프라인 규칙 엔진

0.2

수업용 Ollama 설정

qwen3:4b-instruct

Thinking OFF · 출력 상한 128 · 컨텍스트 2048 · 유지 30m

추적 실행 · Run trace

원문은 저장하지 않습니다. 12자리 콘텐츠 지문(content fingerprint)과 실행 메타데이터만 기록합니다.

SIGNAL — 배송은 빨랐다는 관찰
 FRICTION — 추천 결과가 매번 달라서 비교하기 어려웠습니다.
 NEXT ACTION — 같은 입력 세트로 다음 버전을 비교하고 지표를 기록한다.

추적 식별자 · Trace ID	프롬프트 버전 · Prompt version	모델 · Model
33fab1e5a681	w01.signal.v1	trace-demo-1
Thinking 요청값	응답 지연 · Latency	모델 적재 · Load
OFF	0.15 ms	—
추정 토큰 · Estimated tokens*	출력 상한 · Output limit	모델 생성 · Generation
63	—	—
종료 사유 · Finish reason	콘텐츠 지문 · Content fingerprint	
—	ffdf1925fe72	

기준선 실행

제공자

Demo

응답 지연

현재 실행값

완료 증거

Trace ID · 지문

| Qwen3 4B 응답 시간 설정

qwen3:4b-instruct

MODEL

Thinking 전용이 아닌 지시 수행 모델

Thinking 요청값

false

별도 추론 출력을 요청하지 않는 API 설정

입력·출력 한도

2048 · 128

짧은 수업 입력의 컨텍스트와 최대 생성 토큰

메모리·재현

30m · seed 42

반복 호출의 재적재 감소와 비교 조건 고정

--hidethinking은 표시만 숨기는 옵션 · 속도 설정은 비추론 모델과 think:false의 조합

| Qwen3 Instruct 실행 결과

배송은 빨랐지만 추천 결과가 매번 달라서 비교하기 어려웠습니다. 어떤 프롬프트와 모델을 썼는지 기록되면 팀이 더 빠르게 개선할 수 있을 것 같아요.

SIGNAL: 추천 결과가 매번 달라서 비교하기 어려웠습니다.
FRICTION: 어떤 프롬프트와 모델을 썼는지 기록되지 않음.
NEXT ACTION: 프롬프트와 모델 사용 기록을 체계적으로 기록할 것.

작업
실행
온도
0.2

신호 추출
Ollama · 로컬 언어 모델

수업용 Ollama 설정
qwen3:4b-instruct
Thinking OFF · 출력 상한 128 · 컨텍스트 2048 · 유지 30m

추적 실행 · Run trace

원문은 저장하지 않습니다. 12자리 콘텐츠 지문(content fingerprint)과 실행 메타데이터만 기록합니다.

추적 식별자 · Trace ID	프롬프트 버전 · Prompt version	모델 · Model
18cb16bc00ab	w01.signal.v1	qwen3:4b-instruct
Thinking 요청값	응답 지연 · Latency	모델 적재 · Load
OFF	1950.65 ms	12.80 ms
추정 토큰 · Estimated tokens*	출력 상한 · Output limit	모델 생성 · Generation
67	128	922.89 ms · 70 tokens
종료 사유 · Finish reason	콘텐츠 지문 · Content fingerprint	
stop	ffdf1925fe72	

실행 예시 · 환경별 차이

모델

qwen3:4b-instruct

Thinking

OFF

종료 사유

stop

| Demo와 Ollama 실행 경로 비교

RUN A / BASELINE		Δ	RUN B / VARIANT
입력	동일 합성 고객 피드백	=	동일 합성 고객 피드백
작업·온도	extract · 0.2	=	extract · 0.2
제공자·모델	demo · trace-demo-1	≠	ollama · qwen3:4b-instruct
확인	형식 · 근거 · 상태 · 지연	↔	형식 · 근거 · 적재 · 생성

운영 경로 비교이며 모델 성능의 우열 결론은 아님

| 실습 노트북 실행 순서

순서	노트북 단계	완료 증거
01	Python 버전과 서버 주소	.venv/bin/python · http://127.0.0.1:8000
02	상태와 현재 설정	/health 정상 · /api/v1/config 설정 확인
03	Demo 기준선 2회	같은 입력 · 같은 프롬프트 · 추적 식별자 2건
04	실행 추적 비교표	모델 · 온도 · Thinking · 지연 · 콘텐츠 지문
05	traces · stats · metrics	개별 실행 · 집계 · 수집 지표의 차이
06	선택형 Ollama 실행	qwen3:4b-instruct · 종료 사유 · 다음 변경

| Ollama 오류와 지연 점검

503 / MODEL

모델 태그 불일치

→

ollama list → qwen3:4b-instruct 설치 → .env 재실행

503 / SERVER

Ollama 연결 실패

→

/api/version 확인 → 앱 또는 ollama serve 하나만 실행

SLOW

응답 시간 과다

→

/api/v1/config · ollama ps → 두 번째 호출과 비교

LENGTH

출력 상한 도달

→

finish_reason=length → 192 또는 256으로 상향

422

요청 데이터 구조 오류

→

/docs → task · provider · temperature 범위 확인

첫 실습 운영 기록

01 환경 Python · Ollama 버전 · 모델 태그 · Thinking 요청값

02 실행 증거 Demo 추적 2건 · Ollama 선택 추적 1건 · 비교 판단

03 다음 변경 바꿀 변수 1개 · 기대 결과 · 확인 방법 · 교수 질문
