

프롬프트 평가 오류 분류

평가 기준 · 개발·확인 사례 · 결정 기록

WEEK 03 · 2026.09.18

합성 회의록 평가 작업대 EVAL/03

차성재 · 무신사 Core AI PM × AI 대학원 겸임교수

오늘의 완료 증거

- | | | |
|----|----------|------------------------------|
| 01 | 평가 기준 | 결과를 보기 전에 구조·사실·근거·실행 항목을 정의 |
| 02 | 개발·확인 분리 | 개선에 쓴 사례와 최종 확인 사례를 구분 |
| 03 | 결정 기록 | 후보·보류·제외와 다음 확인을 한 문장으로 남김 |

16주 로드맵 · 현재 위치

01 09.04

실행 추적

02 09.11

프롬프트 비교

03 09.18

평가 기준

04 09.25

검색 근거 · 녹화

05 10.02

검색 품질

06 10.09

데이터 · 녹화

07 10.16

기술 대안

08 10.23

기획서 제출·평가

09-15 10.30-12.11

구현·운영·프로젝트

16 12.18

실시간 온라인 발표

W03 · 평가 기준과 오류 분류 · 전 과정 온라인 · 현재 주차만 파랑 표시

지난 주와 오늘의 연결

2주차 · 비교

같은 입력과 조건에서 프롬프트 버전을 비교
변경한 규칙과 결과를 함께 기록

3주차 · 판정

무엇이 통과·실패인지 기준을 고정
오류 유형과 다음 확인을 함께 기록

100분 수업 구성


01	00:00-00:10	질문·로드맵·완료 증거
02	00:10-00:32	평가 기준과 오류 분류
03	00:32-00:43	실습 구조와 사례 읽기
04	00:43-00:48	휴식·환경 준비
05	00:48-01:19	EVAL/03 실행과 기록
06	01:19-01:40	결과 해석·다음 확인

평가의 출발점

“좋은 답변”이라는 말만으로는 결과를 다시 확인할 수 없다.

무엇을 보았는지, 어떤 사례에서 어긋났는지, 다음에 무엇을 확인할지를 남긴다.

오늘의 실습 산출물



프롬프트 v0.1·v0.2 · 합성 회의 발췌 · 고정 응답 · 실제 모델 성능 측정 아님

평가 기준과 오류 분류

점수보다 먼저 판정 범위

사례보다 먼저 기대 기준

개선보다 먼저 실패 설명

평가 대상의 구체화

평가 대상은 “모델” 하나가 아니라 입력·프롬프트·모델
설정·출력 검사로 이루어진 실행 단위다.

한 요소를 바꾸면 결과 차이의 원인을 분리해 기록한다.

결과와 판정의 분리

결과

회의록 문장과 섹션

모델 또는 고정 응답이 만든 산출물

판정

통과·실패와 이유

사전에 정한 루브릭이 만든 해석

하나의 출력 · 네 가지 확인

01

구조

필수 섹션 4개

02

핵심 사실

앵커 문구 누락

03

근거

원문 밖 단정

04

실행 항목

담당·기한·미정

평가 계약

항목	이번 실습의 결정
입력	합성 회의 발췌 6건
출력	결정·실행·위험·다음 단계 회의록
기준	구조·핵심 사실·근거·실행 항목
기록	프롬프트 원문·해시·결과·결정 이유

루브릭과 측정값

루브릭

무엇을 통과로 볼지

사람이 읽을 수 있는 판단 문장

측정값

몇 건이 통과했는지

루브릭을 집계한 숫자

근거 없는 단정

원문: “이번 달 예산은 아직 검토 중이다.”

출력: “예산 승인 완료 후 데이터 정제를 진행한다.”

판정: 구조가 맞아도 원문에 없는 확정 정보를 추가했으므로 근거 검사 실패

사실 앵커의 역할



앵커는 완전한 의미 이해가 아니라, 이번 사례에서 반드시 남아야 하는 사실의 최소 확인점

오류 분류의 언어

오류 유형	질문	예시
누락	필요한 사실이 빠졌나	담당자·기한 없음
왜곡	원문 뜻이 달라졌나	검토 중 → 승인 완료
형식	약속한 구조가 있나	필수 섹션 없음
범위 밖	검사하지 않은 문제인가	문체·설득력

누락과 왜곡의 차이

누락

말해야 할 사실을 말하지 않음

다음 확인에서 원문과 출력 대조

왜곡

원문에 없는 사실을 더함

근거·정책·책임 판단에 더 큰 위험

오류 위치



같은 실패라도 원인은 데이터·지시·생성·검사·해석 중 다른 위치에 있을 수 있다

개발 사례와 확인 사례

개발 사례 · dev

규칙·프롬프트를 다듬는 데 사용

이번 실습 4건

확인 사례 · test

선택 후에 별도로 확인

이번 실습 2건

확인 사례 오염

확인 사례를 보며 프롬프트를 계속 고치면, 그 사례는 더 이상 독립적인 확인 근거가 아니다.

수정 전후의 데이터 묶음과 선택 시점을 함께 기록한다.

적은 사례의 해석

2/4와 2/2는 각각 다른 질문에 대한 결과다.

dev 2/4: 개선에 쓴 작은 사례에서 네 기준을 모두 통과한 수

test 2/2: 선택 뒤 별도 사례에서 확인한 수

둘 다 일반 성능·운영 준비 완료를 보장하지 않는다.

결정 이전의 질문

- | | | |
|----|---------|-------------------------|
| 01 | 기준의 적합성 | 이 업무에서 이 네 검사가 충분한가 |
| 02 | 사례의 대표성 | 빠진 상황과 위험이 무엇인가 |
| 03 | 오류의 설명 | 실패를 다시 만들고 원인을 말할 수 있는가 |

EVAL/03 평가 작업대

합성 회의 발체 · 고정 응답

외부 모델·API 키 없이 재현

평가 규칙과 결정 기록 중심

실습 서비스 구성



EVAL/03은 FastAPI 기반의 로컬 수업 도구 · 주소 <http://127.0.0.1:8003>

합성 회의 발췌

M02 · 기한 미정

“검색 결과의 출처 표시는 필요하다. 담당자와 완료일은 정하지 못했다.”

실제 회의·학생 개인정보·외부 전송 없음

프롬프트 두 버전

v0.1 · 짧은 요약

핵심 논의와 다음 작업을 한 문단으로 정리

필수 섹션 요구 없음

v0.2 · 구조화 회의록

결정·실행·위험·다음 단계 분리

원문 밖 사실 금지와 미정 표기 요구

네 가지 검사 규칙

01

구조

4개 섹션

02

핵심 사실

필수 앵커

03

근거

금지 단정 없음

04


실행 항목

담당·기한·미정

사례 묶음

구분	사례	수업에서 쓰는 이유
dev	M01-M04 · 4건	구조·미정·근거·복합 위험을 읽고 개선
test	M05-M06 · 2건	선택 후 새 표현과 보류 결정을 확인

실행 보고서 구조



같은 실행을 찾기 위한 식별 정보 · 민감 원문을 익명화하는 기능은 아님

브라우저 화면 읽기

STEP 01 평가 실행 → STEP 02 프롬프트·기준 → STEP 03
결과·오류 → STEP 04 후보 결정

수업 중에는 한 결과 행을 열어 원문·출력·실패 이유를 함께 읽는다.

실습 전 점검

```
.venv/bin/python -m uvicorn eval03.main:app \  
  --app-dir week03/lab --host 127.0.0.1 --port 8003
```

VS Code → Terminal → Run Task → Week 03: Run EVAL/03 · 브라우저 <http://127.0.0.1:8003>

환경 준비

5분 · 서버 시작 · 브라우저 열기

수업 필수는 Demo · Ollama·API 키 없음

막히면 화면을 보며 기준과 실패 유형부터 기록

STEP 01 · 서버 시작

```
.venv/bin/python -m uvicorn eval03.main:app \  
  --app-dir week03/lab --host 127.0.0.1 --port 8003
```

예상 신호 · Uvicorn running on http://127.0.0.1:8003 · 종료는 서버 터미널에서 Ctrl+C

STEP 02 · 평가 실행

- | | | |
|----|----------|------------------------|
| 01 | 사례 묶음 선택 | dev · 개선에 쓰는 개발 사례 4건 |
| 02 | 두 버전 평가 | v0.1과 v0.2를 같은 사례에서 실행 |
| 03 | 결과 행 확인 | 통과율보다 실패한 기준을 먼저 열기 |

v0.1 · 구조 실패

v0.1 출력: 한 문단 요약

루브릭: 결정 사항 · 실행 항목 · 위험·확인 필요 · 다음 단계

판정: 내용이 자연스러워도 섹션 계약을 지키지 않아 `structure_ok = false`

M02 · 실행 항목 실패

출력의 실행 항목: “디자인 작업은 담당자와 완료일을 정한 뒤 시작한다.”

원문: 담당자와 완료일은 정하지 못했다.

판정: 전체 사실은 남아도 실행 항목 안에 담당·기한·미정이 없어 `action_ok = false`


M03 · 근거 실패

01 원문: 이번 달 예산은 아직 검토 중

02 출력: 예산 승인 완료 후 데이터 정제를 진행

03 판정: 금지 단정 “예산 승인 완료”가 있어 evidence_ok = false

실패 상세의 읽는 순서



“실패했다”에서 멈추지 않고, 어느 기준이 어떤 근거로 실패했는지 읽는다

개발 사례 결과

버전	전체 통과	대표 실패
v0.1	0 / 4	필수 섹션 없음
v0.2	2 / 4	M02 실행 항목 · M03 근거

통과율의 한계

v0.2의 2/4는 “이 고정 응답과 4개 개발 사례에서 네 조건을 모두 통과한 수”다.

실제 LLM 성능, 실제 사용자 만족, 다른 업무의 품질을 뜻하지 않는다.

오류 기록 문장

01 사례: M03 / 버전: v0.2

02 기준: 근거 없는 단정 금지

03 관찰: “예산 승인 완료”가 원문에 없음

04 다음 확인: 승인·확정 표현의 부정문과 우회 표현 추가

프롬프트 원문 확인

```
# week03/lab/prompts/meeting_minutes_v0.2.md
- 결정 사항, 실행 항목, 위험·확인 필요, 다음 단계를 분리
- 원문에 없는 사실을 추가하지 않음
- 담당자·완료일이 없으면 “미정”으로 남김
```

Demo 응답은 고정이므로 프롬프트 파일을 수정해도 화면의 결과는 바뀌지 않는다

STEP 03 · 확인 사례 실행

- | | | |
|----|----------|---------------------------|
| 01 | 사례 묶음 변경 | test · 최종 확인 사례 2건 |
| 02 | 같은 기준 실행 | 선택 뒤 새로운 사례에서 확인 |
| 03 | 해석 분리 | 2/2는 작은 확인 결과이지 일반 성능이 아님 |

개발과 확인의 비교

dev · 4건

개선에 사용

v0.2 전체 통과 2/4

test · 2건

선택 뒤 확인

v0.2 전체 통과 2/2

후보 결정 기록

필드	기록 예시
후보 버전	v0.2 · 구조화 회의록
판단	보류
근거와 다음 확인	M02 미정 표기와 M03 단정 오류를 수정 기준으로 추가 사례 평가

JSON 보고서 보관



서버 메모리 기록은 재시작하면 초기화 · 수업 종료 전에 저장

자동 테스트

```
PYTHONPATH=week03/lab .venv/bin/python -m eval03.smoke  
PYTHONPATH=week03/lab .venv/bin/python -m pytest week03/lab/tests -q  
.venv/bin/python -m ruff check week03
```

검증 범위 · 상태 확인, 4×2 개발 결과, 오류 규칙, 결정 기록, JSON 내보내기

실습 중 질의응답

- 01 어떤 기준이 실제 프로젝트에 가장 먼저 필요한가

- 02 현재 기준으로 놓치는 오류는 무엇인가

- 03 새 확인 사례를 어떤 업무 상황에서 만들 것인가

- 04 이 결과를 후보·보류·제외 중 무엇으로 기록할 것인가

결과 해석과 버전 결정

작은 평가 세트의 결과를 과장하지 않기

통과율·실패 유형·남은 위험을 함께 읽기

기획서의 선택 근거로 누적하기

결과 요약

구분	v0.1	v0.2
dev 전체 통과	0 / 4	2 / 4
test 전체 통과	0 / 2	2 / 2
해석	필수 구조 불충족	구조 개선 · 근거·미정 오류 남음

오류와 대응


오류	현재 관찰	다음 대응
구조	v0.1에 필수 섹션 없음	출력 구조 요구와 검사 유지
실행 항목	M02에 미정 정보가 없음	미정 표기 사례 추가
근거	M03에 승인 완료 단정	확정 표현과 원문 근거 대조 확대

합계 점수만으로 부족한 이유

동일한 2/4라도 실패가 문체인지, 근거 없는 약속인지에 따라
다음 행동이 다르다.

업무 위험이 큰 오류는 같은 한 건이어도 별도 기준·사람 검토가 필요하다.

결정 상태



후보: 다음 확인 가능 · 보류: 근거 부족 또는 위험 남음 · 제외: 현재 기준에서 사용하지 않음

보류 결정의 근거

현재 기록: v0.2를 보류

이유: dev에서 M02 실행 항목, M03 근거 오류 확인

다음 확인: 미정·확정 표현의 변형 사례와 사람 검토 결과를 추가

범위: 교육용 고정 응답 · 실제 배포 없음

다음 확인 설계

- | | | |
|----|--------|-----------------------|
| 01 | 새 사례 | 미정·부정문·조건부 약속을 포함 |
| 02 | 같은 루브릭 | 바뀌지 않은 기준과 새 기준을 구분 |
| 03 | 사람 검토 | 자동 규칙이 놓친 의미·업무 위험 확인 |

프로젝트 기획서 연결



8주차 온라인 기획서 제출·평가를 위해, 자신의 서비스에 필요한 평가 기준과 대표 실패를 누적

오늘의 기록 양식

- 01 서비스에서 만들고 싶은 결과

- 02 결과가 맞다고 볼 최소 기준

- 03 대표 성공 사례 1건과 실패 사례 1건

- 04 후보·보류·제외 중 현재 판단과 다음 확인

다음 주 연결

다음 주에는 검색 증강 생성 (Retrieval-Augmented Generation, RAG)의 근거와 인용을 다룬다.

검색 결과도 “찾았다”가 아니라 어떤 문서·근거를 답변에 사용했는지 평가 대상으로 만든다.

오늘의 핵심

01	기준	결과보다 먼저 고정
02	사례	개발과 확인을 분리
03	오류	누락·왜곡·형식·범위를 구분
04	기록	결정과 다음 확인을 남김

수업 종료 확인

실습 화면에서 JSON을 저장했는가

대표 실패 1건을 기준·관찰·다음 확인으로 설명할 수 있는가

2주차 과제 01의 마감과 4주차 격주 과제를 분리해 확인했는가

평가 필드 사전

필드	뜻
structure_ok	네 필수 섹션 존재
coverage_ok	사례별 핵심 앵커 누락 없음
evidence_ok	금지 단정 미포함
action_ok	실행 항목에 담당·기한 또는 미정
overall_ok	네 필드 모두 true

형식 검사와 의미 검사

형식 검사

제목·섹션·자료형처럼 비교적 명확한 계약

자동화하기 쉬우나 충분 조건은 아님

의미 검사

원문과의 일치·업무 위험·문맥

사람 검토·표본·추가 규칙이 필요

자동 규칙의 오탐과 누락

상태	의미	대응
오탐	문제 없는데 실패로 표시	규칙·사례·사람 검토 확인
누락	문제 있는데 통과로 표시	새 실패 사례와 보완 기준 추가
미평가	검사 범위 밖	통과로 해석하지 않음

사람 검토의 역할

사람 검토는 자동 평가를 무효화하는 과정이 아니라, 자동 규칙이 다루지 못한 맥락·정책·위험을 보완하는 과정이다.

검토 결과도 사례·판단자·근거·불일치를 기록해야 비교 가능하다.


루브릭 작성 예시

항목	나쁜 기준	확인 가능한 기준
근거	사실에 맞음	원문에 없는 확정·승인 표현 없음
실행	일이 명확함	실행 항목에 담당자·기한 또는 미정
구조	읽기 좋음	네 섹션을 제목으로 구분

데이터 보호 기준

01	합성 데이터 우선	실제 회의·고객·학생 자료를 실습에 넣지 않음
02	식별 정보 제외	이름·연락처·토큰·내부 문서 제거
03	해시의 한계	동일성 확인용 식별자이며 익명화가 아님

코드 읽기 지도



데이터 → 고정 결과 → 루브릭 → 실행 보고서 → 화면·API

실습 명령 모음

서버

```
.venv/bin/python -m uvicorn eval03.main:app --app-dir week03/lab --port 8003
```

검증

```
PYTHONPATH=week03/lab .venv/bin/python -m eval03.smoke
```

macOS/Linux 기준 · Windows는 week03/VS_CODE_GUIDE.md의 PowerShell 안내 사용

API 경로

메서드	경로	용도
GET	/health	서비스 상태
GET	/api/catalog	프롬프트·루브릭 목록
POST	/api/evaluations	dev 또는 test 평가 실행
POST	/api/decisions	후보·보류·제외 기록
GET	/api/evaluations/ {run_id}/ export	JSON 보고서 내보내기

자료와 검증 범위

- 01 cases.json · 합성 사례·기대 앵커·금지 단정

- 02 demo_outputs.json · 수업용 고정 응답

- 03 tests · 규칙·API 테스트 10개

- 04 VS_CODE_GUIDE.md · 환경·실행·오류 복구

용어 정리

용어	수업에서의 뜻
평가 세트	출력과 기준을 비교하는 사례 묶음
루브릭	통과·실패를 정하는 판단 기준
개발 사례	개선에 사용할 수 있는 사례
확인 사례	선택 뒤 별도로 확인할 사례
Retrieval-Augmented Generation, RAG	검색 문서를 근거로 답하는 생성 방식

수업 자료 위치

PPT · week03/lecture/
03_week3_prompt_evaluation_error_analysis.pptx

학생용 PDF · output/pdf/

03_week3_prompt_evaluation_error_analysis.pdf

실습 안내 · week03/README.md · 실행 가이드 · week03/VIS_CODE_GUIDE.md