

검색 품질 개선

비교 · 순위 결합 · 실패 질의 · 실험 기록

WEEK 05 · 2026.10.02 · 온라인 실시간

차성재 · 무신사 Core AI PM × AI 대학원 겸임교수

오늘의 학습 목표

01	검색 방식 비교	TF-IDF·BM25의 동작 차이
02	결합·재정렬	후보 생성과 순위 변경 구분
03	설정 선택	질의별 실패·비용·복잡도 함께 판단

16주 로드맵 · 현재 주차

01 09.04

실행 추적

02 09.11

프롬프트 비교

03 09.18

평가·오류 분류

04 09.25

RAG·근거 · 녹화

05 10.02

검색 품질

06 10.09

데이터 · 녹화

07 10.16

개선 대안

08 10.23

기획서 제출·평가

09-15 10.30-12.11

구현·운영·프로젝트

16 12.18

실시간 온라인 발표

온라인 수업 운영

주차	운영
01-03, 05, 07, 09-15	온라인 실시간 강의
04 · 09.25 / 06 · 10.09	휴일 주간 · 녹화영상 업로드로 대체
08 · 10.23	중간고사 없음 · 기획서 온라인 제출·평가
16 · 12.18	온라인 실시간 프로젝트 발표

100분 수업 구성

01	00-10분	4주차 질문·오늘의 목표
02	10-30분	TF-IDF·BM25·의미 검색
03	30-45분	RRF·재정렬·후보 수
04	45-50분	휴식·환경 점검
05	50-85분	Notebook·질의별 실험
06	85-100분	과제 피드백·기획서

4주차와 5주차

W04 · 근거 확인

문서·날짜·권한·인용

찾은 자료를 믿을 수 있는지

W05 · 검색 개선

검색 방식·질의 표현·평가

필요한 자료를 더 잘 찾는지

이번 주의 과제 운영

새 과제 출제 없이 과제 02 개선·피드백

격주 과제 · 다음 출제는 6주차 · 온라인 제출 기준은 공지 확인

실패 질의의 출발점

질문: 돈은 언제 돌려줘요

문서 제목: 환불 처리 기간

문서가 있어도 사용자의 표현과 다르면 찾지 못할 수 있습니다.

검색 방식의 이해

Sparse · 희소 표현 / Dense · 밀집 표현

모델 기반 의미 검색과 어휘 검색의 구분

희소 표현과 밀집 표현

희소 표현 · sparse

단어별 빈도·가중치


BM25·TF-IDF 등 어휘 기반

밀집 표현 · dense

학습된 벡터의 좌표

임베딩 모델·유사도 검색

키워드 검색의 흐름



한국어 띄어쓰기·조사·동의어·업무 용어를 실패 질의로 확인

비교 · 순위 결합 · 실패 질의 · 실험 기록

한국어 토큰화 예시

반품 / 반품은 / 반품할

단어만 구분하면 서로 다른 표현

실습: 단어 + 2·3문자 n-gram · 형태소 분석기 아님

단어와 문자 n-gram

단어만

단어 의미와 경계를 유지

조사·띄어쓰기 변화에 약함

문자 조각 추가

부분 표현의 공통점 활용

짧은 공통 조각이 잡음을 늘릴 수 있음


TF-IDF · 단어 가중치

Term Frequency–Inverse Document Frequency

문서 내 빈도 × 역문서 빈도

실습: $(1 + \log tf) \times [\log((N+1)/(df+1)) + 1]$

문서 빈도와 구분력



설명용 N=10 고정 · 실습 smoothing 공식을 사용한 계산

코사인 유사도

벡터 내적 / 두 벡터 길이의 곱

동일 방향: 1 · 직교: 0

TF-IDF 벡터는 학습된 의미 임베딩이 아닙니다.

BM25의 동작

단어 빈도 포화 · 문서 길이 정규화

설정은 대표 질의에서 비교


BM25 · 검색 점수

Best Matching 25 · 어휘 기반 순위 함수

단어 빈도·희귀도·문서 길이를 함께 반영


k_1 : 빈도 포화 / b : 길이 정규화

빈도 포화의 효과



설명용 $k_1=1.5$ · 길이 비율 1 고정 · 반복 빈도의 점수 증가 폭 감소

문서 길이의 효과



설명용 $tf=2$, $k1=1.5$, 평균 길이 100 · $b=0$ 과 0.75 비교

BM25 설정

설정	의미	실습 기준
k1	단어 빈도 포화	1.5
b	문서 길이 정규화	0.75
토큰화	일치할 표현의 단위	단어 + 한국어 n-gram
필터	검색 대상 문서	권한·적용 날짜 먼저

TF-IDF와 BM25

TF-IDF + cosine

정규화된 어휘 벡터 비교

간단한 기준 검색기

BM25

빈도 포화·길이 보정

어휘 검색 기준선


검색 점수의 척도

BM25 점수와 코사인 점수는 다른 척도입니다.

두 raw score를 그대로 더하면 한 방식이 과도하게 지배할 수 있습니다.

선택 실습 · 실제 임베딩

자료



질문



기준선과 모델 검색

필수 기준선

작은 자료 · 빠른 실행

원리·실패·평가를 먼저 확인

선택 모델 검색

학습된 의미 임베딩


한국어 질의·모델 입력 제한 검증

순위 결합과 재정렬

후보 생성 · 결합 · 재정렬을 분리


각 단계의 실패와 비용을 기록

하이브리드 검색의 구조



운영 설계 예시 · 필수 실습은 BM25 + TF-IDF 두 어휘 검색기의 결합

검색 파이프라인



후보에 없는 정답은 재정렬로 복구할 수 없음

RRF · 순위 역수 결합

Reciprocal Rank Fusion

문서 점수 = $\sum 1 / (\text{constant} + \text{rank})$

실습 constant=60 · 높은 순위와 여러 검색기의 공통 후보 반영

RRF의 계산 예시

A 검색기1 1위 + 검색기2 3위

B 검색기1 2위 + 검색기2 1위

C 검색기1 3위만

$A=1/61+1/63$ · $B=1/62+1/61$ · $C=1/63$ · B가 가장 큰 값

점수 결합과 순위 결합

점수 결합

점수 척도·정규화·가중치 필요

후보 분포 변화에 민감

RRF 순위 결합

점수 대신 순위를 사용

동점·중복·상수 설정 확인

중복 후보의 처리

같은 검색 목록에서 문서가 중복되어도 기여는 한 번

같은 원문 조각과 같은 원문 문서는 서로 다른 식별 단위

평가는 문서 기준 중복 제거 후 계산

후보 수와 정답 누락

전체 허용 자료

상위 후보 8개

재정렬 5개

근거 3개

단계별 수는 설계 예시 · 후보에 없던 문서는 다음 단계가 새로 만들지 않음

재정렬 방식

규칙 기반 재정렬

질문 단어의 원문 포함 비율

가법지만 의미·부정·예외에 한계

신경망 재정렬

질문과 후보를 함께 입력하는 모델


추론 시간·모델 평가 필요

재정렬 효과와 한계

순위 변경과 새 근거 발견은 다른 작업입니다.

첫 검색에서 정답이 누락되면 토큰화·확장·후보 수부터 확인합니다.

복합 질문의 검색



추가 검색 지연 · 잘못된 분해 · 전체 주장과 출처 연결도 확인

비교 · 순위 결합 · 실패 질의 · 실험 기록

단계별 Notebook 실습

01 어휘 검색 · 02 결합·재정렬

03 검색 실험 · 04 서비스·기획 연결

실습 파일 구성

노트북	핵심 실험
01_lexical_search	TF-IDF·BM25·토큰화
02_fusion_reranking	RRF·후보 수·규칙 재정렬
03_search_experiments	변경 비교·실패 질의·확인
04_service_project	API·자기 자료·기획 요구사항

Notebook 실행과 기록

01	예측	결과를 보기 전 정답 문서·순위 예상
02	실행	셀 순서대로 실행 · 설정 하나 변경
03	해석	실패 질의·남은 한계·다음 확인 기록

실습 01 · 토큰 확인

`tokenize('반품은 수령 후 가능합니다', False)`

`tokenize('반품은 수령 후 가능합니다', True)`

단어·부분 조각이 실제 검색에 어떻게 사용되는지 확인


실습 01 · 검색 방식 비교

```
for method in ['tfidf', 'bm25']:
    r = retrieve('반품 배송비', method=method)
    print([h['chunk']['doc_id'] for h in r['hits']])
```

자료·질의·청킹·k를 고정하고 method만 변경

비교 · 순위 결합 · 실패 질의 · 실험 기록

실습 01 · 길이 보정



b만 바꿔 짧은 문서·긴 문서의 상대 점수 비교

실습 01 · 표현 실패

문서 용어: 환불 처리 기간

사용자 표현: 돈은 언제 돌려줘요

동의어 확장의 효과와 잘못된 확장 사례를 함께 확인

실습 02 · 후보 비교

BM25

원문 조각의 순위

TF-IDF

어휘 벡터 유사도 순위

RRF

공통 후보·순위 역수 결합

같은 자료에 대한 두 어휘 기준선 비교 · 실제 모델 기반 dense 검색은 선택


비교 · 순위 결합 · 실패 질의 · 실험 기록

실습 02 · RRF 실행

```
bm = index.search(query, 'bm25', 8)
tf = index.search(query, 'tfidf', 8)
hits = reciprocal_rank_fusion([bm, tf],
                              constant=60, k=5)
```

중복 후보가 두 번 기여하지 않는지 assertion 확인

실습 02 · constant 비교



1위와 5위 후보의 단일 기여값 · 상수 증가 시 순위 차이 완화

실습 02 · 재정렬 실행

```
hits = retrieve(query, method='rrf', k=5)['hits']  
reranked = rerank_by_coverage(query, hits)  
print([(h['chunk']['doc_id'], h['score'])  
        for h in reranked])
```

원래 순위·재정렬 점수·새 순위를 같이 보관

비교 · 순위 결합 · 실패 질의 · 실험 기록

실습 02 · 복합 질문

반품 배송비와 환불 처리 기간

단일 검색: 어떤 근거가 빠지는지 확인

분리 검색: 두 질문의 문서 ID를 각각 확인

휴식과 설정 점검

5분 · 커널·포트·Notebook 확인

개발 질의만 사용 · 확인 질의는 선택 뒤 사용

검색 실험과 선택


변경 변수·데이터·지표·실패 사례
평균값과 위험·복잡도를 함께 비교

실습 03 · 기준 설정

```
baseline = {'method': 'bm25', 'size': 120,  
            'overlap': 24, 'k': 3,  
            'expand': False, 'rerank': False}
```

기준 설정을 먼저 기록 · 개선 결과에 맞춰 기준을 바꾸지 않음

실습 03 · 변경 비교



개발 질의 8개 · 정답 문서가 있는 6개만 Recall·MRR 평균에 포함

질의별 비교 기록

항목	기록
질의	질의 ID·사용자 표현·정답 문서
변경	변수 하나·이전 값·새 값
결과	검색 순위·누락·잘못된 발췌
판단	적용·보류·다음 확인


Recall@k와 MRR@k

Recall: 필요한 문서를 얼마나 찾았는가

MRR: 첫 관련 문서가 얼마나 빨리 나왔는가

답 없는 질의: 올바른 보류율로 별도 집계

k 증가의 효과



같은 합성 개발 질의에서 k만 변경 · 비용·잡음 증가도 별도 고려

평균 결과와 실패 질의

평균 결과

전체 변화의 요약

소수의 중요한 실패가 가려질 수 있음

질의별 상세

악화·누락·권한·날짜 확인

운영 위험과 수정 위치 설명

로컬 응답 시간



이번 기기·작은 자료·모델 없는 검색 20회 · 운영 지연 보장 아님

p95의 해석

95th percentile · 95백분위 응답 시간

실습: 20회 정렬 후 $\text{ceil}(0.95 \times 20)$ 번째 값

자료 규모·기기·예열·동시 요청·모델 시간을 분리

재현 가능한 실험 기록

자료 해시 + 코드 버전 + 설정 + 질의 세트

실행 시점·측정 범위·실패 사례

외부 모델 실험은 모델명·입력 제한·예열 상태 추가

설정 선택과 확인

선택

개발 질의로 후보 비교

단순한 기준선과 비용도 검토

확인

선택 설정을 새 질의에서 확인

확인 뒤 수정하면 새 검증 필요

검색 실험실 · 평가 화면

120

24

검색 문서 수 (k)

기준 날짜

3

2026. 09. 29.

☒ 동의어 확장

☐ 규칙 재정렬

TF-IDF는 학습된 임베딩이 아닙니다. 규칙 재정렬은 신경망 reranker가 아닙니다. 역할 선택은 수업용 모의 설정이며 인증 기능이 없습니다.

검색 실행

16개 질의 평가

결과 JSON 저장

완료 · JSON 저장 가능

03 관찰 기록

한 번에 설정 하나만 변경합니다. 어떤 질의의 근거와 순위가 달라졌는지 설명합니다.

```
{  "answerable_count": 13,  "no_answer_count": 3,  "recall": 1,  "mrr": 1,  "correct_abstention": 1}
```

질의	검색 문서	Recall	MRR	보류
Q01 상품 반품 기간	D01, D03, D02	1.00	1.00	아니오
Q02 단순 번심 반품 배송비	D02, D05, D01	1.00	1.00	아니오
Q03 상품 크기 교환 품질	D04, D16, D01	1.00	1.00	아니오
Q04 돈은 언제 돌려줘요	D03, D10	1.00	1.00	예

01 · 검색 지표

정답 문서 회수율과
첫 관련 문서의 순위

02 · 답변 보류

답이 있는 질의와 없는 질의를
분리해서 확인

같은 질의로 BM25·TF-IDF·RRF 비교 · 보고서 JSON과 실패 질의 보관
실제 로컬 실행 화면 · 합성 자료 · 규칙 재정렬

비교 · 순위 결합 · 실패 질의 · 실험 기록

검색 실험실 실행

```
python -m uvicorn week05.lab.search05.main:app \
  --host 127.0.0.1 --port 8005
```

브라우저 <http://127.0.0.1:8005> · JSON 저장으로 실험 기록 보관


실습 04 · API 검증

TestClient로 health·검색 요청 확인

빈 질문·잘못된 overlap·미허용 role → HTTP 422

프로세스 내 테스트와 실제 네트워크 테스트 구분

자기 서비스 자료 적용



학생 연락처·실제 내부 자료·API 키를 공개 저장소에 넣지 않음

글쓰기 개선 서비스 예시



서론·본론1·본론2·결론 분리 · 구조·근거·유창성·이해도 별도 평가

비교 · 순위 결합 · 실패 질의 · 실험 기록

글쓰기 평가 기준의 분리

평가 항목	검토
구조	서론·본론 1·본론 2·결론의 역할
논증	주장 1·2 각각의 근거·연결
유창성	문장 연결·표현 명료성
이해도	주제·주장·근거 관계 설명

근거 있는 개선 피드백




키워드 유무만으로 이해도를 자동 판정하지 않음 · 사람의 검토·수정 경로

비교 · 순위 결합 · 실패 질의 · 실험 기록

8주차 기획서 제출

구분	구성·제출
아주대AI대학원	2-4인 자율 팀 · 팀 지원 URL 등록 · LMS 제출
군산대·국립창원대 등	개인 기획서 · 이메일 제출
공통	10.23 온라인 제출·평가 · 실시간 수업·중간고사 없음
형식	HTML·Word·PDF·PPT 자유 · 열리는 링크·파일 확인

기획서 제출 구성



형식은 자유 · 시안·영상은 선택 · 중복 제출과 유료 도구 사용 불필요

비교 · 순위 결합 · 실패 질의 · 실험 기록

세 관점의 피드백

관점	검토 질문
대표·사업	누구의 어떤 문제인가 · 대안 대비 가치가 있는가
UX 디자이너	사용 흐름이 이해되는가 · 실패·보류·수정이 가능한가
개발자	데이터·권한·구현 범위·평가·운영이 가능한가

UX · User Experience · 사용자 경험

비교 · 순위 결합 · 실패 질의 · 실험 기록

프로젝트 아이디어 예시

글쓰기 코치

구조·논증·피드백

개발 지원 Agent

도구 권한·실행 승인

업무 지식 검색

버전·출처·보류

리서치 보조

원출처·근거 비교

리서치와 프로토타입 도구

목적	선택 도구·확인
자료 조사	Gemini Deep Research · 원출처 재확인
코드·시안	Codex / Claude Code · 실제 실행·오류 확인
디자인	Figma 또는 HTML · 핵심 흐름과 실패 상태
데모	60-120초 권장 · 합성 자료·동작 범위 명시

과제 02 피드백 기준

01	재현	Notebook Restart 후 Run All
02	분석	개선·악화·보류 사례 설명
03	연결	평가 조건과 PRD 요구사항 일치

6주차 연결

데이터 설계와 모델 개선의 선택

10.09 한글날 · 실시간 강의 대신 녹화영상 업로드

참고 자료와 실행 위치

Stanford IR · RRF 원 논문 · Ollama 공식 문서

[week05/lab/notebooks](#) · [week05/lab/README.md](#)

과제 02 · 8주차 기획서 HTML