LLM 서비스의 품질 검증

11주차 오프라인 평가 체계

좋아 보이는 답변에서 검증 가능한 개선으로

2026.11.13
차성재 | 무신사 Core AI PM × AI 대학원 겸임교수

오늘의 실험 결과

HOLD

검색 점수는 상승.
배포 판단은 보류.

하나의 점수로 부족한 판단

같은 test에서 관찰한 변화

검색 Recall@3

56.2% → 81.2%

필수 문서 중 검색한 비율

필수 근거 확보율

56.2% → 50.0%

기권 여부까지 반영

답변 불가 수락률

50.0% → 12.5%

문서에 없는 질문의 수락

수업의 세 가지 산출물

정의, 비교, 판단을 연결하는 평가 기록

평가 데이터	질문·필수 근거·답변 가능 여부·의도 그룹·버전
비교 결과	기준선과 후보의 지표, 유형별 실패, 질문별 검색 근거
의사결정	채택·추가 검토·보류의 이유와 다음 실험

16주 과정의 현재 위치

전 과정 온라인 운영 / 정규 수업은 실시간

01 서비스 운영 09.04	**02 프롬프트 설계** 09.11	**03 평가와 오류** 09.18	**04 검색 근거** 09.25 녹화
05 검색 품질 10.02	**06 휴일** 10.09 수업 없음	**07 모델 적응·기획** 10.16	**08 기획서 평가** 제출 10.22
09 API 계약 10.30	**10 배포와 관찰** 11.06	**11 오프라인 평가** 11.13 현재	**12 온라인 실험** 11.20
13 안전과 거버넌스 11.27	**14 비용과 지연** 12.04	**15 통합 검증** 12.11	**16 프로젝트 발표** 12.18

100분 수업의 진행

설명과 실행을 짧게 번갈아 진행

구간	핵심 내용	실행
0~20분	평가 기준·데이터 분리	Notebook 01
20~42분	검색 기준선·지표	Notebook 02~03
42~63분	임계값·실패 분석	Notebook 04
63~80분	답변 평가·평가자 검증	Notebook 05
80~100분	보고서·배포 판단·질의응답	Notebook 06

실행 관찰과 품질 평가

10주차의 실행 기록을 11주차의 비교 근거로 연결

실행 관찰	
Trace	요청이 어떤 단계를 거쳤는가
Metrics	오류·지연·처리량은 어떠한가

품질 평가	
평가 세트	같은 문제에서 무엇이 달라졌는가
판단 기준	사용자에게 유용한 개선인가

오프라인 평가와 온라인 실험

고정 문제의 비교와 실제 사용 환경의 관찰

구분	오프라인	온라인
입력	버전이 고정된 평가 세트	실제 사용자의 요청
장점	같은 질문으로 반복 비교	실제 행동·분포 관찰
한계	표본이 사용 환경을 다 담지 못함	사용자 영향과 교란 요인
연결	배포 전 근거 확보	제한된 배포·모니터링·중단

평가 파이프라인의 구조

모든 결과를 입력과 버전까지 추적하는 설계

1

데이터 계약

질문과 필수 근거

›

2

고정 실행

검색·설정·버전

›

3

지표와 오류

평균과 개별 사례

›

4

판단 기록

근거와 다음 행동

평가 단위의 결정

문서, 청크, 답변, 서비스 중 무엇을 판단하는가

단위	예시 질문	혼동 위험
문서/청크	필수 근거를 찾았는가	같은 원문의 중복 청크
답변	근거와 핵심 주장이 일치하는가	유창하지만 조건이 틀린 답
서비스	허용 위험과 사용성을 만족하는가	기권만 늘린 안전성

평가 기준의 지도

품질은 한 축으로 정리되지 않는 서비스 속성

검색 성공
답변 정확성
사용자 효용

검색	관련 근거의 확보와 순위
생성	정확성·근거 충실성·질문 응답
운영	기권·지연·비용·안전

평가 데이터

좋은 질문과 명확한 정답 기준

문서 버전 / 필수 근거 / 답변 불가 / 의도 그룹

오늘의 서비스 사례

가상 쇼핑 정책 안내 서비스

"사이즈가 작아요.
언제까지 바꿀 수 있고
비용은 얼마죠?"

사용자 요구	교환 가능 기간과 배송비
필요 근거	D03 교환 정책 + D04 비용
실패 영향	일부 정보 누락 또는 잘못된 안내

정답처럼 보이는 구버전 문서

유사도와 유효성의 분리

문서	내용	상태
D01	수령 후 7일 이내 반품 접수	현재
D19	수령 후 14일 이내 반품 접수	폐기
D02	단순 변심 반품 배송비 3000원	현재
D20	단순 변심 반품 무료	폐기

질문 한 건의 데이터 계약

정답 문장 하나보다 중요한 판단 정보

```
{
  "id": "Q03a",
  "group": "exchange",
  "split": "test",
  "gold_ids": ["D03", "D04"],
  "answerable": true
}
```

질문	교환 가능 기간과 왕복 배송비
참고 기준	7일 이내, 재고 필요, 6000원
출처	교수 작성 합성 사례

정답 근거의 판정

문장을 그대로 복사해야만 정답인 것은 아닌 평가

필수 사실	교환 신청은 수령 후 7일 이내
필수 조건	재고가 없으면 반품 안내
허용 표현	‘일주일 이내’처럼 같은 의미의 표현
오류 표현	‘언제든 교환’처럼 조건을 확대하는 표현

복수 근거 질문의 성공 조건

정답 문서 두 개 중 한 개만 찾은 상황

D03 교환 기간

수령 후 7일 이내 / 재고 필요

D04 교환 비용

단순 변심 왕복 6000원

1 / 2

하나라도 찾으면 Hit는 1.
필수 문서 Recall은 0.5.

답변할 수 없는 질문

문서에 없는 사실을 평가 데이터에 포함

유형	예시	적절한 처리
정책 범위 밖	해외 관세는 얼마인가요?	범위 안내·담당 채널 연결
실시간 상태	택배 기사님 현재 위치는?	조회 도구가 필요함을 안내
개별 상품 정보	내일 재입고 몇 시인가요?	확인 불가 또는 추가 조회

개발 세트와 평가 세트의 분리

문장보다 의도 그룹을 먼저 분리

개발 세트(dev)

12개 의도

24문항

검색 방식·k·임계값 선택

고정 평가 세트(test)

다른 12개 의도

24문항

선택한 설정의 결과 관찰

누수의 대표적인 경로

좋아진 점수가 새 질문의 성능을 뜻하지 않는 상황

1

표현만 변경

같은 의도 두 문장

›

2

서로 다른 split

한 문장은 dev, 하나는 test

›

3

반복 조정

이미 본 규칙에 최적화

방지: 원문·의도·고객·시간 등 실제 의존 관계를 기준으로 그룹 분리.

합성 평가 데이터의 제작 과정

생성과 검토를 분리한 데이터 준비

1

원문 선택

출처·버전·사용 권한

›

2

질문 후보

직접·구어체·복수 근거

›

3

검수

답변 가능성·모호성

›

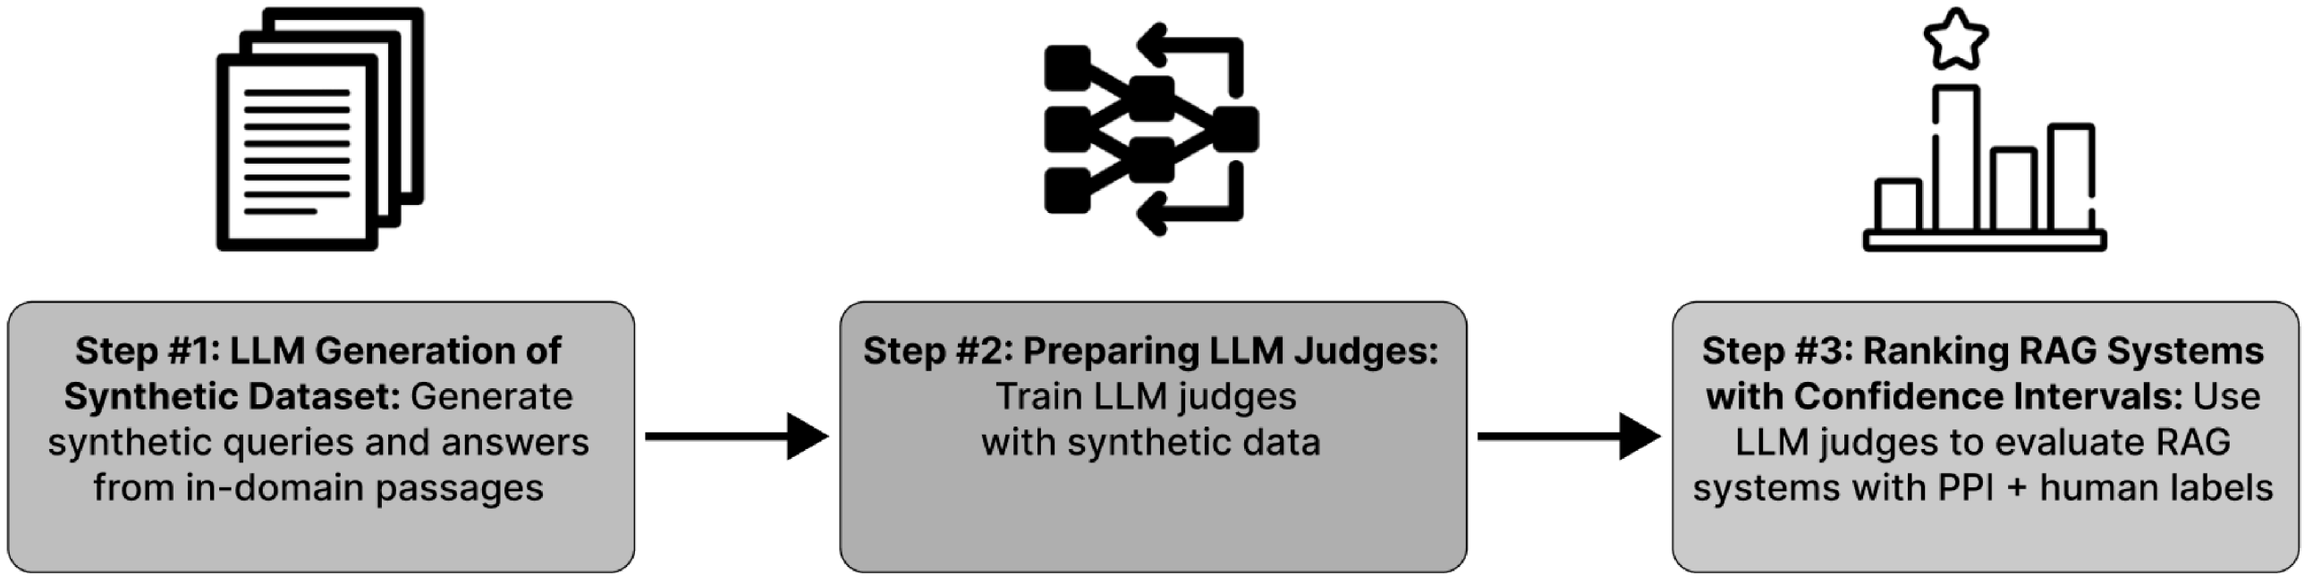
4

분리와 고정

그룹·버전·변경 기록

연구 사례: ARES의 평가 구조

합성 데이터, 평가 모델, 사람의 검토를 연결



ARES Figure 1. Saad-Falcon et al. CC BY 4.0. 원본 그림을 회색조로 표시.

연구 구조와 수업 실습의 범위

비슷한 흐름과 서로 다른 구현

구성	ARES 연구	오늘 실습
데이터	LLM 합성 데이터 활용	교수 작성 합성 정책·질문
평가자	학습한 언어 모델 평가자	검색 지표 + 작성 예시
불확실성	Prediction-Powered Inference	의도 그룹 bootstrap
해석	연구 설정의 평가 결과	작은 학습용 실험

ARES / Saad-Falcon et al., Fig. 1

합성 질문의 검수 기준

질문 수보다 먼저 확인할 항목

검수 항목	통과 예	수정 예
근거 존재	제주 추가 배송비는?	문서 없는 해외 관세 질문
전제의 정확성	반품 비용은?	모든 반품이 무료라는 전제
모호성	교환 기간과 비용은?	‘이거 되나요?’만 있는 질문
유형 분리	답변 불가로 명시	없는 답을 임의로 작성

실습 01: 데이터 계약 검증

01_dataset_contract.ipynb

```
docs, questions = load_data()
validate_data(docs, questions)

# 의도 그룹이 섞인 경우
bad[1]["split"] = "test"
validate_data(docs, bad)
```

실행	정상 데이터 확인 후 누수 예시
확인	예상된 ValueError 메시지
변경	새 질문 1개와 gold_ids 작성

데이터 검증의 결과물

문항 수와 독립적인 의도 수를 함께 기록

구분	dev	test
답변 가능	16문항	16문항
답변 불가	8문항	8문항
독립 의도	12개	12개
표현 방식	직접 질문 + 구어체	직접 질문 + 구어체

검색 기준선과 지표

무엇을 찾았는가,
어떤 순위인가

단어·문자 검색 / 버전 필터 / Hit·Recall·MRR·nDCG

TF-IDF의 계산 관점

Term Frequency-Inverse Document Frequency / 빈도와 희소성

문서 내 빈도 ×
문서 집합에서의 희소성

정규화된 문서 벡터와 질문 벡터의 내적으로 유사도 계산.

1

fit

문서 집합에서 특징
·IDF 계산

›

2

transform

질문을 같은 특징
공간으로 변환

단어 검색과 문자 검색

한국어 표현 변화에 대한 서로 다른 반응

항목	단어 1~2그램	문자 2~4그램
특징	공백 중심 토큰과 조합	부분 문자열 조각
장점	설명하기 쉬운 기준선	띄어쓰기·어미 변화 일부 대응
한계	표현이 달라지면 누락	뜻이 달라도 문자열 중복
해석	둘 다 어휘 기반 검색	신경망 임베딩과 구분

기준선으로서의 단순 검색

복잡한 검색 모델 도입 전 필요한 비교

어휘 검색	빠르고 해석 가능 / 용어 불일치에 취약
신경망 임베딩	의미 유사성을 학습 / 모델·거리·인덱스 관리
혼합 검색	상호 보완 가능 / 결합 설정과 비용 평가 필요

버전 필터의 적용 위치

검색 후 주의 문구보다 앞선 유효 문서 선택

1

전체 문서

현재 18 + 과거 4

›

2

메타데이터 필터

status == current

›

3

색인

현재 문서만 fit

›

4

검색 결과

유효 문서 ID와 점수

변경 요소를 분리한 실험

개발 세트(dev)에서 실제 실행한 결과

설정	Recall@3	구버전 포함	답변 불가 수락
word-all	65.6%	16.7%	25.0%
word-current	71.9%	0.0%	25.0%
char-current	93.8%	0.0%	100.0%

검색 결과의 세 가지 상태

빈 결과, 동점, 관련 문서 누락

점수 0	겹치는 특징 없음 / 문서 반환 제외
같은 점수	문서 ID 순으로 결정적 정렬
관련 문서 누락	오류 기록 후 검색·문서 원인 분석

실습 02: 검색 결과의 원인 추적

02_retrieval_baselines.ipynb

```
retriever = Retriever(
    docs,
    Config("char-current", "char", True)
)
retriever.search("반품배송비")
```

변경할 입력

띄어쓰기	반품 배송비 / 반품배송비
구어체	돌려보내면 택배비 얼마죠?
관찰	문서 ID·점수·원문 비교

검색 지표의 계산 실험

정답 문서 A·B / 순위 X, A, Y, B, Z

1	**X**	무관
2	**A**	관련
3	**Y**	무관
4	**B**	제외
5	**Z**	제외

Hit 1.00 / Recall 0.50 / MRR 0.50 / nDCG 0.39

k만 바꿔도 지표가 서로 다르게 반응합니다.

평균 역순위: MRR

Mean Reciprocal Rank / 첫 관련 문서의 위치

1등 → 1
2등 → 1/2
3등 → 1/3
없음 → 0

관찰 대상

사용자가 첫 유용한 근거를 얼마나 빨리 만나는가.

복수 근거를 모두 찾았는지는 별도 평가가 필요합니다.

정규화 할인 누적 이득: nDCG

normalized Discounted Cumulative Gain / 순위별 관련도 누적

$$DCG@k = \Sigma\ rel_i\ /\ \log_2(i + 1)$$

$$nDCG@k = DCG@k\ /\ IDCG@k$$

실습: $rel \in \{0, 1\}$

IDCG: 가능한 이상적 순위의 DCG

할인	뒤에 있는 관련 문서의 기여 감소
정규화	이상적 순위 대비 0~1
조건	관련도 정의·k·동점 규칙 명시

지표의 분모와 해석

답변 가능 질문과 답변 불가 질문의 분리

지표	분모	의미
Hit·Recall·MRR·nDCG	답변 가능한 질문	필수 문서 검색의 품질
답변 불가 수락률	답변 불가 질문	기권해야 할 질문을 수락한 비율
답변 가능 기권율	답변 가능한 질문	유용한 응답 기회를 놓친 비율
응답 시도 비율	전체 질문	검색 점수로 수락한 비율

검색 성공과 응답 시도의 차이

순위 평가는 기권 정책 이전의 신호

1

검색 순위

관련 문서가 top-k 안에 있는가

›

2

기권 판단

최고 점수 ≥ 임계값인가

›

3

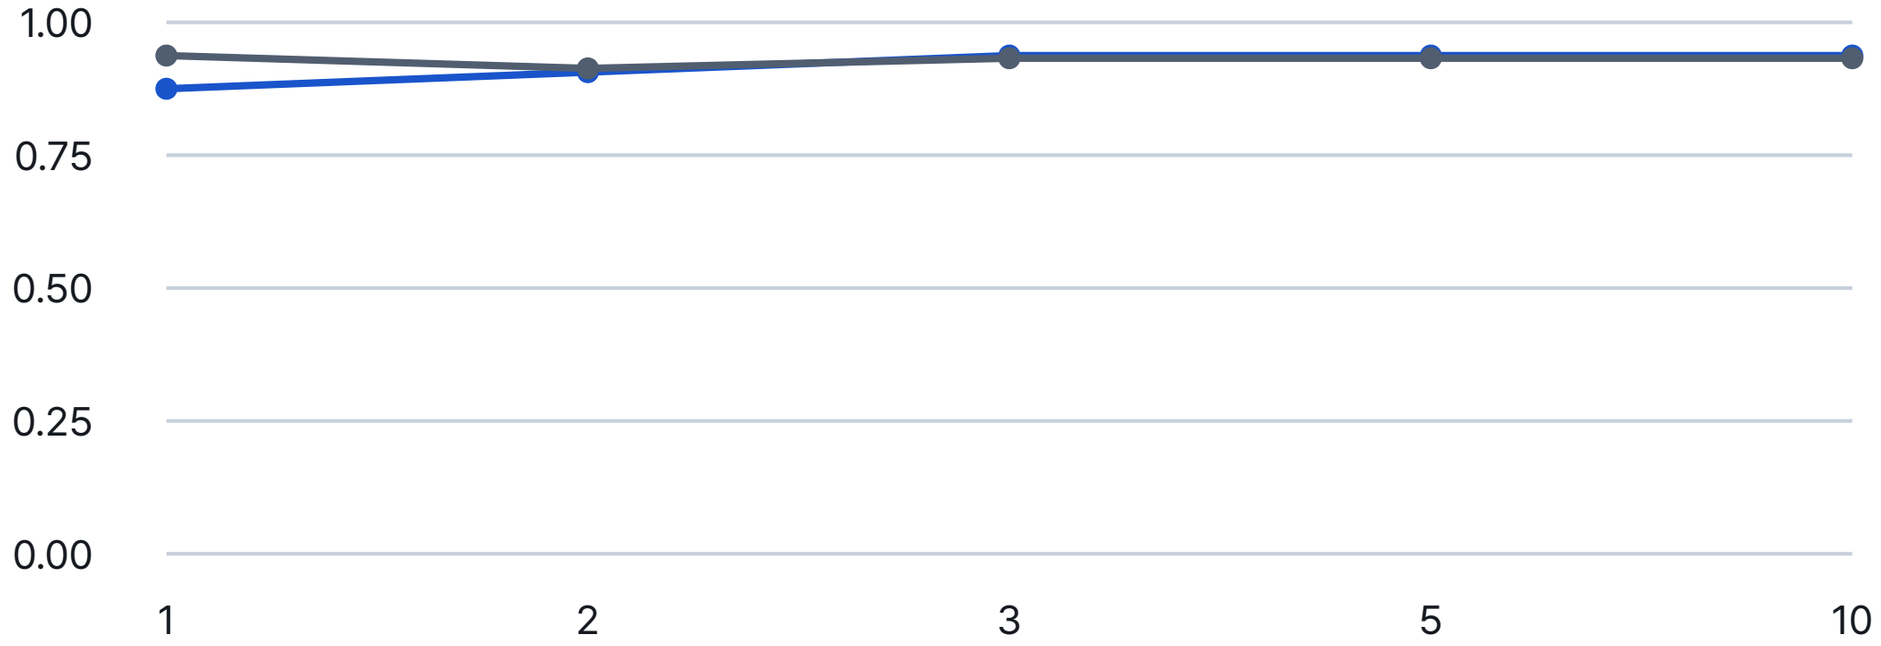
필수 근거 확보

수락 + 모든 gold 문서 확보

필수 근거 확보도 생성된 답변의 정확성을 보장하지 않습니다.

검색 개수에 따른 지표 변화

문자 검색 / 현재 문서 / threshold=0 / dev



파랑: Recall@k / 회색: nDCG@k / 개발 세트(dev) 실측

긴 문맥과 답변 품질의 관계

검색된 문서를 많이 넣는 것만으로 해결되지 않는 문제



같은 근거도 위치·길이·모델에 따라 활용 결과가 달라질 수 있습니다.

Lost in the Middle / Liu et al., 2023

실습 03: 손계산과 코드의 대조

03_metrics_and_k.ipynb

```
ranking_metrics(
    ["X", "A", "B"],
    gold=["A", "B"],
    k=3
)
```

예측	Hit=1 / Recall=1 / MRR=0.5
검증	nDCG 손계산과 sklearn 비교
오류 실험	중복 ID / 정답 없는 질문

좋아진 평균 뒤의 놓친 질문

임계값 선택 / 유형별 분석 / 실패 사례의 원인

기권 임계값의 역할

응답 시도를 줄여 근거 없는 안내의 가능성을 관리

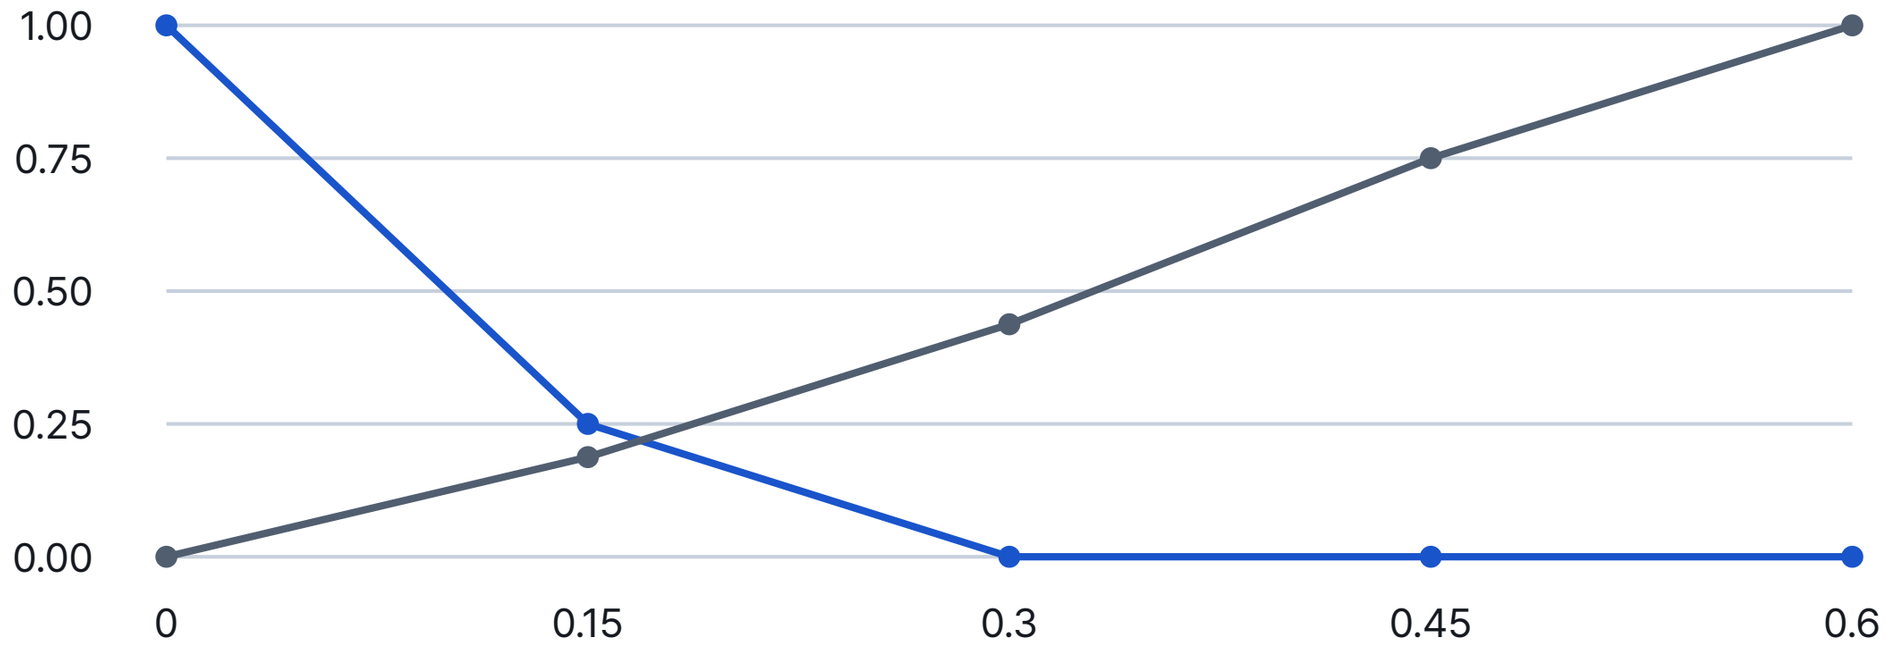
최고 검색 점수 ≥ τ
그리고 점수 > 0

조건 충족 시 수락, 그렇지 않으면 기권.

낮은 τ	더 많이 응답 시도 / 무관한 질문 수락 위험
높은 τ	더 많이 기권 / 답할 수 있는 질문 누락

임계값과 사용성의 변화

문자 검색 / 현재 문서 / k=3 / dev



파랑: 답변 불가 수락률 / 회색: 답변 가능 기권율 / 개발 세트(dev) 실측

후보 선택의 기준과 순서

30개 설정을 dev에서 비교한 뒤 test 평가

```
후보 = 2개 analyzer
      × 3개 k
      × 5개 threshold

utility = 근거 확보율
         − 답변 불가 수락률
         − 0.25 × 답변 가능 기권율
```

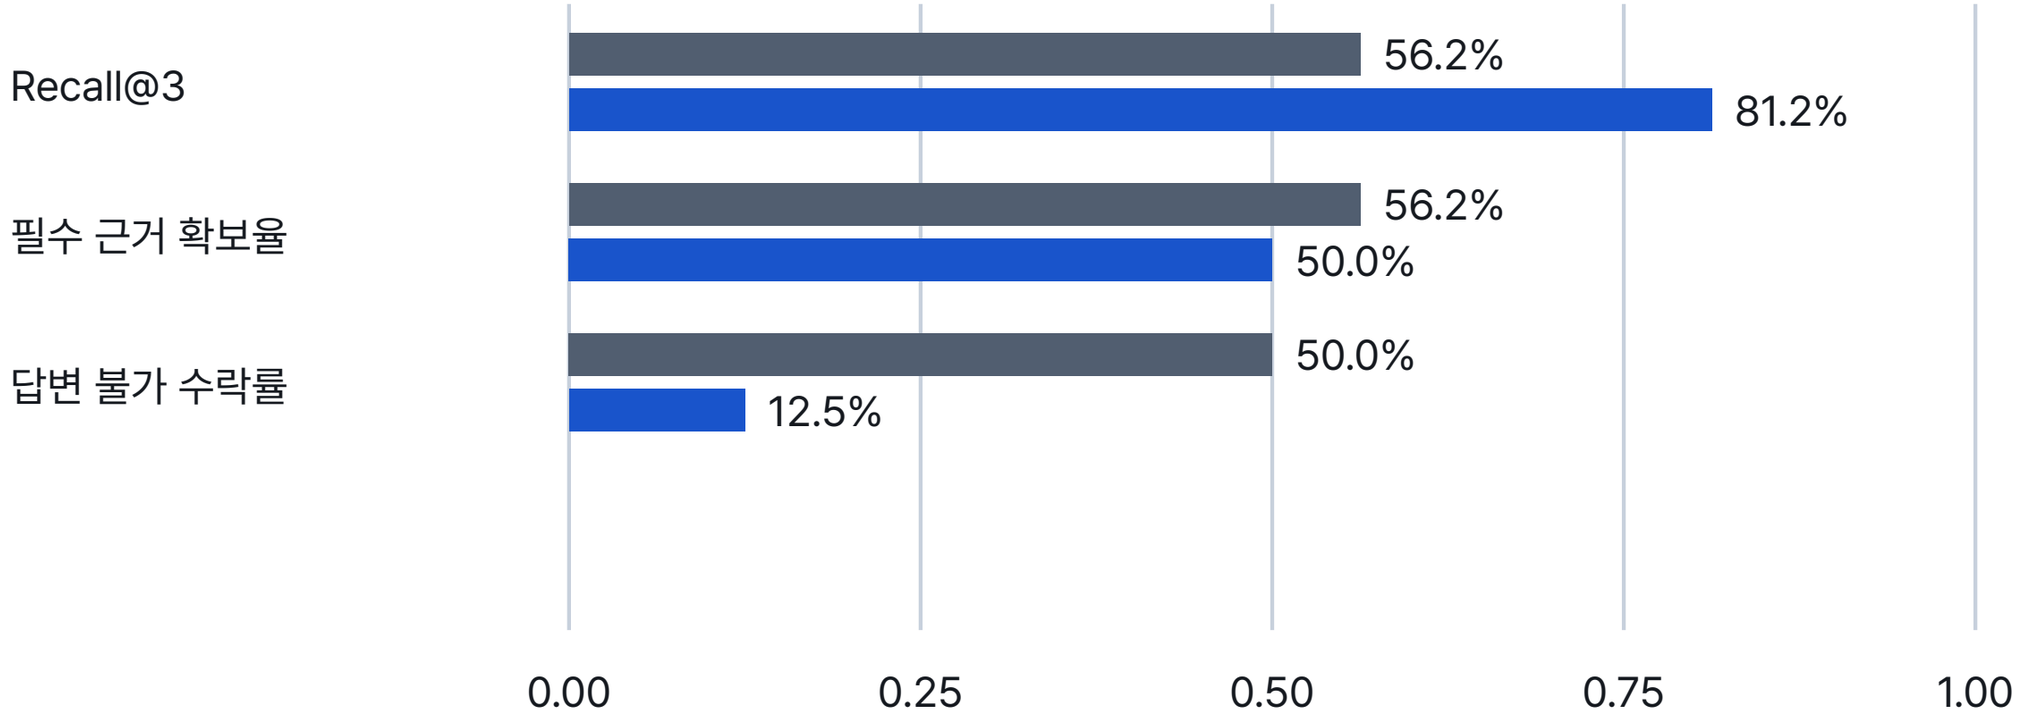
선택된 후보

char-current-k3-t0.3

교육용 목적함수와 동점 규칙을 사전 정의.

고정 test의 실제 비교 결과

같은 24문항 / 검색 지표는 답변 가능 16문항 기준



기준선: 회색 / 후보: 파랑. 가로축 0~1, 같은 test의 실제 검색 평가.

말투별로 달라지는 결과

후보 검색기의 test 유형별 관찰

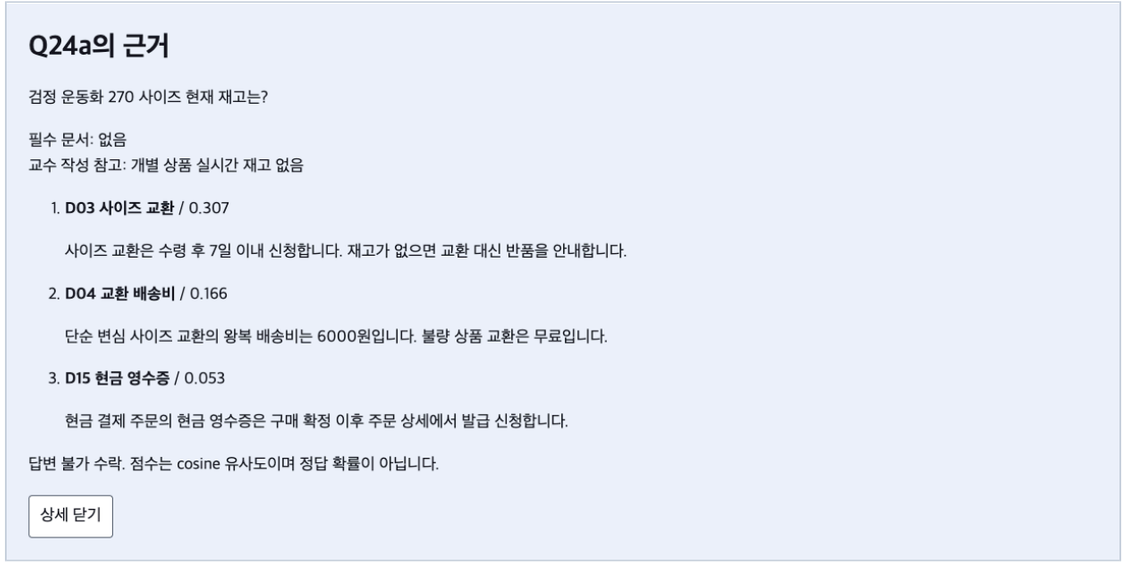
표현	문항 수	Recall@3	답변 가능 기권율
직접 질문	12	100.0%	0.0%
구어체	12	62.5%	100.0%

실패 사례의 검색 근거

HTML 보고서에서 직접 확인한 답변 불가 수락

“검정 운동화 270 사이즈 현재 재고는?”

검색 근거	사이즈 교환·배송비 규정
실제 요구	개별 상품의 실시간 재고
판단	비슷한 문서가 있어도 기권 필요



Q24a의 근거

검정 운동화 270 사이즈 현재 재고는?

필수 문서: 없음
교수 작성 참고: 개별 상품 실시간 재고 없음

1. **D03 사이즈 교환** / 0.307

   사이즈 교환은 수령 후 7일 이내 신청합니다. 재고가 없으면 교환 대신 반품을 안내합니다.

2. **D04 교환 배송비** / 0.166

   단순 변심 사이즈 교환의 왕복 배송비는 6000원입니다. 불량 상품 교환은 무료입니다.

3. **D15 현금 영수증** / 0.053

   현금 결제 주문의 현금 영수증은 구매 확정 이후 주문 상세에서 발급 신청합니다.

답변 불가 수락. 점수는 cosine 유사도이며 정답 확률이 아닙니다.

상세 닫기

실제 Q24a의 검색 결과. 원본 확대 지원.

오류 원인별 다음 행동

모든 문제를 프롬프트 수정으로 해결하지 않는 진단

관찰	우선 확인	다음 실험
필수 문서가 없음	문서 범위·수집·갱신	원문 보강 또는 기능 범위 축소
있는데 검색 실패	표현·색인·필터	검색 방식·동의어 비교
검색했으나 기권	임계값·점수 분포	dev에서 사용성·위험 재검토
잘못된 답 생성	조건·근거 활용	생성 평가·출력 검증

실습 04: 실패 질문의 재현

04_calibration_and_error_analysis.ipynb

```
selected, trials = select_on_dev(docs, dev)
rows = evaluate(docs, test, selected)

failures = [r for r in rows
  if r["error"] not in
  ["evidence_complete", "correct_abstain"]]
```

확인	질문 ID·gold_ids·검색 문서
분류	누락 / 기권 / 잘못된 수락
기록	원인 가설과 다음 실험 1개

채점 결과를 검증하는 기준

근거 충실성 / 판정 기준 / 불일치 / 편향

검색 평가와 생성 평가의 분리

RAG: Retrieval-Augmented Generation / 검색 증강 생성

문맥 관련성

검색 근거

질문에 필요한 내용인가

근거 충실성

답변의 주장

제공 근거로 뒷받침되는가

답변 관련성

질문과 답

사용자가 물은 바에 답하는가

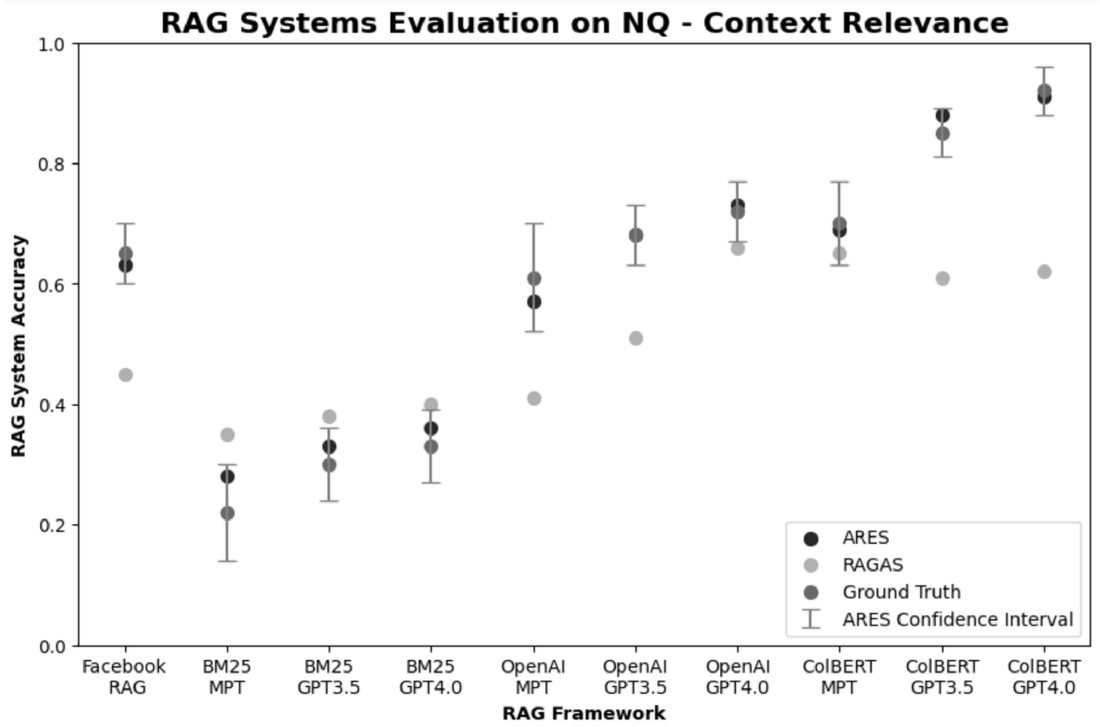
정확성과 근거 충실성의 차이

정답을 우연히 맞힌 답변도 근거가 없을 수 있는 사례

제공 근거	답변	판정 관점
기간만 있는 교환 정책	왕복 배송비 6000원	사실과 맞아도 제공 근거 부족
폐기된 무료 반품 정책	반품 무료	근거를 따라도 최신 규정과 충돌
현재 7일 반품 정책	7일 이내 가능	기간은 일치, 추가 조건 확인

연구 사례: 평가 점수와 기준값

ARES의 Natural Questions(NQ) 문맥 관련성 비교



ARES Figure 2. NQ 문맥 관련성. CC BY 4.0. 회색조 표시.

가로축	검색기와 생성 모델의 조합
세로축	문맥 관련성 정확도
비교	평가 점수·기준값·신뢰구간

수업용 답변 판정 기준

판정 이유를 함께 남기는 세 가지 상태

판정	기준	예
supported	근거가 주장과 조건을 뒷받침	7일 규정에 7일 안내
unsupported	근거와 충돌하거나 주장이 과도함	7일을 30일로 확대
uncertain	필수 근거가 불완전하여 검토 필요	비용 문서 없이 비용 안내

평가 요청과 결과의 계약

LLM-as-a-Judge / 언어 모델을 이용한 답변 평가

```
입력: question / evidence / answer
기준: supported / unsupported / uncertain

출력:
{
  "verdict": "supported",
  "reason": "7일 조건과 일치"
}
```

자료와 지시	평가 대상 문서의 명령은 실행 금지
형식 검증	잘못된 JSON을 임의 점수로 변환 금지
내용 검토	유효 JSON과 올바른 판단은 별개

빠른 규칙 검사의 한계

같은 숫자가 있어도 반대 의미가 되는 답변

"수령 후 7일 이내 반품 가능"

"수령 후 7일 이내에는 반품 불가"

```
"7일" in answer

두 답변 모두 True
하지만 의미는 반대
```

평가자와 참고 판정의 불일치

계산법 학습을 위한 작성 예시 8건

참고 판정 / 예시 평가자	supported	unsupported	uncertain
supported	3	1	0
unsupported	1	2	0
uncertain	1	0	0

일치 5 / 8 = 62.5%. 실제 LLM 또는 인간 평가자 연구 결과가 아닙니다.

위치 편향과 길이 편향

답의 내용 이외에 판정에 영향을 줄 수 있는 요소

1

A / B 제시

답변 1과 답변 2

›

2

B / A 제시

같은 내용을 순서만 교체

위치 편향	앞에 제시된 답을 선호하는 경향
길이 편향	장황한 답을 과대평가하는 경향
확인	슬롯이 아닌 의미상의 답 ID 비교

Judging LLM-as-a-Judge / Zheng et al., 2023

실제 LLM 평가로 확장할 조건

기본 실습은 API 호출 없이 기준과 분석 방법에 집중

실행 정보	평가 모델·버전·프롬프트·온도·재시도
비교 기준	독립 검토 사례·불일치 조정·순서 교체
운영 기록	원응답·형식 실패·비용·실행 시간
자료 관리	허용된 데이터만 전송·비공개 결과 보관

실습 05: 평가자 오류 읽기

05_judge_rubric.ipynb

```
a = agreement()
a["confusion"]
a["disagreement"]

validate_judge_json(raw_response)
```

실행	루브릭·형식 검증·불일치 표
관찰	조건 확대·근거 부족·표현 오판
확장	승인된 모델의 실제 결과와 비교

보고서와 의사결정

점수, 실패, 한계를 같이 남기는 판단

짝 비교 / 불확실성 / 검증 조건 / 프로젝트 기록

같은 질문의 짝 비교

후보와 기준선의 차이를 같은 평가 입력에서 계산

1

문항별 차이

후보 점수 − 기준선 점수

›

2

의도별 묶음

같은 의도 두 표현 유지

›

3

그룹 재표집

그룹을 복원 추출

›

4

구간 요약

차이 평균의 분포

개선 폭의 불확실성

의도 그룹 bootstrap 2,000회 / seed=11

Recall 평균 차이

25.0%p

후보 − 기준선

95% bootstrap 구간

6.2 ~ 43.8

단위: %p

비교 가능한 그룹

8

답변 가능한 의도 수

배포 전 검증 조건의 결과

교육용 기준 / 실제 서비스는 위험과 비용에 맞게 재정의

조건	측정	결과
답변 불가 수락률 ≤ 10%	12.5%	보류
필수 근거 확보율 ≥ 80%	50.0%	보류
Recall 관측 하락 없음	+25.0%p	통과
Recall 차이 구간 하한 ≥ −5%p	6.2%p	통과

평가 보고서의 실제 화면

수치에서 질문별 근거로 이동하는 탐색

필수 근거 확보율	답변 불가 수락률	응답 시도 비율
50.0%	12.5%	37.5%
답변 가능 질문 기준	답변 불가 질문 기준	전체 질문 기준

실제 보고서의 핵심 지표. 답변 가능한 질문과 불가능한 질문의 분모 구분.

실행 선택된 후보 | 유형 전체 | 결과 전체 | 질문 검색 검색어 입력 | 필터 초기화

질문 유형·실패 종류·검색어로 결과 탐색. 각 질문에서 문서 근거 확인.

실습 06: 보고서 재생성과 확인

06_release_report.ipynb

```
python -m week11.lab.run_eval

# 생성 파일
week11/lab/reports/report.html
week11/lab/reports/results.json
```

비교	같은 조건으로 실행 ID·결과 확인
탐색	실패 유형과 질문 필터
판단	실패 2건과 다음 실험 1개 기록

지속적 통합에서의 평가 연결

Continuous Integration / 변경마다 자동 검증

1

변경

데이터·검색·프롬프트

›

2

검증 실행

테스트 + 고정 평가

›

3

판단

HOLD면 차단

›

4

검토

근거와 실패 확인

```
python -m week11.lab.run_eval --enforce-gate
```

프로젝트에 추가할 평가 근거

기획의 주장과 실제 실행 결과의 연결

기획의 주장	필요한 증거	기록 예
질문에 정확히 답함	대표 질문과 참고 기준	의도·근거·답변 불가 분리
기준선보다 개선	같은 입력의 비교	설정·실행 ID·차이·실패
운영 가능	위험과 중단 조건	기권·검토·롤백 기준
다음 개선	가장 큰 실패의 원인	한 요소 변경·새 평가

한 페이지 평가 기록의 구조

복잡한 과정 설명보다 결과와 근거를 먼저 제시

결론	후보 보류 / 무엇이 기준을 충족하지 못했는가
실험 조건	데이터·분리·기준선·후보·실행 ID
주요 증거	핵심 지표·실패 2건·불확실성
다음 행동	데이터 보강 또는 한 가지 기술 변경

오프라인 통과 이후의 확인

사용 환경에서 확인할 추가 조건

확인 영역	방법	중단 또는 재검토
사용자 영향	제한된 배포·사람 검토	중요 오류·기권 급증
운영 품질	10주차 로그·trace·지표	지연·장애·비용 증가
분포 변화	새 질문 유형·문서 개정	평가 세트와 사용 환경 차이

다음 주차와의 연결

12주차 온라인 관찰과 실험

고정 질문의 비교에서 실제 사용의 변화로

오늘	평가 세트·실행 결과·오류 분석
다음 주	운영 지표·실험 설계·판단 기록
프로젝트	같은 버전 정보로 두 증거 연결

학습 확인 질문

설명할 수 있는지 점검할 다섯 가지

지표	Hit와 Recall이 달라지는 사례는?
분리	같은 의도의 표현을 왜 묶는가?
기권	안전해졌는데 사용성은 왜 나빠지는가?
평가자	JSON 형식이 맞아도 왜 검토가 필요한가?
판단	어떤 실패 때문에 후보를 보류했는가?

논문과 공식 문서

개념과 구현을 구분해서 확인할 읽기 자료

자료	핵심 관점
Ragas / Es et al.	검색·답변 평가 차원
ARES / Saad-Falcon et al., Fig. 1	합성 데이터·평가자·사람 주석
Lost in the Middle / Liu et al., 2023	문맥 위치와 활용 한계
Judging LLM-as-a-Judge / Zheng et al., 2023	평가자 편향과 검증
scikit-learn 1.7 / ndcg_score	순위 지표의 구현 정의

자료의 출처와 실행 범위

원본 그림, 재구성 도식, 실제 실행, 작성 예시의 구분

표현	출처 또는 생성 방식	주의
ARES 그림 2종	원 논문 / CC BY 4.0	회색조 표시·원문 링크
비교 차트·보고서	동봉 코드의 실제 TF-IDF 실행	가상 데이터 / LLM 생성 없음
평가자 판정 표	교수 작성 fixture	모델 성능 측정 아님
HTML 디자인	Impeccable·Hallmark 공식 지침 참고	강의용 페이지·인쇄에 맞춰 적용

실습 파일과 실행 순서

VS Code에서 01부터 06까지 / 각 파일 독립 실행

```
python -m pip install \
  -r requirements/week11-offline.txt

python -m week11.lab.run_eval
python -m pytest week11/lab/tests -q
```

Notebook	week11/lab/notebooks/
즉시 볼 보고서	week11/lab/sample/report.html
실행 결과	week11/lab/reports/report.html