LLM 서비스의 품질 검증

11주차 / 2026.11.13

평가 기준과 실제 응답의 검증

차성재
무신사 Core AI PM × AI 대학원 겸임교수

판단	이 변경을 배포해도 되는가
실행	검색·생성·평가·추적
결과	실패 근거와 다음 개선

16주 과정의 현재 위치

전 과정 온라인 운영 / 정규 수업은 실시간

01 서비스 운영 09.04	**02 프롬프트 설계** 09.11	**03 평가와 오류** 09.18	**04 검색 근거** 09.25 녹화
05 검색 품질 10.02	**06 휴일** 10.09 수업 없음	**07 모델 적응·기획** 10.16	**08 기획서 평가** 제출 10.22
09 API 계약 10.30	**10 배포와 관찰** 11.06	**11 오프라인 평가** 11.13 현재	**12 온라인 실험** 11.20
13 안전과 거버넌스 11.27	**14 비용과 지연** 12.04	**15 통합 검증** 12.11	**16 프로젝트 발표** 12.18

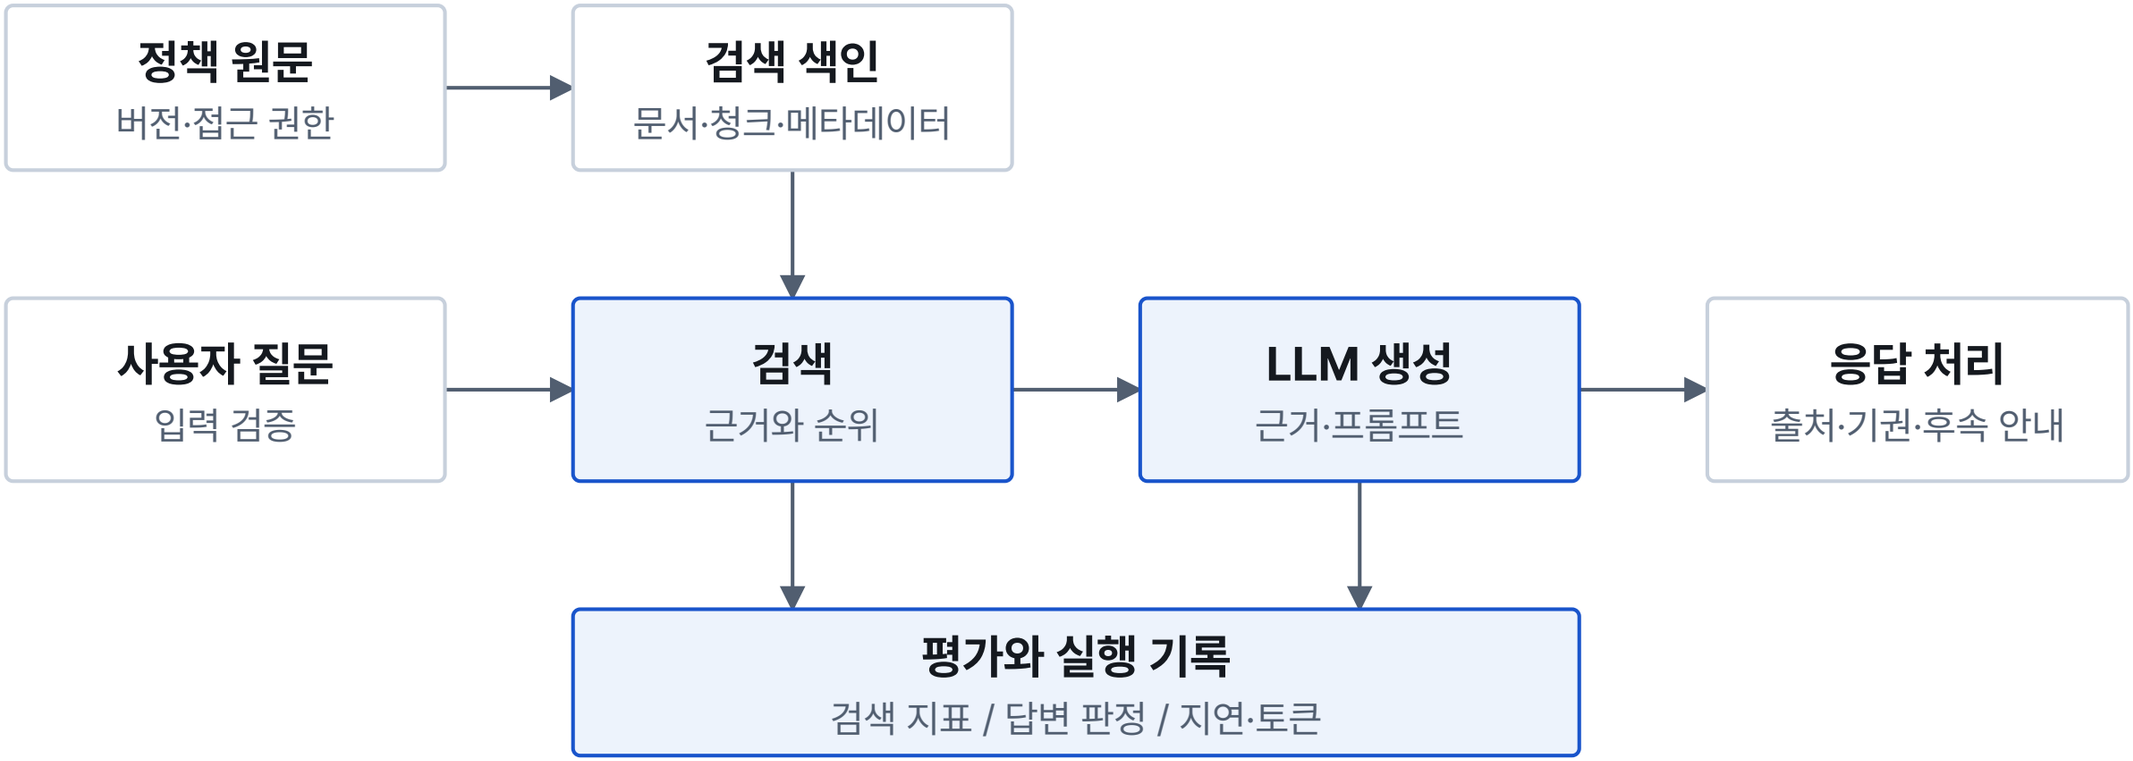
100분 수업의 진행

개념 설명과 핵심 셀 실행의 반복

시간	핵심 질문	Notebook
0~15분	어디에서 무엇을 평가할까	01 핵심 셀
15~35분	검색 개선은 어떻게 비교할까	02~04 핵심 셀
35~60분	실제 모델은 근거대로 답할까	07 실제 생성
60~80분	평가자와 실행 기록은 믿을 만한가	05 → 08 실제 평가
80~100분	어떤 근거로 배포를 결정할까	06 보고서·토론

LLM 서비스와 평가 지점

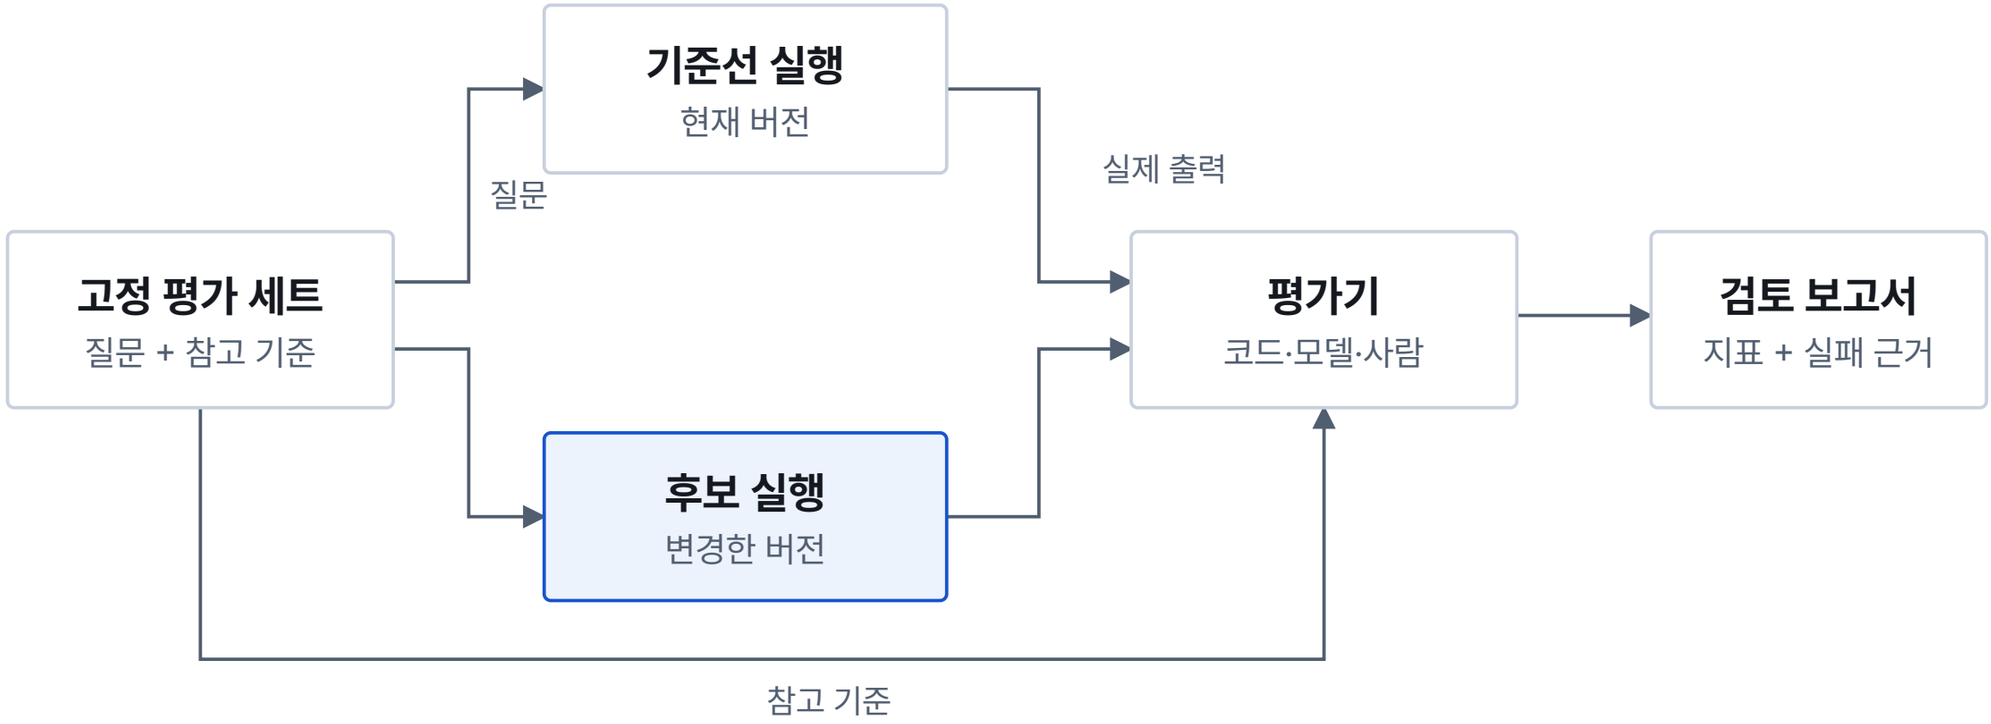
검색 증강 생성 / Retrieval-Augmented Generation



자체 구성한 참조 아키텍처. 파랑 영역: 이번 실습에서 실행·검사하는 범위.

배포 전 평가 아키텍처

같은 입력, 분리된 참고 기준, 두 버전의 비교



참고 정답은 평가기에만 전달. 생성 모델 입력에 정답을 섞지 않는 구조.

Trace와 Span의 역할

전체 요청과 내부 작업의 구분

```
Trace: 질문 한 건
├─ retrieval: 검색 문서·점수
├─ generation: 프롬프트·응답
├─ code_checks: 형식·인용 검사
└─ llm_judge: 판정·근거
```

Trace	요청 전체의 연결 기록
Span	요청 안의 작업 한 단계
원인 추적	어느 단계에서 실패했는지 확인

서비스 사례와 성공 조건

가상 쇼핑 정책 안내 서비스

"사이즈가 작아요.
언제까지 바꿀 수 있고
비용은 얼마죠?"

사용자 요구	교환 가능 기간과 배송비
필요 근거	D03 교환 정책 + D04 비용
실패 영향	일부 정보 누락 또는 잘못된 안내

질문과 참고 기준의 구조

정답 문장 하나보다 중요한 판단 정보

```
{
  "id": "Q03a",
  "group": "exchange",
  "split": "test",
  "gold_ids": ["D03", "D04"],
  "answerable": true
}
```

질문	교환 가능 기간과 왕복 배송비
참고 기준	7일 이내, 재고 필요, 6000원
출처	교수 작성 합성 사례

문서 버전과 정답 근거

유사도와 유효성의 분리

문서	내용	상태
D01	수령 후 7일 이내 반품 접수	현재
D19	수령 후 14일 이내 반품 접수	폐기
D02	단순 변심 반품 배송비 3000원	현재
D20	단순 변심 반품 무료	폐기

답변할 수 없는 질문

문서에 없는 사실을 평가 데이터에 포함

유형	예시	적절한 처리
정책 범위 밖	해외 관세는 얼마인가요?	범위 안내·담당 채널 연결
실시간 상태	택배 기사님 현재 위치는?	조회 도구가 필요함을 안내
개별 상품 정보	내일 재입고 몇 시인가요?	확인 불가 또는 추가 조회

개발 세트와 평가 세트의 분리

문장보다 의도 그룹을 먼저 분리

개발 세트(dev)

12개 의도

24문항

검색 방식·k·임계값 선택

고정 평가 세트(test)

다른 12개 의도

24문항

선택한 설정의 결과 관찰

실습 01: 데이터 계약 검증

01_dataset_contract.ipynb

```
문서 22개 = 현재 18 + 과거 4
질문 48개 = dev 24 + test 24
각 세트: 12개 의도
```

실행	첫 환경 셀 → 1~5단계
확인	없는 문서와 그룹 누수 차단
기록	복수 근거 질문 Q03a

실습 01 실행 순서·확인 결과

단어 검색과 문자 검색

TF-IDF: Term Frequency~Inverse Document Frequency / 단어 빈도와 문서 희소성

항목	단어 1~2그램	문자 2~4그램
특징	공백 중심 토큰과 조합	부분 문자열 조각
장점	설명하기 쉬운 기준선	띄어쓰기·어미 변화 일부 대응
한계	표현이 달라지면 누락	뜻이 달라도 문자열 중복
해석	둘 다 어휘 기반 검색	신경망 임베딩과 구분

한 요소씩 바꾼 비교

개발 세트(dev) / 기권 임계값 0

설정	Recall@3	구버전 포함	답변 불가 수락
word-all	65.6%	16.7%	25.0%
word-current	71.9%	0.0%	25.0%
char-current	93.8%	0.0%	100.0%

복수 근거 질문의 성공 조건

정답 문서 두 개 중 한 개만 찾은 상황

D03 교환 기간

수령 후 7일 이내 / 재고 필요

D04 교환 비용

단순 변심 왕복 6000원

1 / 2

하나라도 찾으면 Hit는 1.
필수 문서 Recall은 0.5.

검색 개수와 지표의 변화

정답 문서 A·B / 순위 X, A, Y, B, Z

1	**X**	무관
2	**A**	관련
3	**Y**	무관
4	**B**	제외
5	**Z**	제외

Hit 1.00 / Recall 0.50 / MRR 0.50 / nDCG 0.39

k만 바꿔도 지표가 서로 다르게 반응합니다.

MRR과 nDCG의 차이

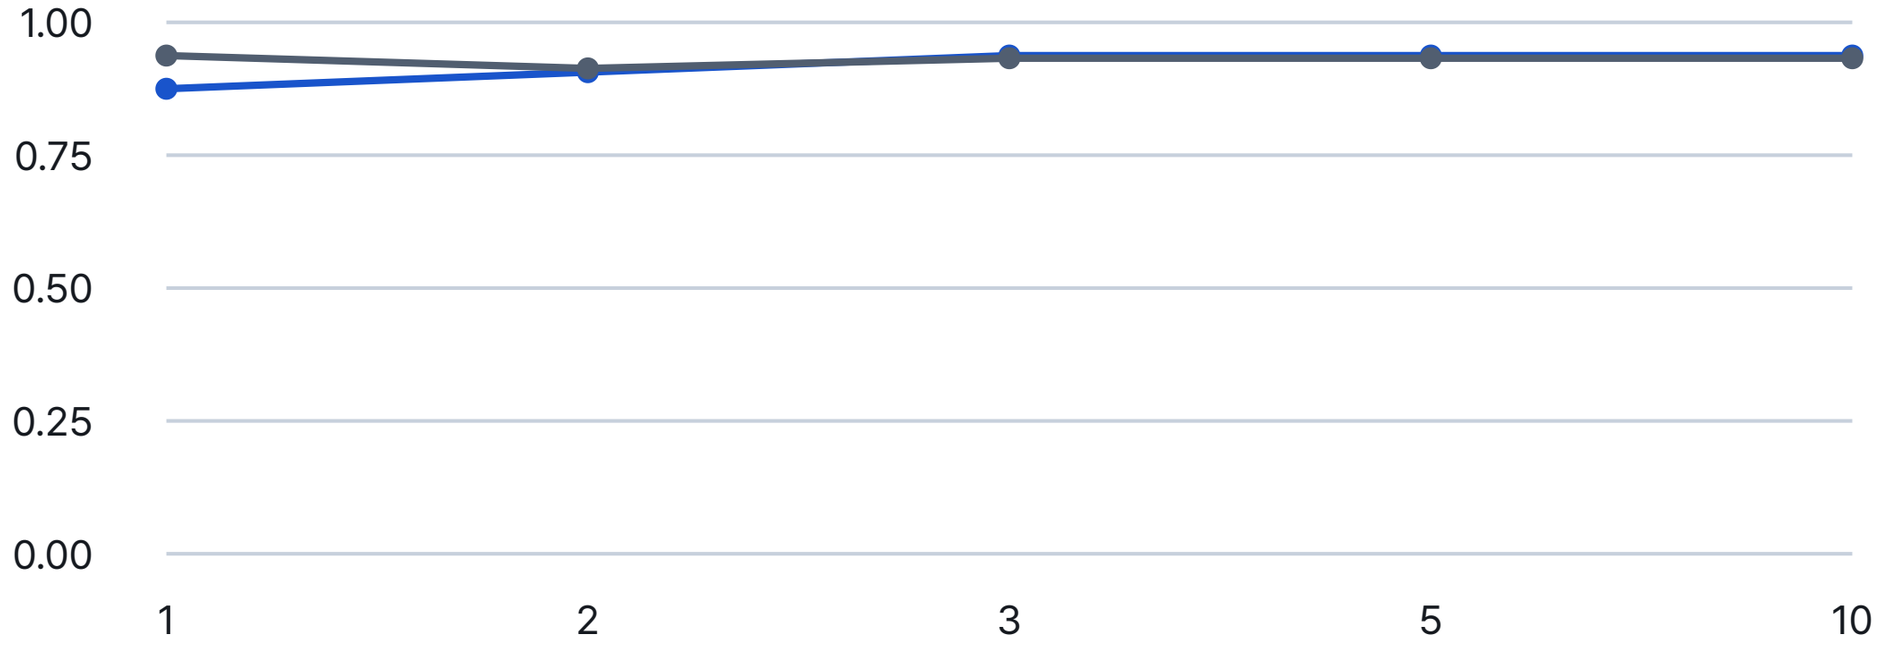
첫 정답의 순위와 여러 근거의 순위

지표	관찰 대상	예: [X, A, B], 정답 A·B
MRR	첫 정답 순위의 역수 평균	첫 정답 2위 → 0.5
nDCG	여러 관련 문서의 순위 할인	이진 관련도 기준 약 0.6934

MRR: Mean Reciprocal Rank
nDCG: normalized Discounted Cumulative Gain

검색 개수에 따른 지표 변화

문자 검색 / 현재 문서 / threshold=0 / dev



파랑: Recall@k / 회색: nDCG@k / 개발 세트(dev) 실측

긴 문맥과 답변 품질의 관계

검색된 문서를 많이 넣는 것만으로 해결되지 않는 문제



같은 근거도 위치·길이·모델에 따라 활용 결과가 달라질 수 있습니다.

Lost in the Middle / Liu et al., 2023

검색 실습의 확인 지점

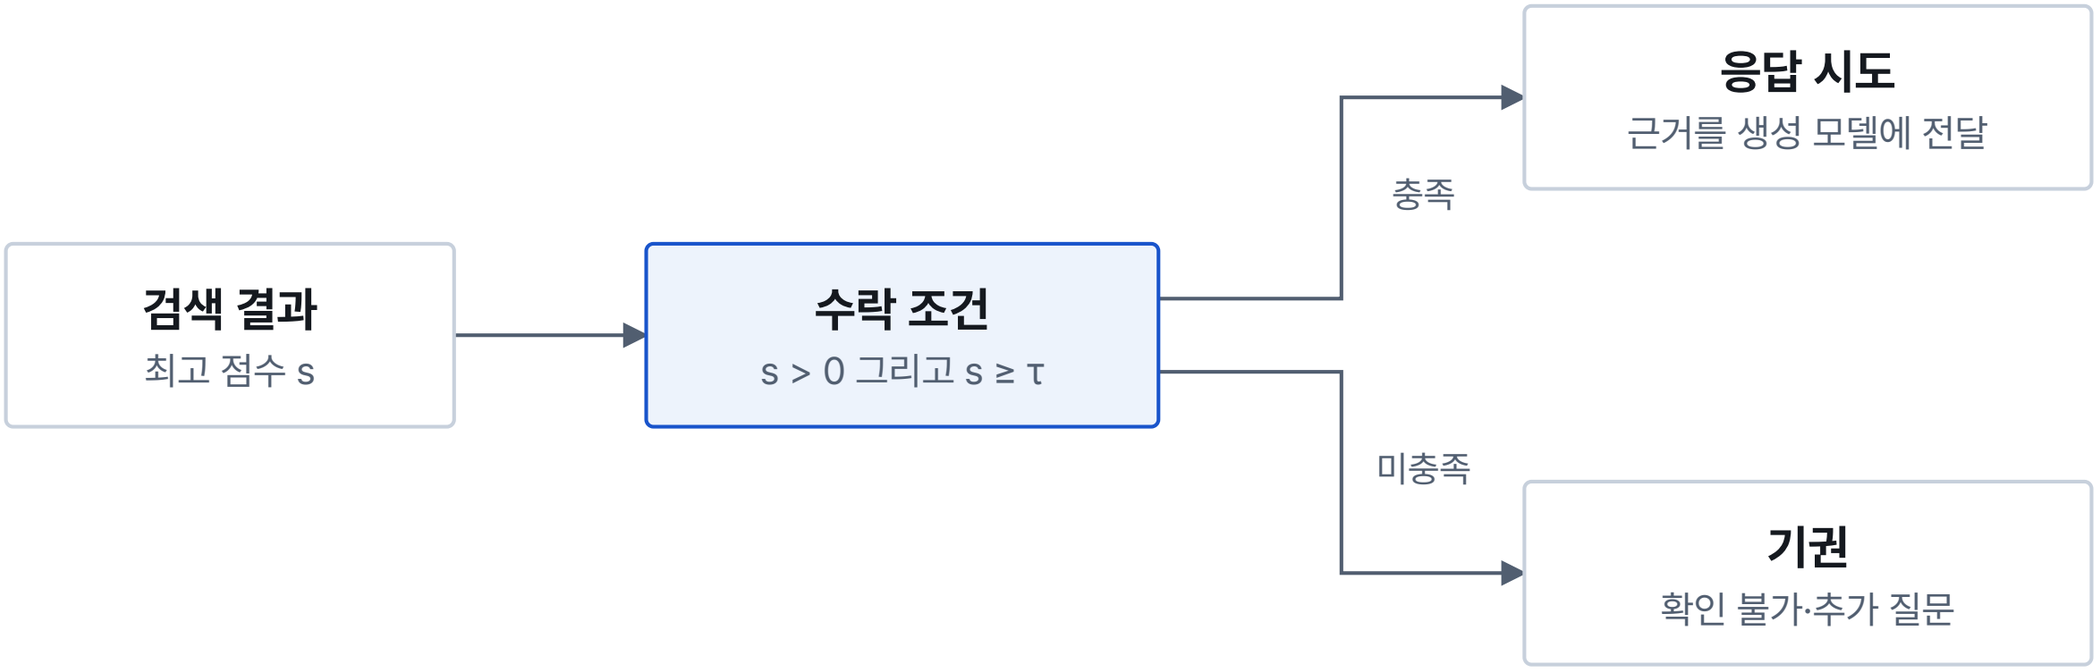
02_retrieval_baselines / 03_metrics_and_k

실행	확인할 결과	해석
02 / 기준선	D02·D20·D04 검색	폐기 문서 D20 포함
02 / 필터 비교	구버전 포함 비율 0%	문서 상태 필터의 효과
03 / 손계산	Hit=1, Recall=0.5	정답 2개 중 1개 검색
03 / k 비교	k=3과 5의 dev Recall 동일	검색 개수 증가의 한계

실습 02~03 실행 순서·확인 결과

응답과 기권의 판단 흐름

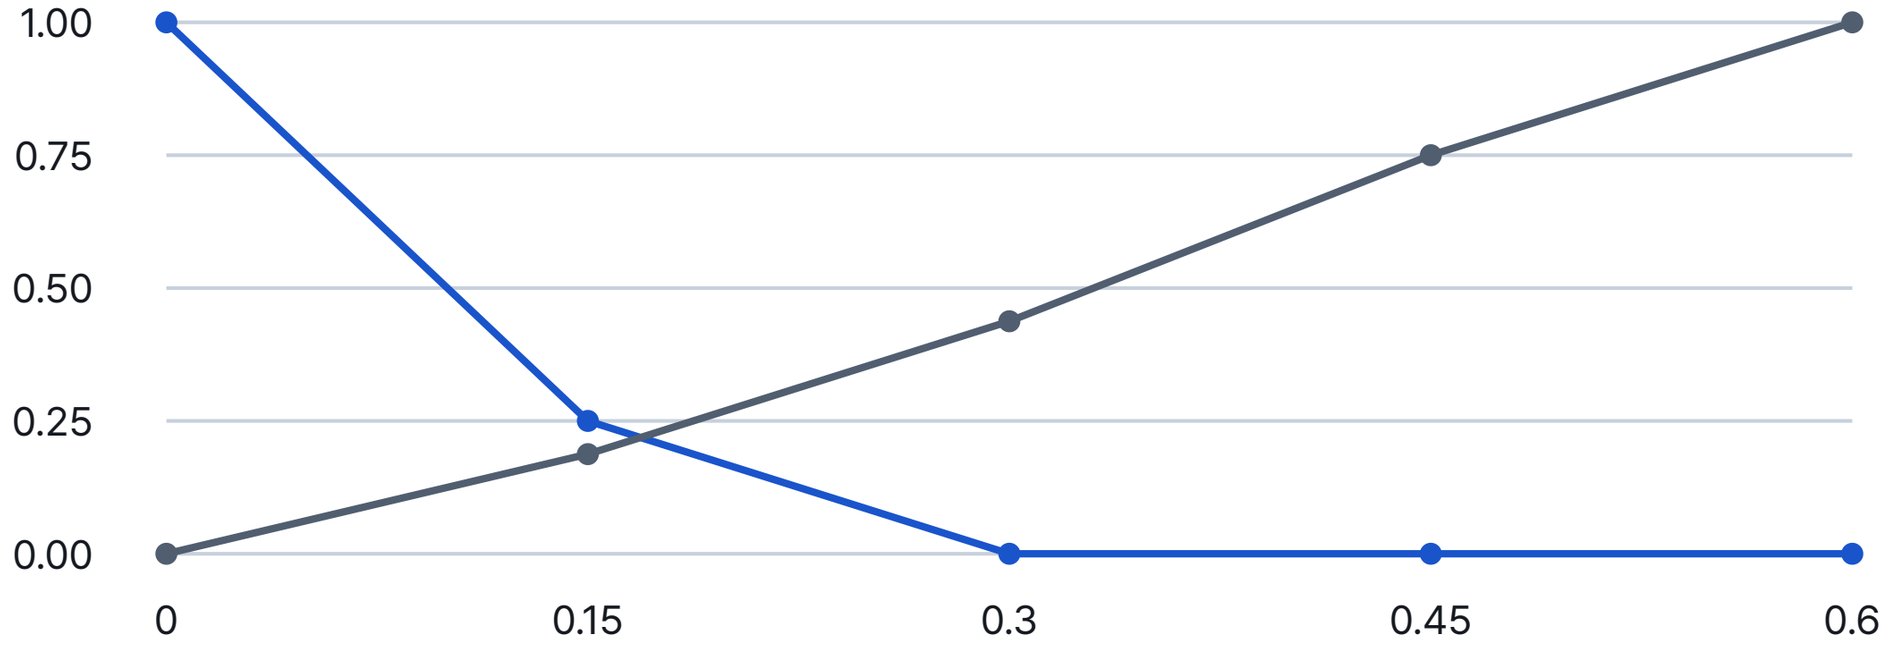
정답 확률이 아닌 검색 점수의 임계값



τ: 기권 임계값. 이 규칙만으로 답변의 사실성이 보장되지는 않음.

임계값과 사용성의 변화

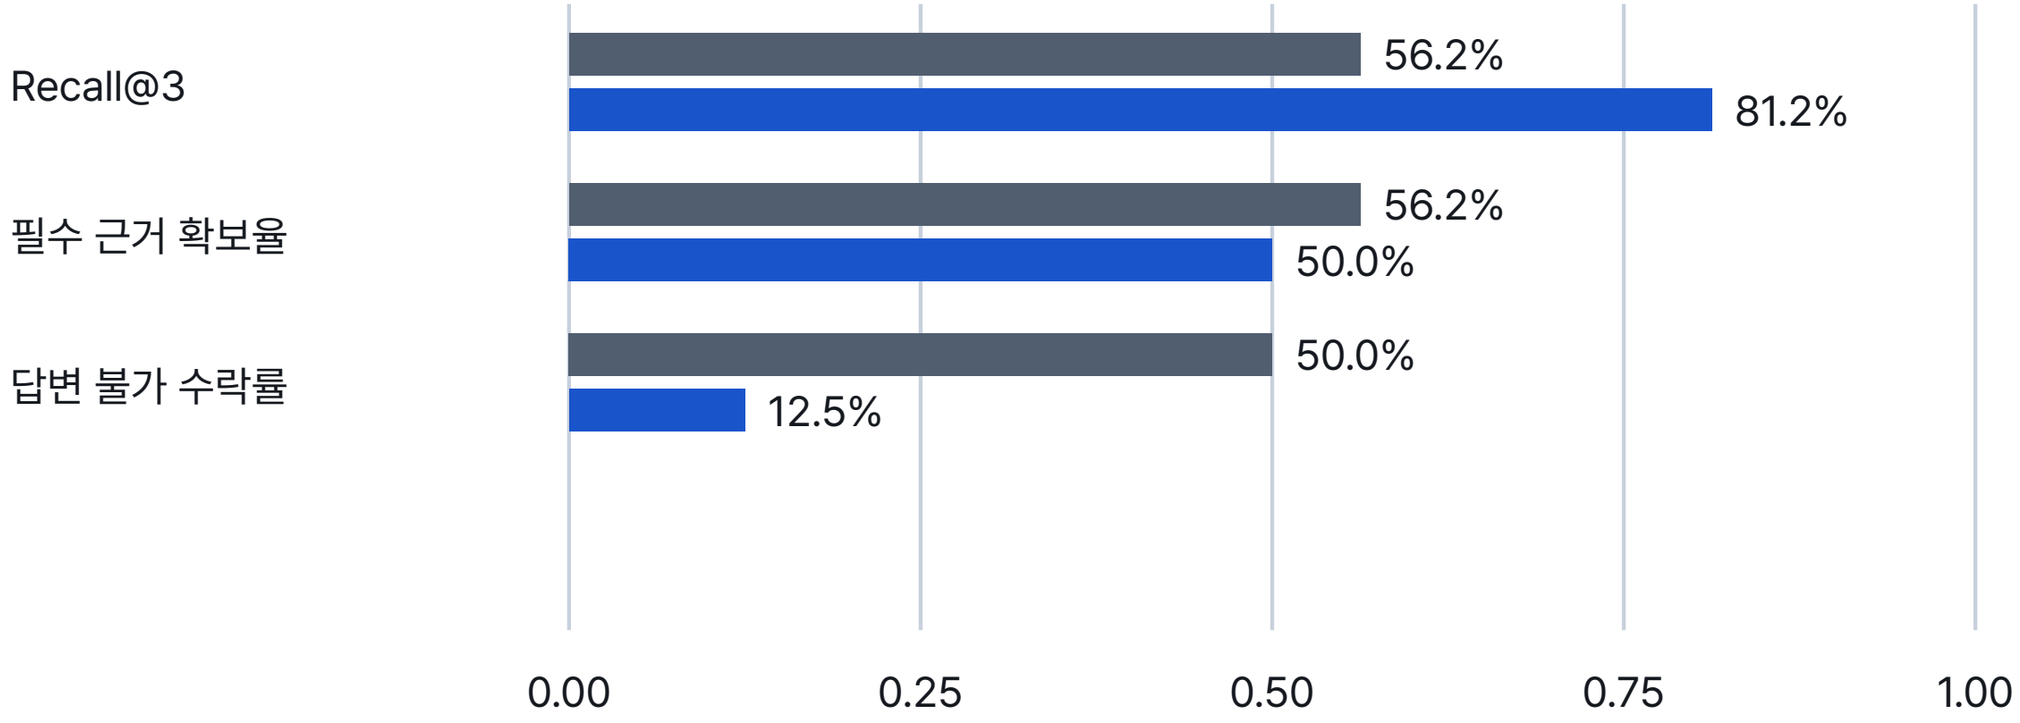
문자 검색 / 현재 문서 / k=3 / dev



파랑: 답변 불가 수락률 / 회색: 답변 가능 기권율 / 개발 세트(dev) 실측

기권 정책 적용 후의 결과

같은 24문항 / 검색 지표는 답변 가능 16문항 기준



기준선: 회색 / 후보: 파랑. 가로축 0~1, 같은 test의 실제 검색 평가.

말투별로 달라지는 결과

후보 검색기의 test 유형별 관찰

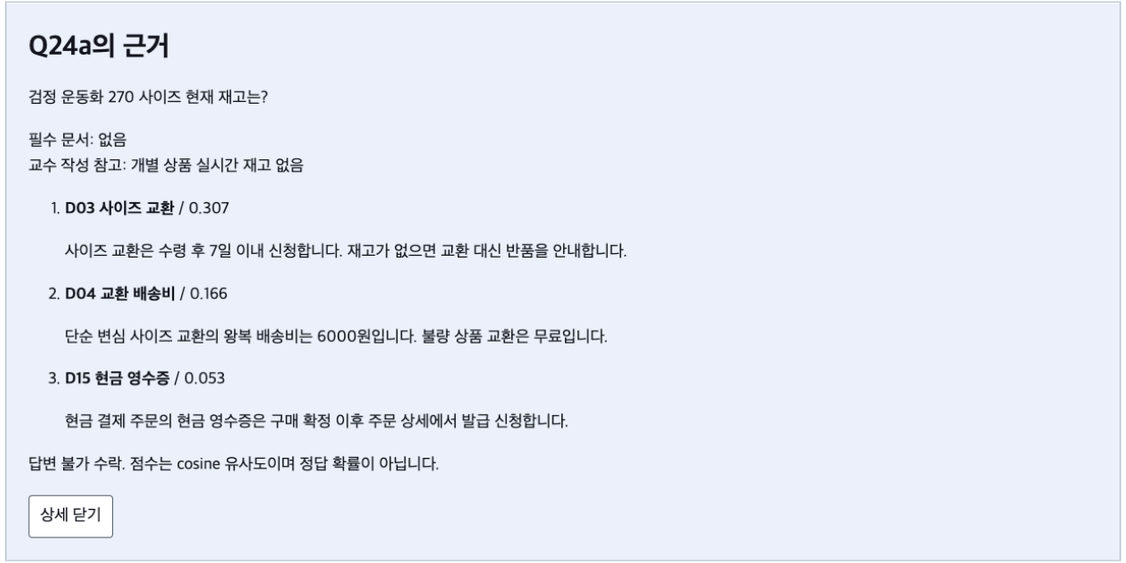
표현	문항 수	Recall@3	답변 가능 기권율
직접 질문	12	100.0%	0.0%
구어체	12	62.5%	100.0%

관련 문서와 답변 근거의 차이

HTML 보고서에서 직접 확인한 답변 불가 수락

“검정 운동화 270 사이즈 현재 재고는?”

검색	교환 규정과 배송비
부족한 정보	실시간 재고
필요한 처리	기권 또는 재고 조회



Q24a의 근거

검정 운동화 270 사이즈 현재 재고는?

필수 문서: 없음
교수 작성 참고: 개별 상품 실시간 재고 없음

1. **D03 사이즈 교환** / 0.307

   사이즈 교환은 수령 후 7일 이내 신청합니다. 재고가 없으면 교환 대신 반품을 안내합니다.

2. **D04 교환 배송비** / 0.166

   단순 변심 사이즈 교환의 왕복 배송비는 6000원입니다. 불량 상품 교환은 무료입니다.

3. **D15 현금 영수증** / 0.053

   현금 결제 주문의 현금 영수증은 구매 확정 이후 주문 상세에서 발급 신청합니다.

답변 불가 수락. 점수는 cosine 유사도이며 정답 확률이 아닙니다.

상세 닫기

Q24a의 실제 검색 결과. 그림 확대 가능.

실패 원인과 다음 실험

모든 문제를 프롬프트 수정으로 해결하지 않는 진단

관찰	우선 확인	다음 실험
필수 문서가 없음	문서 범위·수집·갱신	원문 보강 또는 기능 범위 축소
있는데 검색 실패	표현·색인·필터	검색 방식·동의어 비교
검색했으나 기권	임계값·점수 분포	dev에서 사용성·위험 재검토
잘못된 답 생성	조건·근거 활용	생성 평가·출력 검증

실습 04: 실패 질문의 재현

04_calibration_and_error_analysis.ipynb

```
선택: char-current-k3-t0.3
Recall: 56.25% → 81.25%
필수 근거 확보: 56.25% → 50%
```

확인	Q05b: 문서는 찾았지만 기권
원인	최고 점수 < 임계값 0.3
다음 실험	dev에서 위험과 사용성 비교

실습 04 실행 순서·확인 결과

빠른 로컬 모델의 실행 조건

Qwen2.5 1.5B Instruct / 실제 호출

```
ollama pull qwen2.5:1.5b-instruct

# 앱이 실행 중이지 않을 때
ollama serve
```

설정	수업 기본값
문맥 / 출력 상한	2,048 / 192 tokens
temperature / seed	0 / 11
모델 유지	10분
추론 출력	thinking 지원 시 비활성화

실제 RAG 요청의 실행 순서

검색 결과를 입력으로 전달하고 응답을 검사하는 구조

1
검색
현재 문서 상위 3개

›

2
생성
질문 + 문서 + 지시

›

3
검사
JSON·인용·기권

›

4
기록
응답·지연·버전

정답 문장·gold_ids는 생성 입력에서 제외. 실제 요청은 로컬 Ollama에만 전송.

프롬프트 변경의 실제 결과

같은 재고 질문 / 같은 검색기 / 같은 instruct 모델

기준 프롬프트

현재 재고는 없습니다.

기권: False / 인용: D03, D04

확인 불가 문장뿐 아니라 abstain·인용 값의 일관성도 검사.

근거 제한 프롬프트

검정 운동화 270 사이즈의 재고는 확인할 수 없습니다.

기권: False / 인용: D03, D04, D15

기계적 검사와 의미 검토

형식 통과와 답변 정확성의 구분

검사	자동 확인	사람이 추가로 볼 부분
JSON	필드·타입·빈 응답	표현이 질문에 적절한가
인용	검색된 문서 ID인지	주장을 실제로 뒷받침하는가
기권	참고 기준과 일치하는지	필요한 후속 안내가 있는가
완전성	필수 문서 인용 여부	기간·비용·조건을 모두 설명했는가

실습 07: 실제 응답 비교

07_ollama_rag_generation.ipynb

실행	기준 응답 → 근거 제한 응답 → 경계 질문
확인	Q03a 기간·비용 / Q24a 재고 질문 기권
기록	실제 답변·인용·모델 로드·생성 시간

실습 07 실행 순서·확인 결과

수업용 답변 판정 기준

판정 이유를 함께 남기는 세 가지 상태

판정	기준	예
supported	근거가 주장과 조건을 뒷받침	7일 규정에 7일 안내
unsupported	근거와 충돌하거나 주장이 과도함	7일을 30일로 확대
uncertain	필수 근거가 불완전하여 검토 필요	비용 문서 없이 비용 안내

빠른 규칙 검사의 한계

같은 숫자가 있어도 반대 의미가 되는 답변

“수령 후 7일 이내 반품 가능”

“수령 후 7일 이내에는 반품 불가”

```
"7일" in answer

두 답변 모두 True
하지만 의미는 반대
```

평가자 검증의 작은 기준 세트

05번: 작성 예시 8개 / 계산 구조의 사전 확인

참고 판정 / 예시 평가자	supported	unsupported	uncertain
supported	3	1	0
unsupported	1	2	0
uncertain	1	0	0

일치 5 / 8 = 62.5%. 실제 LLM 또는 인간 평가자 연구 결과가 아닙니다.

작은 모델 평가자의 실제 판정

생성 모델과 같은 모델을 평가자로 사용한 사례

생성 답변

현재 재고는 없습니다.

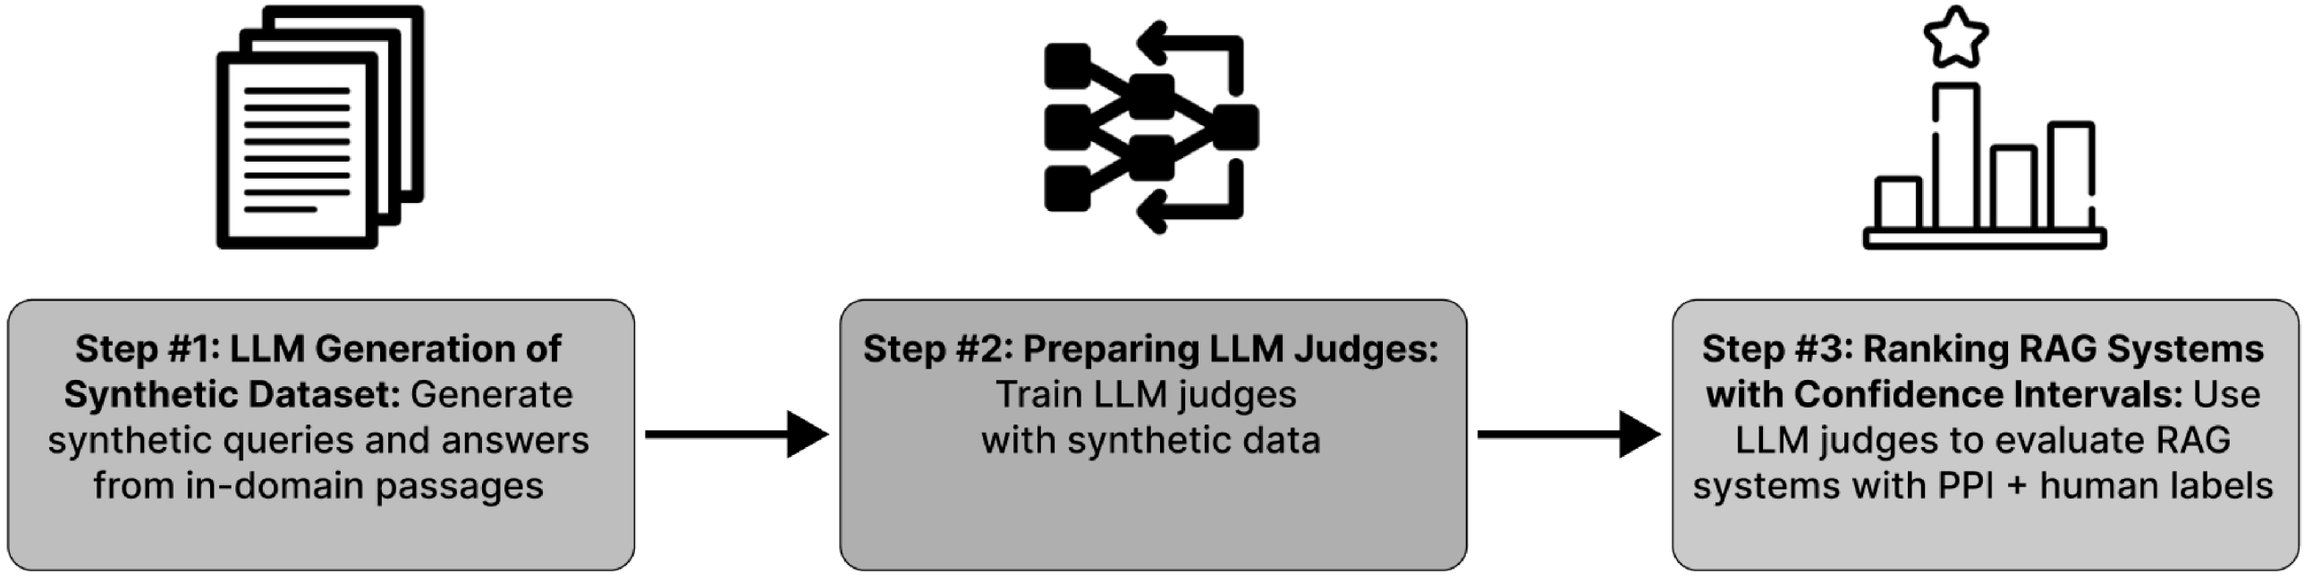
평가 모델의 판정

supported

답변은 제공된 자료에 근거해 검정 운동화 270 사이즈의 현재 재고가 없습니다고 답변하고 있습니다.

ARES: 평가자와 사람 검토의 결합

연구의 평가 구조 / 이번 실습과 다른 구현



ARES Figure 1. Saad-Falcon et al. CC BY 4.0. 원본 그림을 회색조로 표시.

실습 08: 실제 평가와 추적

08_ollama_judge_and_traces.ipynb

평가자 점검	4개 기준 사례에 실제 모델 판정
서비스 응답	새로 생성한 Q03a 답변의 평가
추적	검색·생성·코드 검사·모델 판정 연결

실습 08 실행 순서·확인 결과 / 05번 작성 예시와 actual 판정의 구분

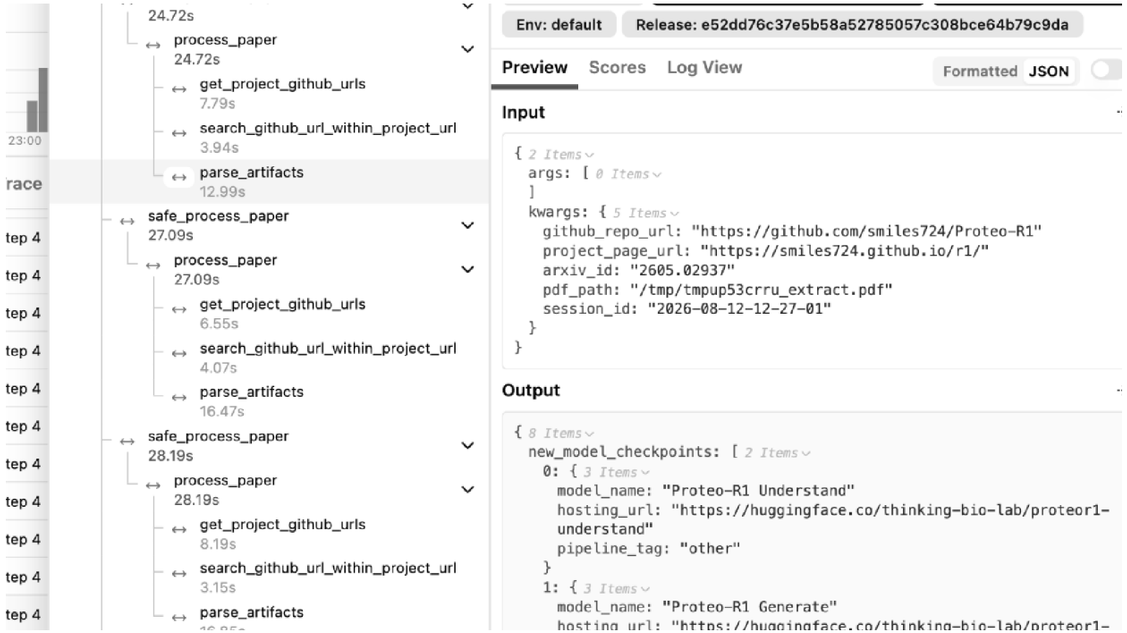
필요한 기능과 선택 가능한 도구

Langfuse·LangSmith의 수업 내 역할

서비스에 필요한 기능	도구 없이 시작	플랫폼 도입 시
요청 추적	로컬 JSONL·trace_id	요청 검색·단계별 탐색
반복 비교	같은 데이터의 두 실행	실험 이력·버전 비교
검토 기록	실패 사례·사람 판정	점수·검토 큐·팀 협업

Langfuse: 실패 요청의 원인 추적

공식 문서의 실제 UI 사례



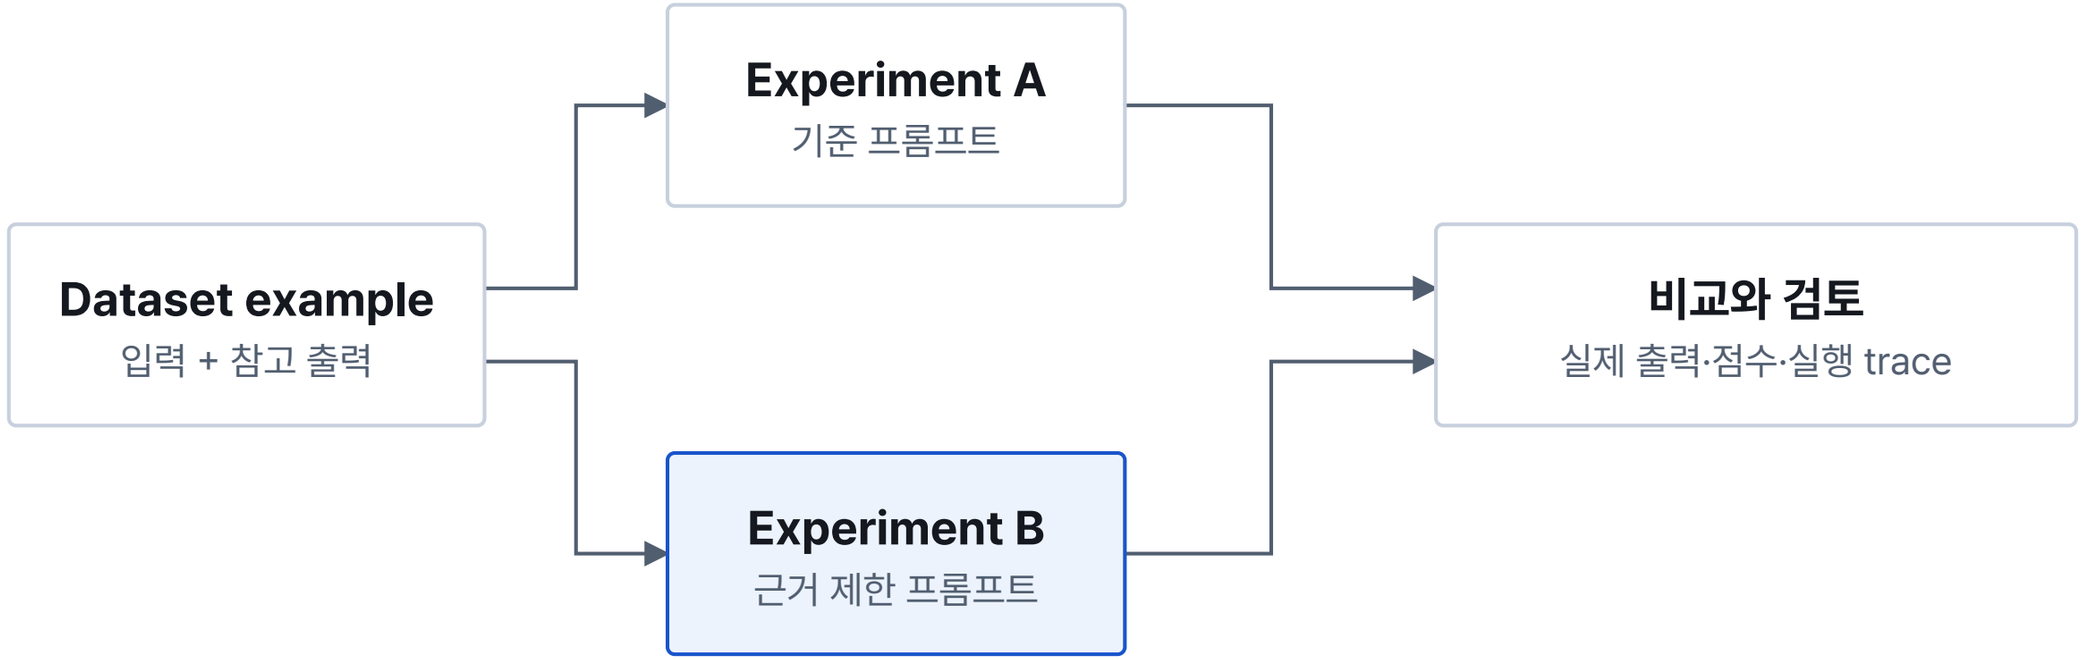
공식 화면 일부 확대 / 전체 그림 확인 가능

수업 계정의 실행 화면이 아닌 공식 문서 사례.

작업 트리	어느 단계가 느리거나 실패했는가
입력·출력	실제로 무엇을 받아 반환했는가
검토·평가	점수와 검토 의견을 어디에 남기는가

LangSmith: 같은 질문의 실험 비교

Dataset example과 Experiment의 연결



공식 문서의 개념을 수업 사례로 재구성. 제품 화면을 모사한 그림이 아님.

실습 기록과 제품 용어의 대응

기능의 역할로 읽는 도구 비교

이번 실습	Langfuse	LangSmith
trace_id + spans	Trace / observations	Run trace / child runs
질문 + 참고 기준	Dataset item	Dataset example
프롬프트별 실행	Experiment	Experiment
검사·평가·검토	Scores / annotation	Feedback / annotation queue

운영 실패의 재평가 흐름

실제 요청을 다음 평가 세트로 연결하는 절차

1

운영 관찰

오류·낮은 평가·기권

›

2

검토

권한·비식별·기준 확인

›

3

평가 세트

대표 실패와 정상 사례

›

4

변경 검증

같은 입력으로 재실행

실패 사례만 모으면 사용 분포가 왜곡될 수 있음. 대표 사례와 위험 사례를 함께 관리.

개선 폭의 불확실성

의도 그룹 bootstrap 2,000회 / seed=11

Recall 평균 차이

25.0%p

후보 − 기준선

95% bootstrap 구간

6.2 ~ 43.8

단위: %p

비교 가능한 그룹

8

답변 가능한 의도 수

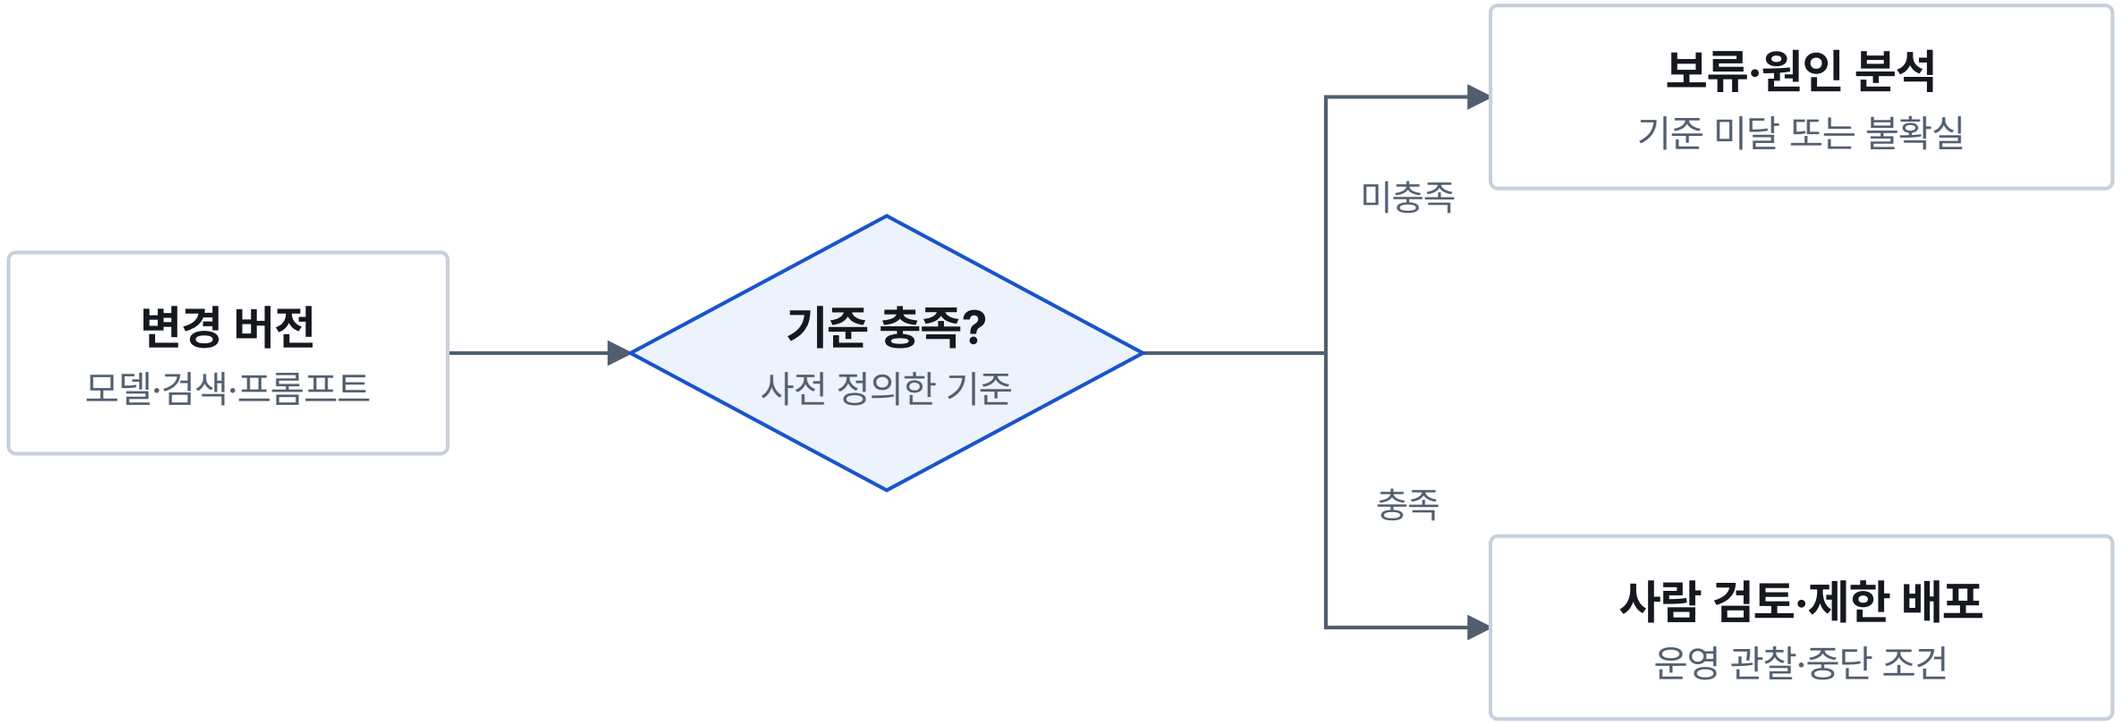
배포 전 검증 조건의 결과

교육용 기준 / 실제 서비스는 위험과 비용에 맞게 재정의

조건	측정	결과
답변 불가 수락률 ≤ 10%	12.5%	보류
필수 근거 확보율 ≥ 80%	50.0%	보류
Recall 관측 하락 없음	+25.0%p	통과
Recall 차이 구간 하한 ≥ −5%p	6.2%p	통과

품질 검증과 배포 승인

교육용 HOLD는 차단 / 통과 이후에도 검토



검증 조건은 서비스 위험·비용에 맞게 정의. 점수 평균으로 필수 실패를 상쇄하지 않는 예시.

평가 보고서의 실제 화면

수치에서 질문별 근거로 이동하는 탐색

필수 근거 확보율	답변 불가 수락률	응답 시도 비율
50.0%	12.5%	37.5%
답변 가능 질문 기준	답변 불가 질문 기준	전체 질문 기준

실제 보고서의 핵심 지표. 답변 가능한 질문과 불가능한 질문의 분모 구분.

실행 선택된 후보 | 유형 전체 | 결과 전체 | 질문 검색 검색어 입력 | 필터 초기화

질문 유형·실패 종류·검색어로 결과 탐색. 각 질문에서 문서 근거 확인.

실습 06: 보고서 재생성과 확인

06_release_report.ipynb

```
python -m week11.lab.run_eval

# 실제 생성과 평가
python -m week11.lab.ollama_lab \
  --limit 3 --judge
```

06 / 검색 평가	report.html / HOLD
07~08 / 실제 LLM	ollama-report.html / 실제 응답
열기	VS Code 탐색기 → 브라우저

실습 06~08 실행 순서·확인 결과

실제 생성의 지연과 실행 기록

Ollama API 응답에서 가져온 토큰·소요 시간

질문	프롬프트	응답 시간	출력 토큰
Q01a	baseline	335 ms	45
Q01a	grounded	328 ms	46
Q03a	baseline	311 ms	51
Q03a	grounded	541 ms	85

로컬 기기 관측값. 최초 모델 로드·동시 실행·질문 길이에 따라 달라짐.

프로젝트의 한 페이지 평가 기록

복잡한 과정 설명보다 결과와 근거를 먼저 제시

결론	채택·추가 검토·보류와 이유
조건	데이터·모델·검색·프롬프트 버전
근거	지표와 실제 실패 응답 2건
다음 행동	한 가지 변경과 재평가 계획

학습 확인과 다음 단계

자신의 실행 결과를 근거로 설명할 세 가지

검색	근거를 찾았는데도 왜 잘못 답할 수 있는가
평가	평가자가 supported라 해도 무엇을 더 확인할까
운영	이번 실패를 다음 변경에서 어떻게 재검증할까

실습 안내와 참고 자료

실행 순서, 공개 보고서, 공식 문서

실습 안내	실습 01~08 실행 순서·확인 결과
실제 응답	Ollama 실행 보고서
검색 평가	기준선·후보 비교 보고서

참고	핵심 관점
Langfuse	실행 추적·평가
LangSmith	데이터·실험 비교
MLflow	평가 실행 구성
ARES	평가자 검증
Lost in the Middle	문맥 활용의 한계