지도 미세조정과 메모리 효율

SFT · LoRA · QLoRA

6주차 학습 단원 보충 · 7주차 통합 강의 복습

차성재 · 무신사 Core AI PM × AI 대학원 겸임교수

6–7주차 자료의 연결

10월 9일 휴일에는 수업·녹화·신규 과제 없음

6주차 기술 내용은 10월 16일 7주차에서 함께 진행

통합 녹화 영상과 이번 시각 자료로 복습

기획서 마감: 10.22(목) 23:59 한국시간 · 10.23은 제출물 평가

오늘의 구분

01	SFT	어떤 입력과 기대 답변으로 학습하는가
02	LoRA	어떤 파라미터를 갱신하는가
03	QLoRA	고정 모델을 어떤 정밀도로 저장하는가

SFT라는 학습 목적에 LoRA 또는 QLoRA를 결합할 수 있음

학습보다 먼저 확인할 문제

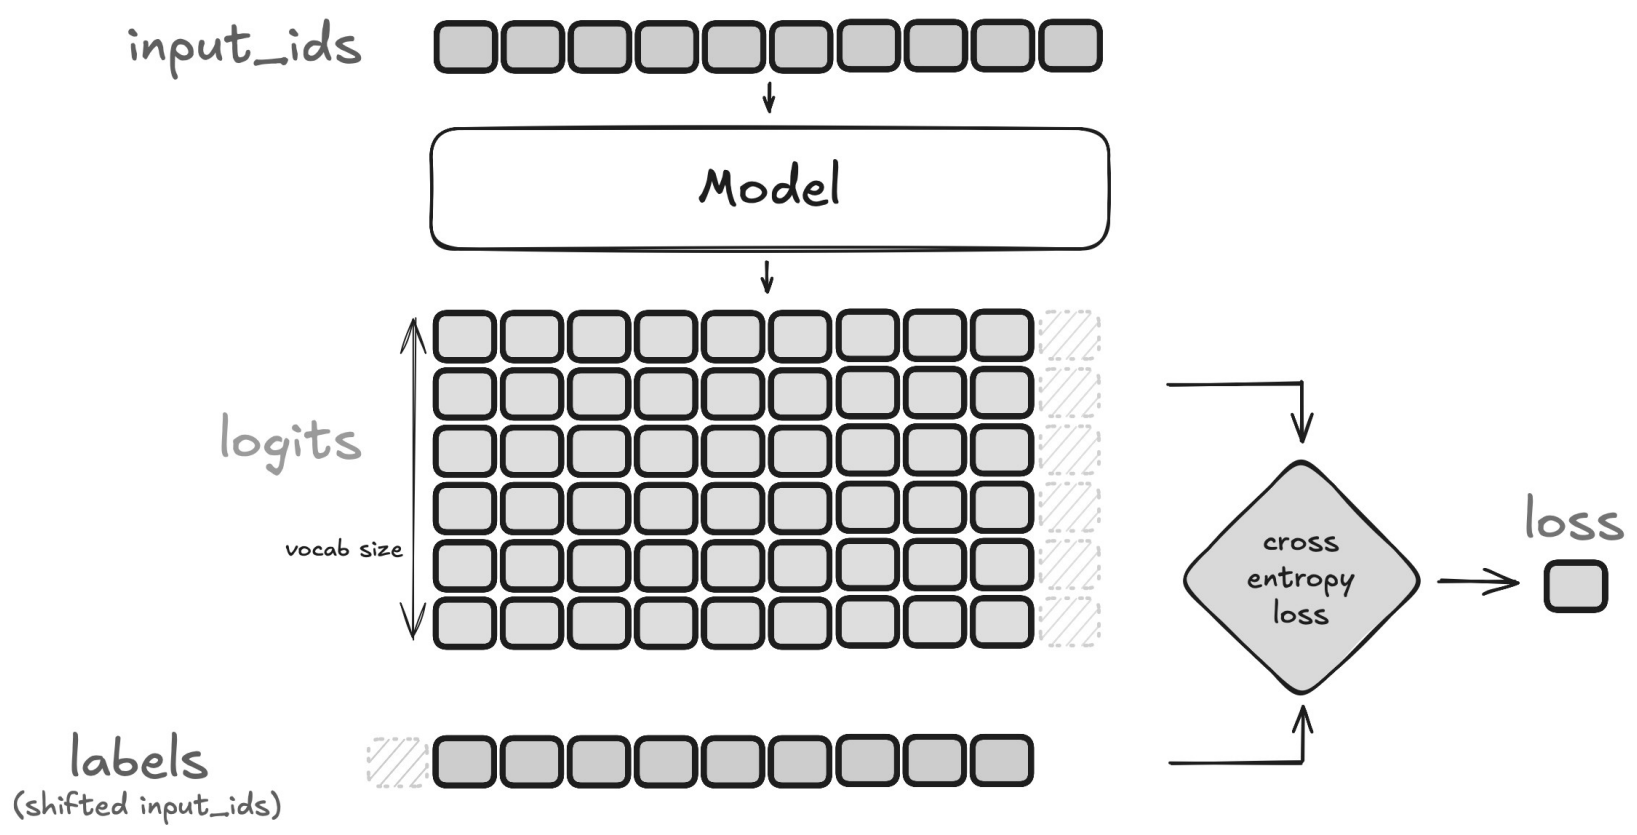
문제	첫 비교 대상	확인할 근거
최신 정책 오류	검색·문서 버전	적용일·출처·권한
출력 형식 오류	프롬프트·출력 검사	같은 입력의 반복 실패
반복 행동 불안정	SFT·Adapter	허가된 예시·보류 평가셋

지도 미세조정

Supervised Fine-Tuning · SFT

업무 입력과 기대 답변으로 다음 토큰 예측 학습

SFT의 토큰 예측과 손실



입력

input_ids: 토큰 ID의 나열

예측

logits: 다음 토큰의 점수

비교

labels와 교차 엔트로피 손실

Hugging Face TRL 공식 도식 · 원본 이미지의 흑백 표시

학습 데이터 한 건

```
instruction: 문의 상태 정리
input: 합성 사례 DEMO-01
response:
  status: review
  source: DEMO-01
```

입력과 기대 출력의 경계

합성 사례만 사용

형식·정확성 별도 검토

상태·출처를 정리하는 설명용 예시 · 실제 정책 아님

자료 준비와 평가 분리

01

수집

사용 허가

02

검사

필드·중복

03

분할

사건·시간

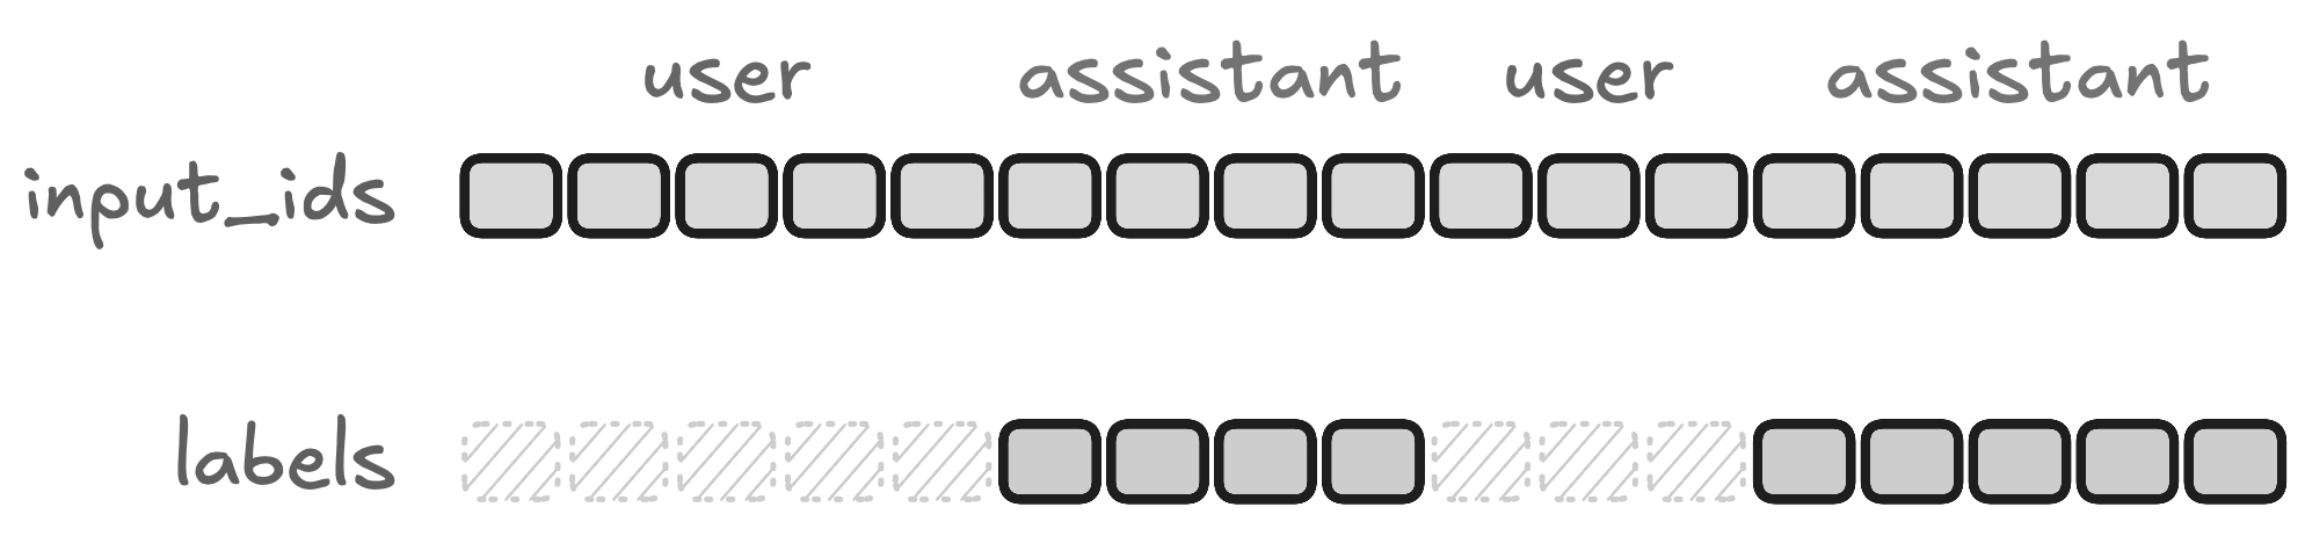
04

보류

최종 평가셋

같은 사건의 표현을 train과 test에 나누면 평가가 낙관적으로 보일 수 있음

답변 구간의 손실 마스킹



user

사용자 입력은 참고 문맥

assistant

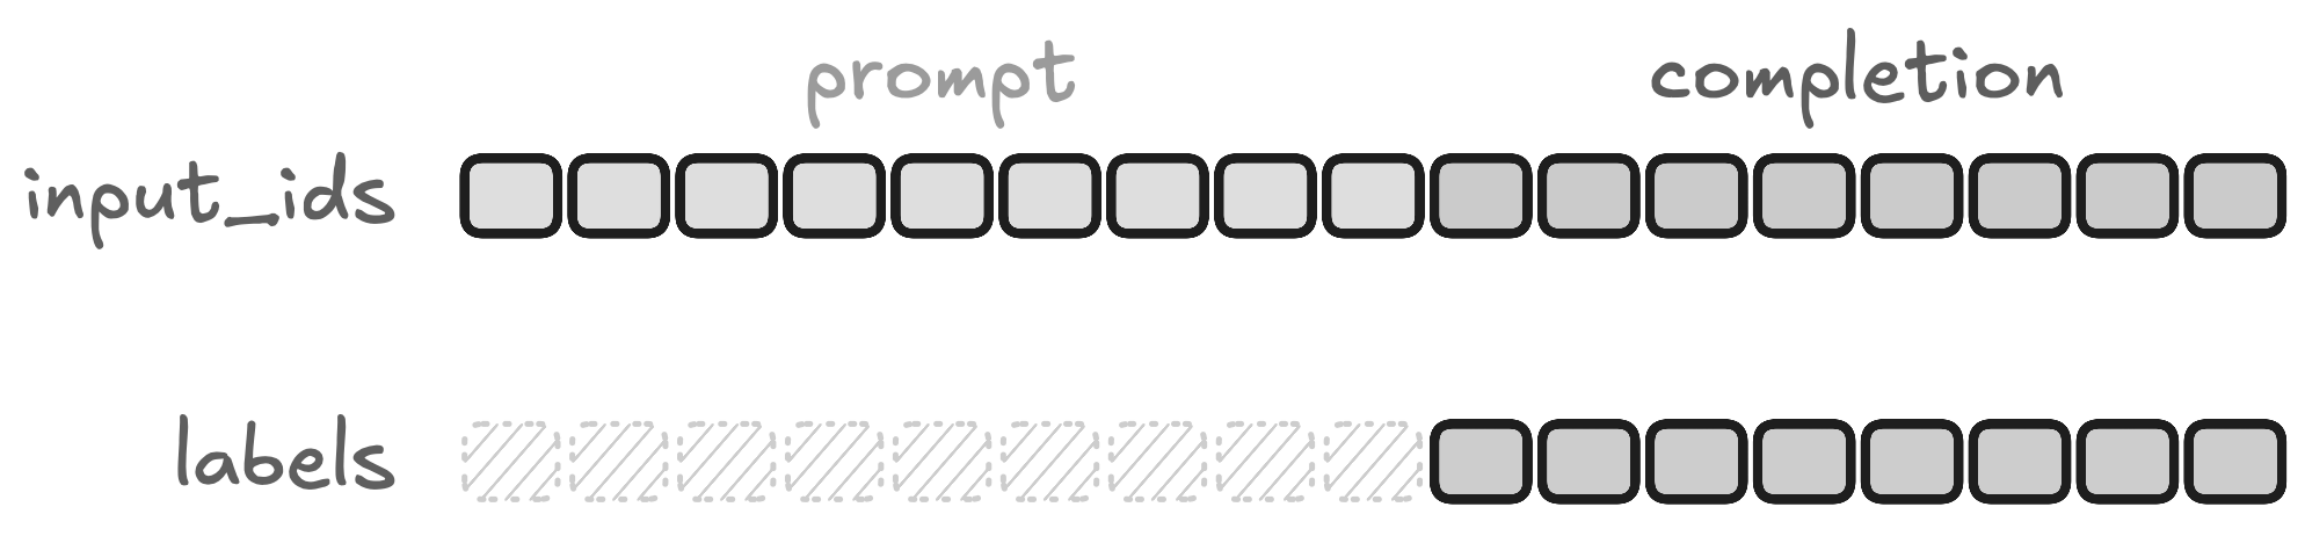
선택한 답변 토큰에 학습 신호

빗금 구간

손실 계산에서 제외한 위치

Hugging Face TRL · assistant-only loss · 모델별 템플릿 확인

Prompt와 Completion의 분리



prompt

질문·지시·참고 문맥

completion

기대 답변

확인

답변 경계·종료 토큰·잘림

Hugging Face TRL · completion-only loss · assistant-only와 입력 형식 구분

마스킹의 최소 확인

```
token_ids = [10, 11, 12, 20, 21, 22]
labels = [-100, -100, -100, 20, 21, 22]
assert sum(x != -100 for x in labels) == 3
```

가상 토큰 ID · 실제 모델 tokenizer 실행과 구분

길이 제한과 답변 누락

긴 문맥이 답변 구간을 밀어내는 문제

문자 길이 대신 해당 모델의 토큰 길이 확인

긴 사례·짧은 사례·경계 사례를 따로 점검

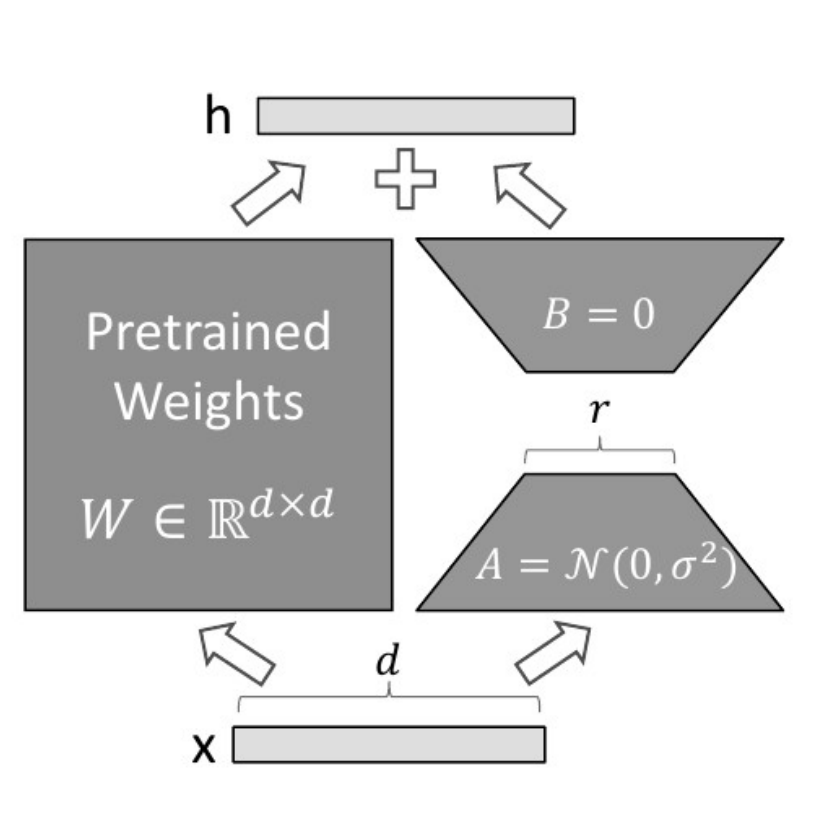
답변 정답이 잘린 데이터로 학습하지 않도록 사전 검사

LoRA의 구조

Low-Rank Adaptation · 저차원 행렬 기반 모델 적응

기존 가중치는 고정하고 작은 두 행렬을 학습

LoRA 원 논문의 두 경로



Hu et al., 2021, Figure 1 · 원본 도식 발췌·흑백 렌더링

고정 경로 W

기존 모델의 계산 유지

학습 경로 A·B

작은 변화량을 학습

합산

두 경로의 출력 결합

가중치 변화의 표현

$$W' = W + (\alpha / r) \cdot BA$$

W: 고정 모델 가중치 · A와 B: 학습 행렬

r: rank · α : 변화량의 배율 설정

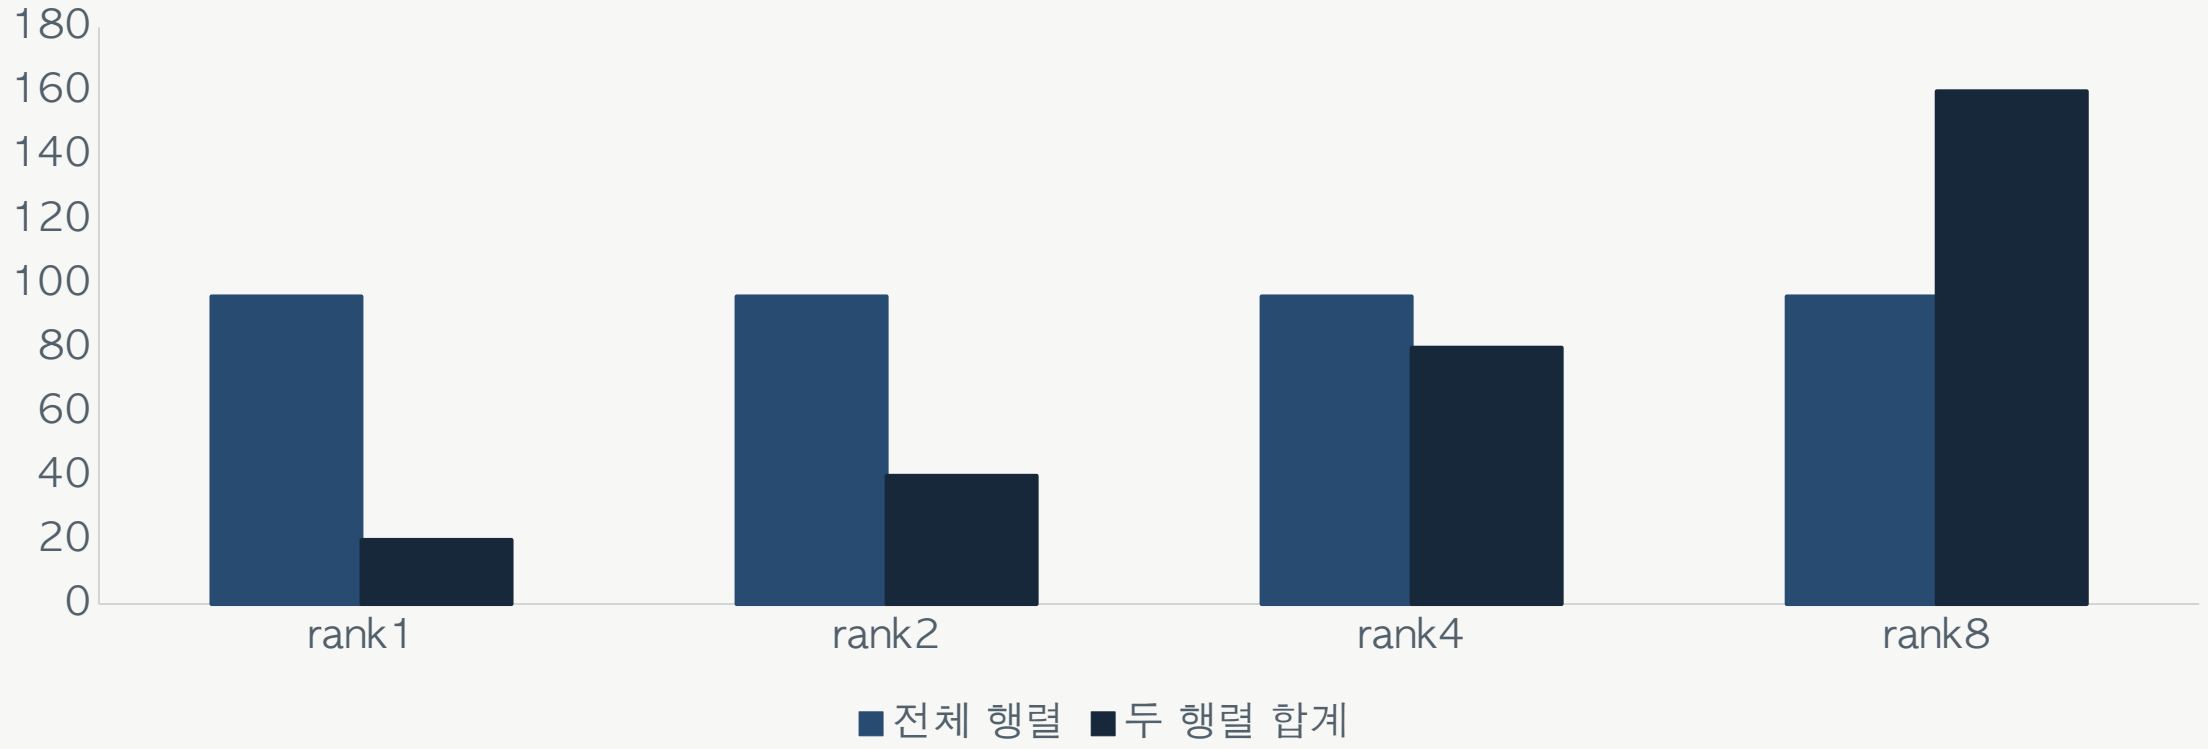
일반 LoRA scaling 기준 · rsLoRA 등 다른 변형은 설정을 구분

작은 행렬의 차원

01	02	03	04
입력	A	B	출력
8차원	2 × 8	12 × 2	12차원

예시 r=2 · BA는 12×8 · 7주차 Notebook 02와 연결

rank별 학습 파라미터



12×8 합성 행렬 · 전체 96개 · 두 행렬 r(12+8) · 실제 GPU 측정 아님

rank 선택의 조건

작은 rank는 적은 파라미터로 변화량을 표현

큰 rank가 항상 더 좋은 업무 품질을 보장하지 않음

고정된 평가 입력과 비용으로 후보 비교

작은 12×8 예시에서는 rank 8의 두 행렬이 원본보다 큼

LoRA 설정의 역할

```
r = 8
lora_alpha = 16
target_modules = ["q_proj", "v_proj"]
seed = 42
```

설정과 실행 결과의 구분

rank·alpha: 용량과 배율

target_modules: 적용할 모듈

seed 외 환경도 함께 기록

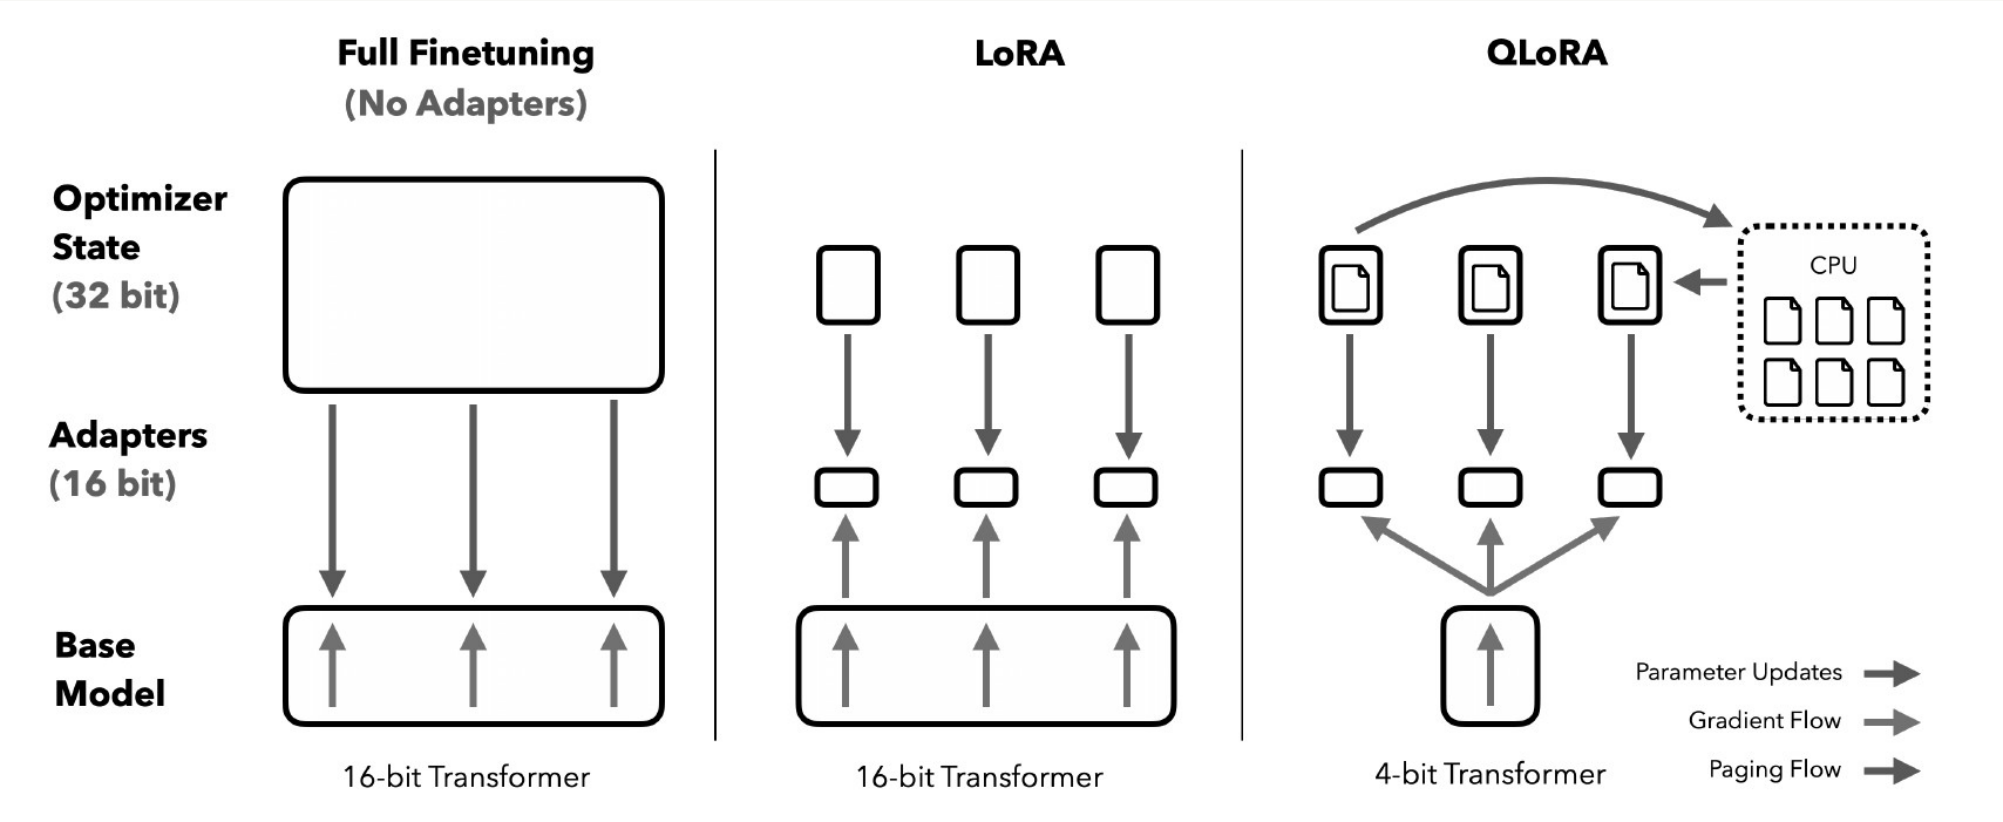
설정 설명용 예시 · 모델 구조·구현 버전에 따라 재검증

QLoRA의 메모리 절약

Quantized Low-Rank Adaptation · 양자화 기반 LoRA

고정 모델의 저장 비용까지 줄이는 접근

전체 미세조정·LoRA·QLoRA



모델 가중치와 optimizer 상태 고정 모델과 학습 Adapter 4-bit 고정 모델과 Adapter

QLoRA Figure 1 · CC BY 4.0 · 흑백 발췌

저장 정밀도와 계산 정밀도

저장

고정 모델의 주 가중치를 4-bit로 압축

블록별 스케일 등 추가 정보 보존

계산

필요한 연산에서 복원해 계산

Adapter는 높은 정밀도로 학습

4-bit 저장은 모든 연산·활성값·optimizer가 4-bit라는 뜻이 아님

QLoRA의 세 가지 구성

기술	역할
NF4 · 4-bit NormalFloat	정규분포 가중치를 고려한 양자화 표현
Double Quantization	양자화 상수도 양자화해 부가 저장량 절약
Paged Optimizers	메모리 급증 시 CPU/GPU 메모리 관리

실제 지원 하드웨어·커널·학습 설정은 별도 확인

가중치 저장량의 계산

정밀도	7B × bit/8	읽는 방법
16-bit	14.0 GB	가중치 원시 저장량
8-bit	7.0 GB	추가 메타데이터 제외
4-bit	3.5 GB	총 학습 메모리가 아님

7B=70억 파라미터 가정 · 십진 GB · scale·Adapter·activation·optimizer 제외

총 학습 메모리의 구성

압축한 모델 가중치 외의 추가 비용

Adapter·gradient·optimizer state·activation

입력 길이·batch·체크포인팅·버퍼도 영향

같은 모델·길이·batch에서 최대 사용량을 측정해 판단

학습 환경의 사전 점검

01	**지원**	하드웨어·정밀도·라이브러리 조합
02	**작은 실행**	짧은 길이·작은 batch로 점검
03	**평가**	정답·형식·비용의 기준선 확보

공통 Notebook은 GPU·모델 다운로드 없는 개념 실험으로 진행

Base와 Adapter의 비교

동일 입력에서 답변 품질과 운영 비용을 확인

학습 손실과 실제 사용 품질의 구분

평가 조건과 기록

검사	같게 유지할 조건	남길 결과
업무 품질	입력·근거·출력 규칙	통과·실패와 응답 원문
비용	기기·길이·반복·예열	시간·최대 메모리
재현	모델·토크나이저·Adapter	버전·설정·데이터 해시

손실 감소 이후의 실패

출력 형식은 좋아졌지만 근거 없는 답변 증가

학습 사례에는 정확하지만 새 사건에는 실패

형식·근거·보류·일반화를 분리해서 검토

Adapter의 보존과 복구

01

Base

모델 revision

02

Tokenizer

chat template

03

Adapter

가중치·설정

04

평가

입력·원문·결정

Adapter 파일만 저장하면 재현과 복구에 필요한 정보가 빠짐

실습 연결과 확인 질문

01	Notebook 01	동일 사건이 분할을 넘는 데이터 누출 탐지
02	Notebook 02	rank·행렬 오차·파라미터 수 비교
03	**확인 질문**	실제 모델 학습과 이번 수치 실험의 차이

7주차 lab/notebooks · 기존 실습 파일과 공통 requirements 유지

참고 자료와 복습 경로

Hugging Face TRL · SFT Trainer 공식 도식

LoRA 원 논문 · QLoRA 원 논문과 공식 해설

7주차 통합 녹화 · Notebook 01·02

원본 이미지 출처·이용 범위: lecture/assets/SOURCES.md